Lista 1 - Prática (MAE5763)

Jaqueline Lamas (17646475) e Lais Uchoa()

Table of contents

Exercício 1 **1**
Análise Descritiva 2
Ajuste do modelo 3
Validação do modelo 4
Análise de resíduos 4
Análise de diagnóstico 5

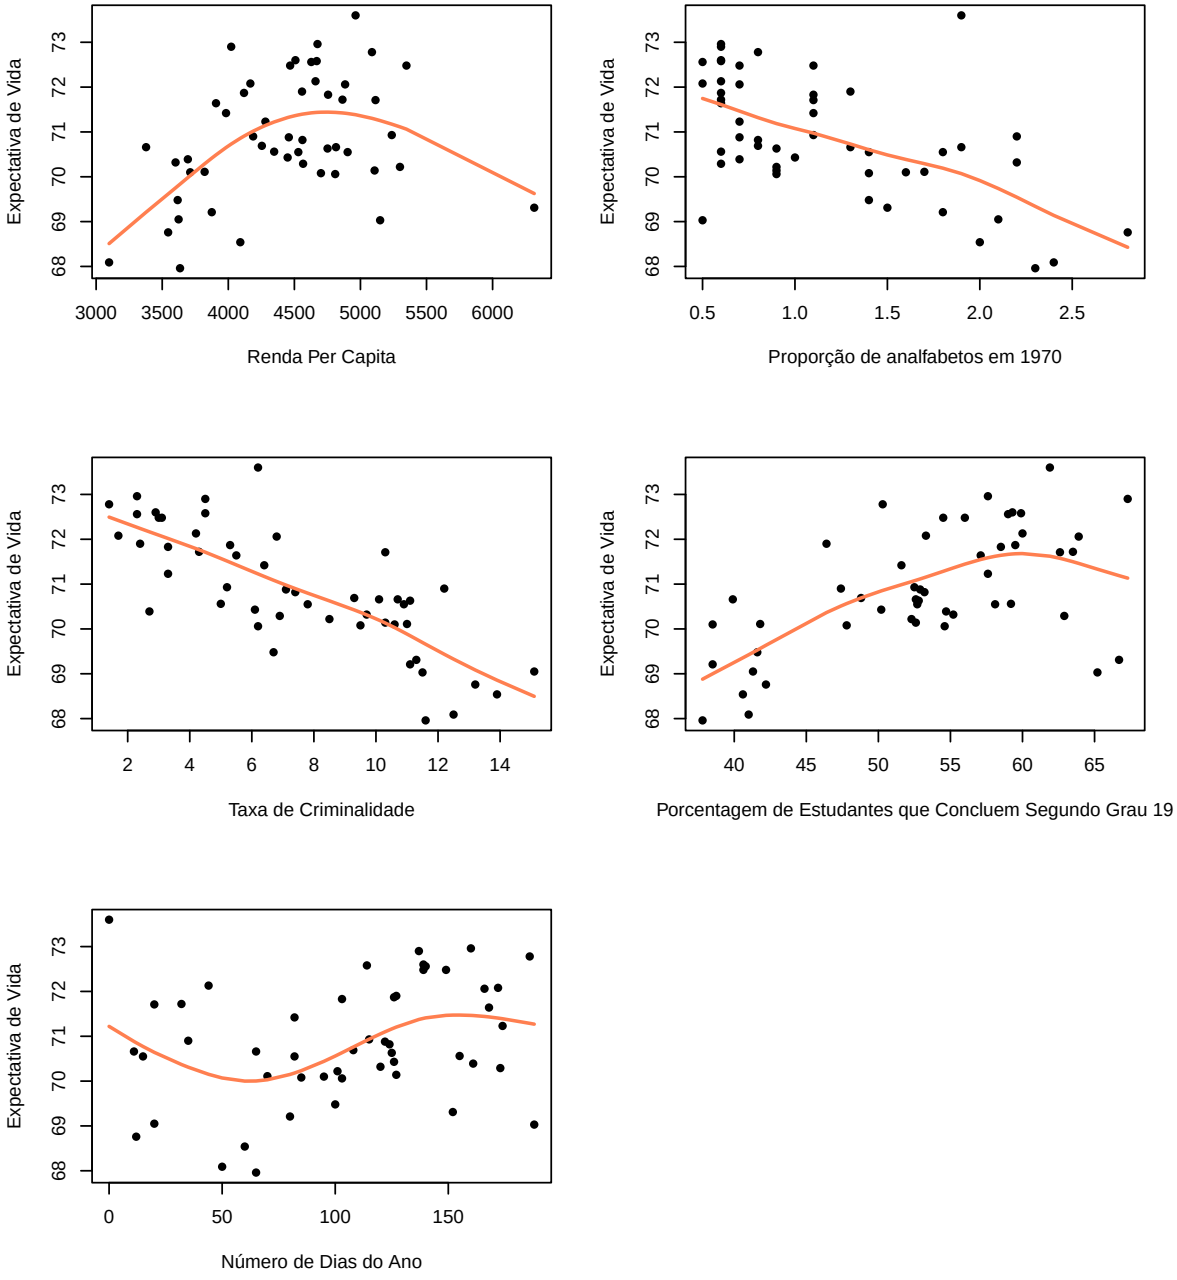
Exercício 1

- **UF** (nome do estado); **pop** (população estimada em julho de 1975); **renda** (renda per-capita em 1974 em USD); **propa** (proporção de analfabetos em 1970); **expec** (expectativa de vida em anos 1969-70); **taxa** (taxa de criminalidade por 100000 habitantes 1976); **prope** (porcentagem de estudantes que concluem segundo grau 1970); **ndazero** (número de dias do ano com temperatura abaixo de zero grau Celsus na cidade mais importante do estado); **area** (área do estado em milhas quadradas).

O objetivo do estudo é explicar a *expec* média usando um modelo de regressão normal linear dadas as variáveis explicativas *renda*, *propa*, *taxa*, *prope* e *ndazero*.

Análise Descritiva

Figura 1: Gráficos de dispersão da variável resposta pelas explicativas.



Pelos gráficos de dispersão conseguimos observar que:

- As variáveis Taxa de Criminalidade e Proporção de Analfabetos em 1970 parecem se

relacionar negativamente e de forma linear com a Expectativa de Vida.

- A variável Porcentagem de Estudantes que Conluem o Ensino Médio parece estar relacionada com a resposta por meio de uma curva, com uma tendência positiva.
- As variável Renda e Número de Dias do Ano com Temperaturas abaixo de zero aparenta se relacionar com a resposta por meio de uma curva.

Ajuste do modelo

- **Ajuste inicial**:

$$(1)\ Y_i \sim N(\mu_i, \sigma^2)$$
$$(2)\ \mu_i = \beta_0 + \beta_1 renda + \beta_2 propa + \beta_3 taxa + \beta_4 prope + \beta_5 ndazero$$

- Após a seleção baseada no AIC, temos o seguinte modelo ajustado:

$$(1)\ Y_i \sim N(\hat{\mu}_i, \hat{\sigma}^2), \hat{\sigma}^2 = 0.5074$$
$$(2)\ \hat{\mu}_i = 71.04 - 0.2831 taxa + 0.0499 prope - 0.0069 ndazero$$

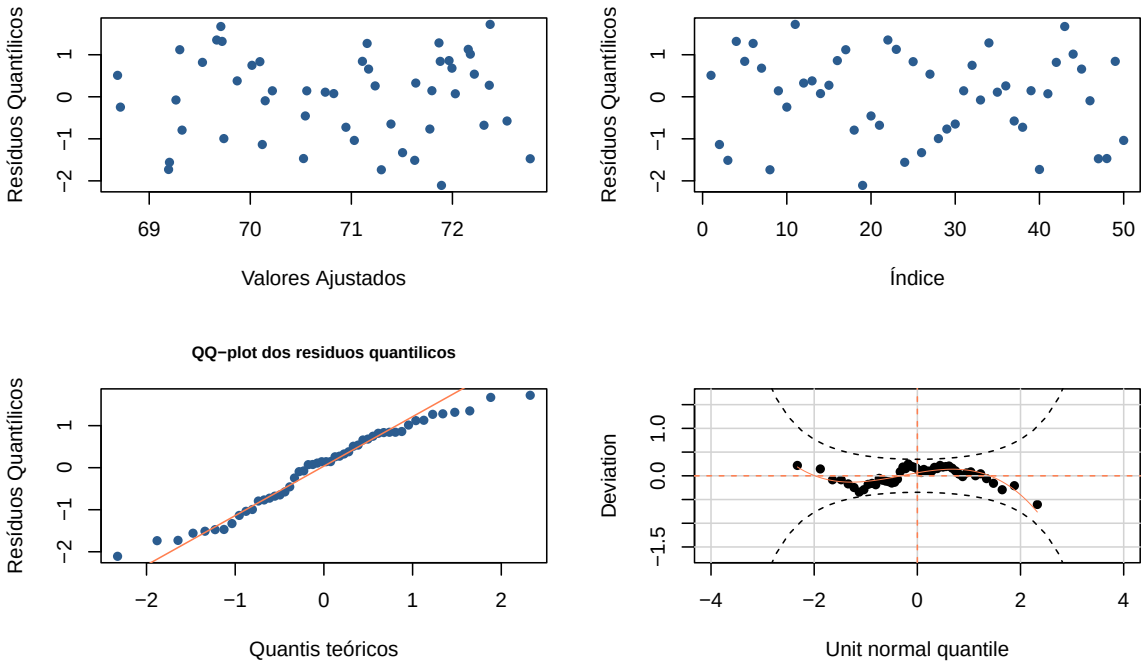
Todos os coeficientes foram significativos a um nível de signinficância de 5%.

- Considerando um estado em que a taxa de criminalidade é nula, a porcentagem de estudantes que concluem o ensino médio é igual a zero e nenhum dia ano apresenta temperaturas negativas na cidade mais inportante do estado. Espera-se que a expectativa de vida seja em média 71.04 anos.
- Considerando as outras covariáveis constantes, ao aumentar uma unidade na taxa de criminalidade espera-se uma redução de 0.2831 na média da expectativa de vida.
- Considerando as outras covariáveis constantes, ao aumentar 1% na porporção de estudantes que concluem o ensino médio espera-se observar um aumento de 0.0499 na expectativa de vida média.
- Considerando as outras covariáveis constantes, com o aumento de um dia nos número de dias do ano com temperaturas abaixo de zero na cidade mais importante do estado, espera-se uma redução de 0.0069 na média da expectativa de vida.

Validação do modelo

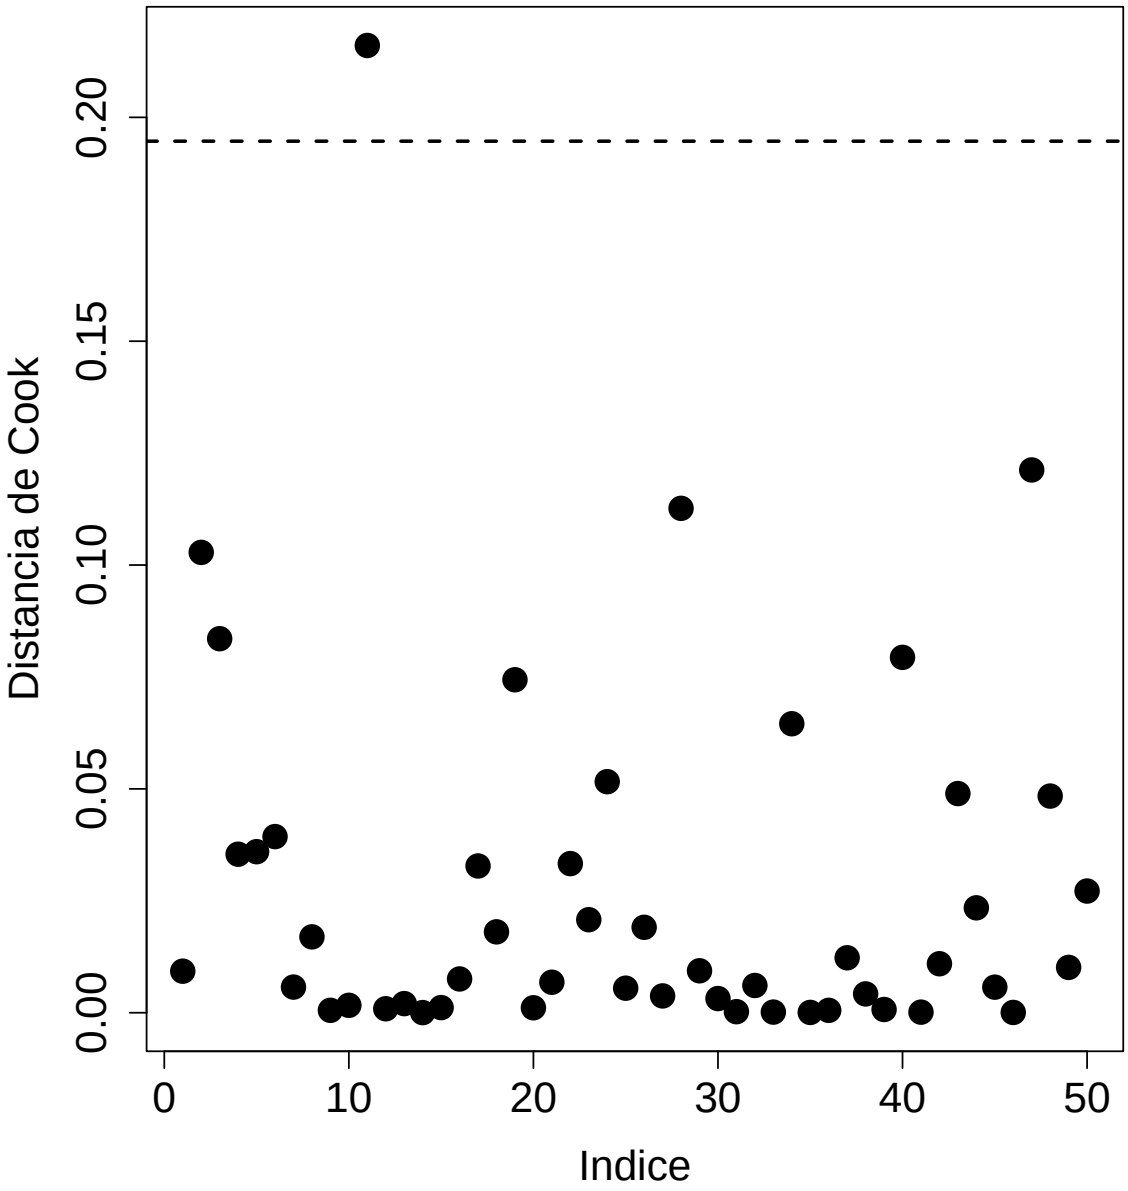
Análise de resíduos

Figura 2: Gráficos dos resíduos.



- O gráfico dos resíduos pelo valores ajustados não apresenta nenhum padrão indicativo de heterocedasticidade, a suposição de homocedasticidade é atendida;
- O gráfico dos resíduos pelo índice das observações não apresenta padrões indicativos de dependência entre os resíduos;
- Os gráficos dos resíduos comparados com os quantis da normal(qq-plot e wormplot) não apresentam grandes desvios da normalidade. A suposição de normalidade pode ser considerada adequada.

Análise de diagnóstico



Hawaii é o estado que apresenta a maior distância de Cook. Vamos reajustar o modelo sem essa observação para avaliar seu impacto nas estimavas.

```
******************************************************************
Family:  c("NO", "Normal")

Call:  gamlss(formula = expec ~ taxa + prope + ndazero, family = NO,
    trace = F)

Fitting method: RS()

------------------------------------------------------------------
Mu link function:  identity
Mu Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept) 71.061338   0.916690  77.519  < 2e-16 ***
taxa        -0.272106   0.034684  -7.845 6.74e-10 ***
prope        0.043437   0.014546   2.986   0.0046 **
ndazero     -0.004909   0.002495  -1.967   0.0555 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

------------------------------------------------------------------
Sigma link function:  log
Sigma Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  -0.3677     0.1010   -3.64 0.000713 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

------------------------------------------------------------------
No. of observations in the fit:  49
Degrees of Freedom for the fit:  5
      Residual Deg. of Freedom:  44
                      at cycle:  2

Global Deviance:     103.0208
            AIC:     113.0208
            SBC:     122.4799
******************************************************************
```

Retirando o estado Havaí observa-se uma redução na significância da variável *ndazero*, ela passa a ser significativa apenas ao nível de significância de 10%. As estimativas pontuais não mudam muito e para as demais covariáveis a inferência é a mesma.

O que fazer com a covariável ndazero??? Em um exemplo na aula o prof eliminou uma interação

que só era significativa no modelo com a observação influente. Acho que aqui depende, se o nível adotado for de 10% a inferência não muda!!!

- **Interpretação**

Como fica a homocedasticidade no caso da Poisson, a média é igual a variancia.

5 páginas por questão!!!