Lista 1 - Prática (MAE5763)

Jaqueline (17646475) e Maia ()

Sumário

Exercício 1 **2**
Análise Descritiva . . . 2
Ajuste do modelo . . . 3
Validação do modelo . . . 4
Análise de resíduos . . . 4
Análise de diagnóstico . . . 5

Exercício 2 **6**
Análise Descritiva . . . 6
Ajuste do modelo . . . 7
Análise de resíduos . . . 9

Exercício 3 **11**

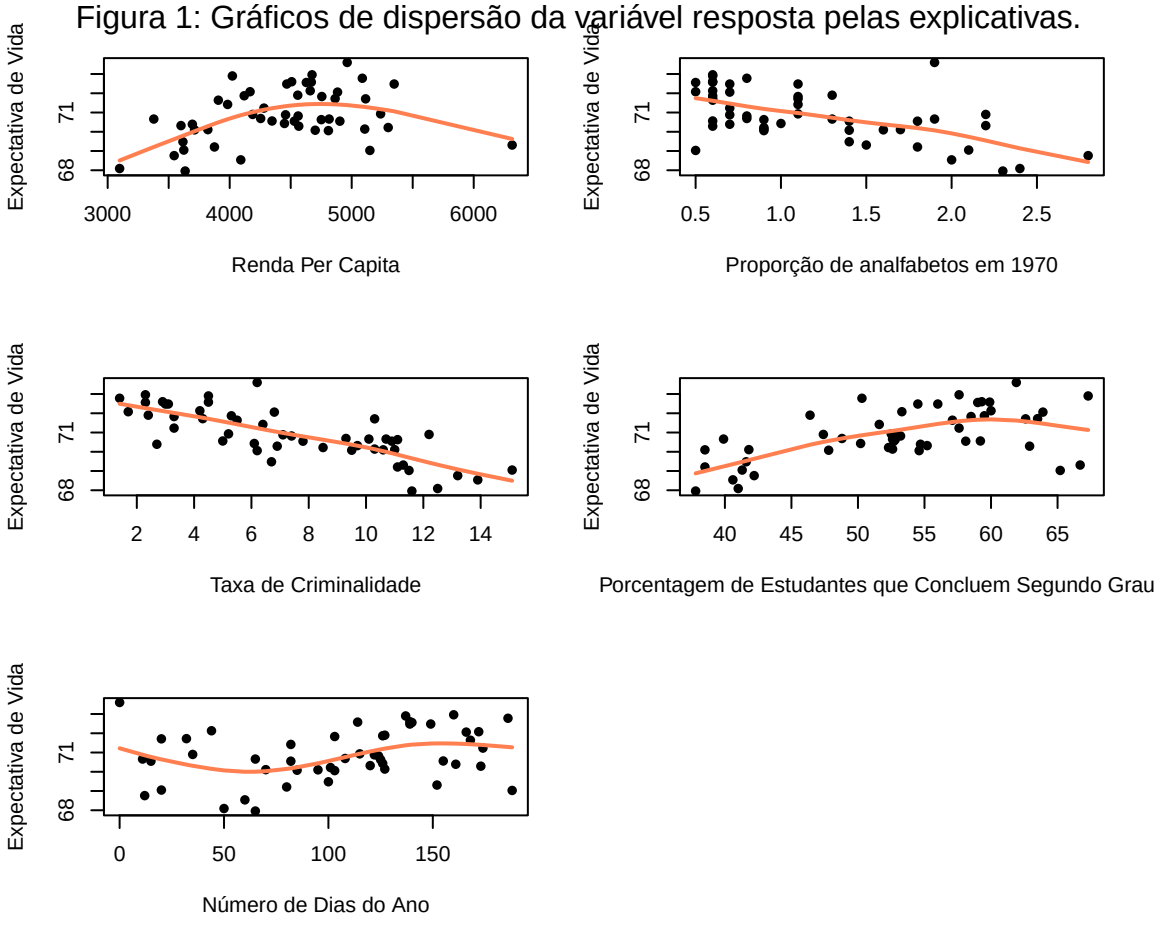
Exercício 1

O objetivo do estudo é explicar a *expec* média usando um modelo de regressão normal linear dadas as variáveis explicativas *renda*, *propa*, *taxa*, *prope* e *ndazero*.

- **UF** (nome do estado); **pop** (população estimada em julho de 1975); **renda** (renda per-capita em 1974 em USD); **propa** (proporção de analfabetos em 1970); **expec** (expectativa de vida em anos 1969-70); **taxa** (taxa de criminalidade por 100000 habitantes 1976); **prope** (porcentagem de estudantes que concluem segundo grau 1970); **ndazero** (número de dias do ano com temperatura abaixo de zero grau Celsus na cidade mais importante do estado); **area** (área do estado em milhas quadradas).

Análise Descritiva

Figura 1: Gráficos de dispersão da variável resposta pelas explicativas.



Pelos gráficos de dispersão conseguimos observar que:

- As variáveis Taxa de Criminalidade e Proporção de Analfabetos em 1970 parecem se relacionar negativamente e de forma linear com a Expectativa de Vida.
- A variável Porcentagem de Estudantes que Conluem o Ensino Médio parece estar relacionada com a resposta por meio de uma curva, com uma tendência positiva.
- As variável Renda e Número de Dias do Ano com Temperaturas abaixo de zero aparenta se relacionar com a resposta por meio de uma curva.

Ajuste do modelo

- **Ajuste inicial**:

$$
\begin{aligned}
&(1)\ Y_i \sim N(\mu_i, \sigma^2) \\
&(2)\ \mu_i = \beta_0 + \beta_1 renda + \beta_2 propa + \beta_3 taxa + \beta_4 prope + \beta_5 ndazero
\end{aligned}
$$

- Após a seleção baseada no AIC, temos o seguinte modelo ajustado:

$$
\begin{aligned}
&(1)\ Y_i \sim N(\hat{\mu_i}, \hat{\sigma}^2), \hat{\sigma}^2 = 0.5074 \\
&(2)\ \hat{\mu_i} = 71.04 - 0.2831 taxa + 0.0499 prope - 0.0069 ndazero
\end{aligned}
$$

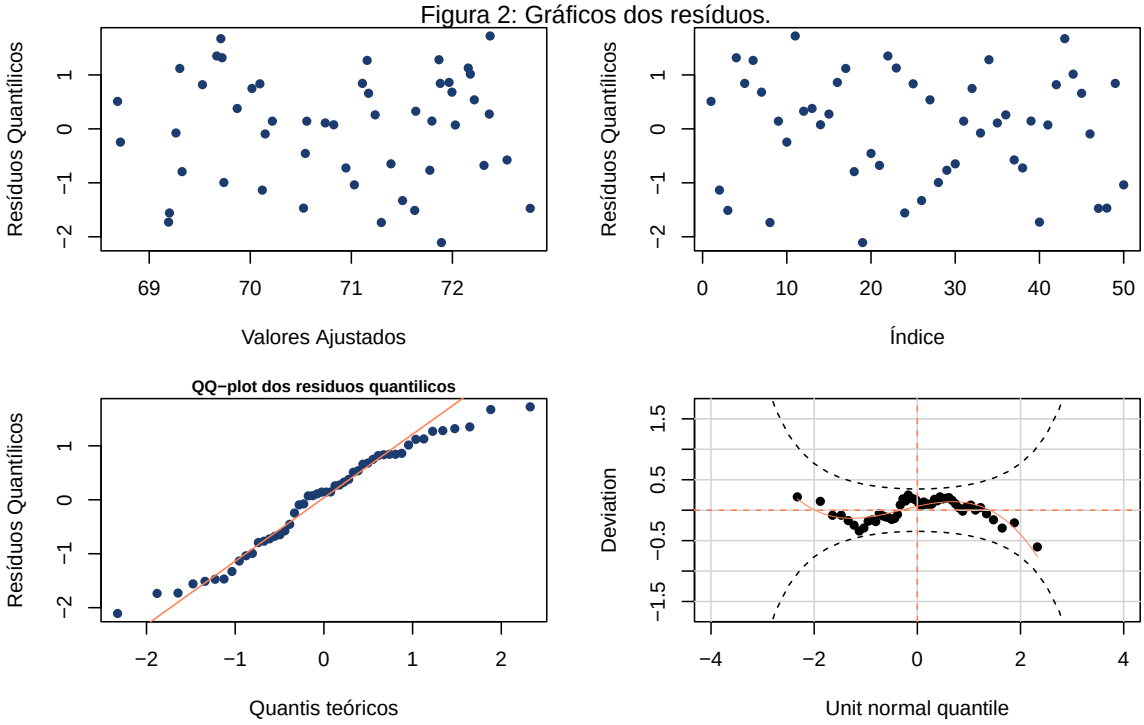
Todos os coeficientes foram significativos a um nível de signinficância de 5%.

- Considerando um estado em que a taxa de criminalidade é nula, a porcentagem de estudantes que concluem o ensino médio é igual a zero e nenhum dia ano apresenta temperaturas negativas na cidade mais inportante do estado. Espera-se que a expectativa de vida seja em média 71.04 anos.
- Considerando as outras covariáveis constantes, ao aumentar uma unidade na taxa de criminalidade espera-se uma redução de 0.2831 na média da expectativa de vida.
- Considerando as outras covariáveis constantes, ao aumentar 1% na porporção de estudantes que concluem o ensino médio espera-se observar um aumento de 0.0499 na expectativa de vida média.
- Considerando as outras covariáveis constantes, com o aumento de um dia nos número de dias do ano com temperaturas abaixo de zero na cidade mais importante do estado, espera-se uma redução de 0.0069 na média da expectativa de vida.

Validação do modelo

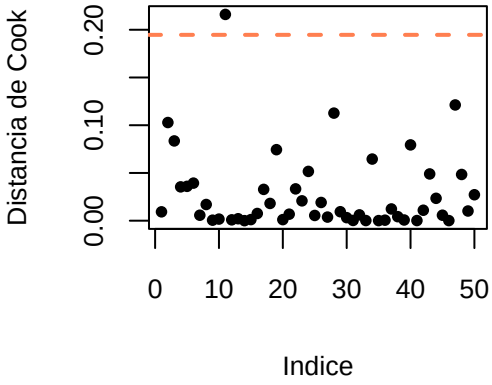
Análise de resíduos

Figura 2: Gráficos dos resíduos.



- O gráfico dos resíduos pelo valores ajustados não apresenta nenhum padrão indicativo de heterocedasticidade, a suposição de homocedasticidade é atendida;
- O gráfico dos resíduos pelo índice das observações não apresenta padrões indicativos de dependência entre os resíduos;
- Os gráficos dos resíduos comparados com os quantis da normal(qq-plot e wormplot) não apresentam grandes desvios da normalidade. A suposição de normalidade pode ser considerada adequada.

Análise de diagnóstico



Hawaii é o estado que apresenta a maior distância de Cook. Analisando as medidas resumo, verificamos que ele possui uma população abaixo da média e uma proporção de analfabetos acima do 3° quartil. Ele apresenta também o maior valor para a expectativa de vida, uma porcentagem de estudantes que concluem segundo grau acima do 3° quartil e o menor valor de número de dias com temperaturas abaixo de zero, nenhum dia. Reajustamos o modelo sem essa observação para avaliar seu impacto nas estimavas e observamos o seguinte:

- Variações nos coeficientes estimados de 0.04% (intercepto), 3.87% (taxa), 13.04% (prope) e 28.98% (ndazero);

De acordo com o professor Gilberto, variações percentuais desproporcionais (muito acima de $(1/n) \times 100\%$) são esperadas, porém deve-se dar atenção quando ocorrerem mudanças inferenciais. Nesse âmbito, observou-se uma redução na significância da variável *ndazero*, foi de um valor-p de 0.0051 para 0.0555.

Exercício 2

O objetivo principal do estudo é relacionar a cpue média com as demais variáveis explicativas.

- **Periodo** (período da pesca, seco ou chuvoso); **area** (local da pesca, área1, área2, área3, área4); **mare** (maré, quadratura ou sizigia); **vvento** (velocidade do vento, em m/s); **tmax** (temperatura máxima, em °C); **tmin** (temperatura mínima, em °C); **ins** (insolação, em horas); **cpue** (captura por unidade de esforço, em kg).

Análise Descritiva

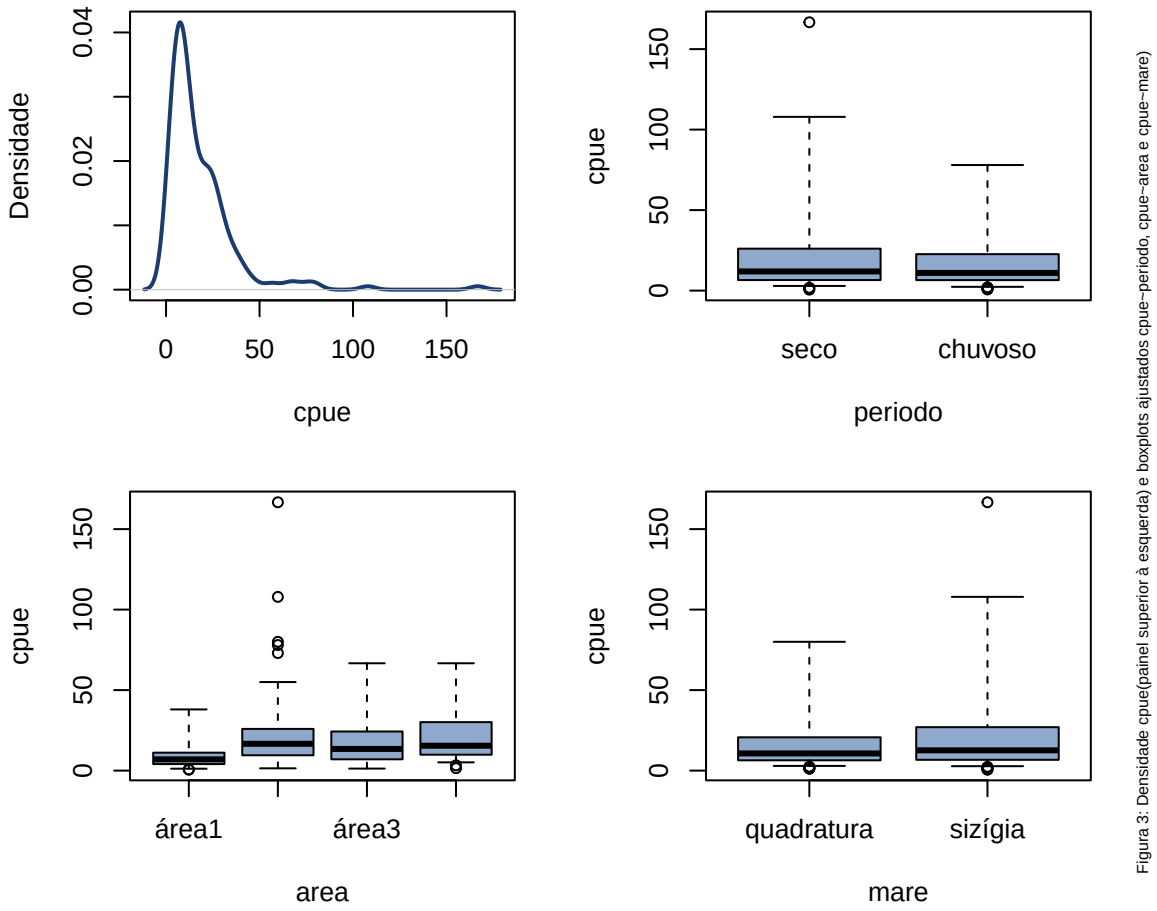


Figura 3: Densidade cpue(painel superior à esquerda) e boxplots ajustados cpue~periodo, cpue~area e cpue~mare)

Na Figura 3, observamos que a variável **cpue** apresenta uma distribuição assimétrica à direita. O período não parece impactar na captura dos peixes, observa-se uma distribuição parecida entre seco e chuvoso. As áreas 2 e 4 aparentam ter um mediana um pouco maior que as

demais. A maré de sizigia (maré viva) apresenta uma mediana levemente maior que a maré de quadratura.

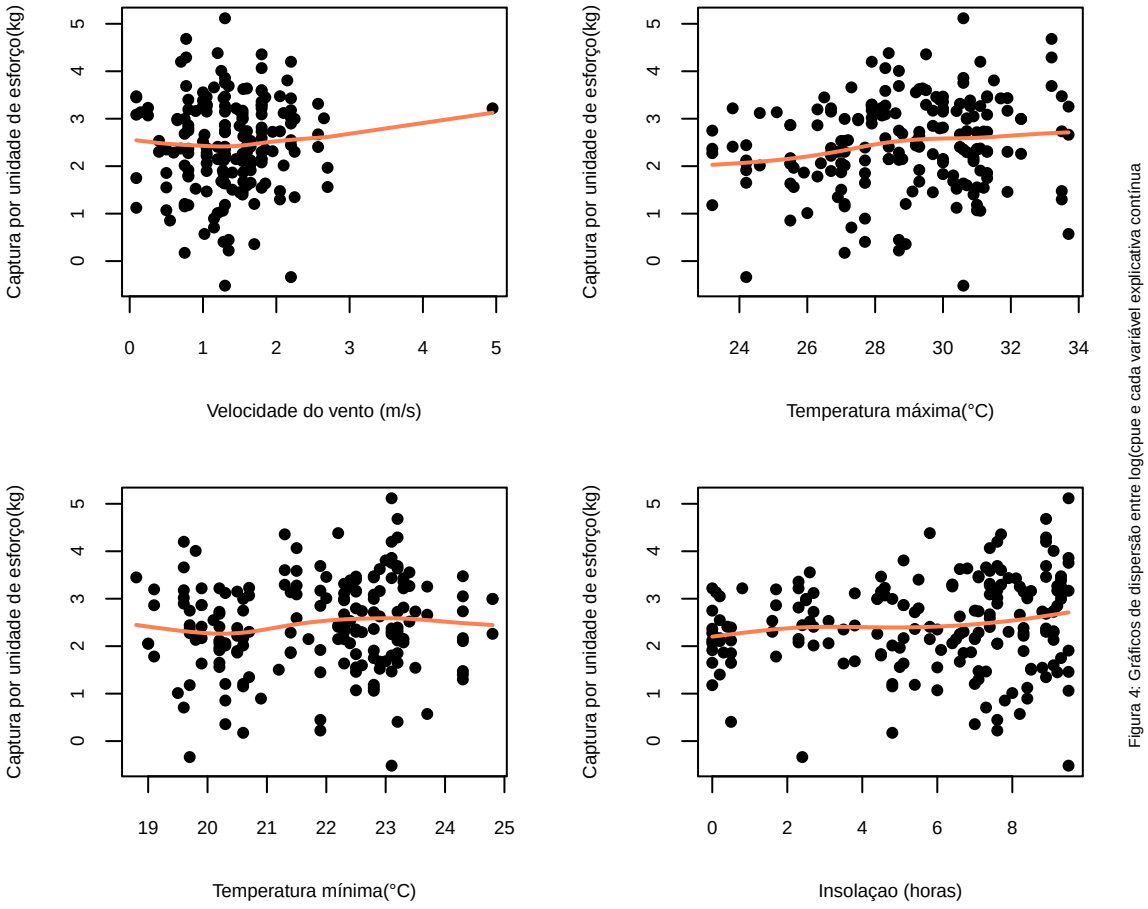


Figura 4: Gráficos de dispersão entre log(cpue e cada variável explicativa contínua

Na Figura 4 é possível verificar que nenhuma das variáveis contínuas parece impactar na captura. A velocidade do vento pode indicar um efeito positivo influenciado pelo ponto que apresentou valor fora da massa de dados.

Ajuste do modelo

- **Ajuste inicial**:

(1) $Y_i \sim Gamma(\mu_i, \sigma)$, em que σ é o coeficiente de variação de Y
(2) $\log(u_i) = \eta_i = \beta_0 + \beta_1 periodo.chuvoso + \beta_2 area_2 + \beta_3 area_3 + \beta_4 area_4 +$
$\beta_5 mare.sizgia + \beta_6 vvento + \beta_7 tmin + \beta_8 tmax + \beta_9 ins$

```
GAMLSS-RS iteration 1: Global Deviance = 1393.542
GAMLSS-RS iteration 2: Global Deviance = 1393.542
```

(1) $Y_i \sim Gamma(\mu_i, \sigma)$, em que σ é o coeficiente de variação de Y
(2) $\log(u_i) = \eta_i = 0.1319 + 0.6935 area_2 + 0.3459 area_3 + 0.6832 area_4 + 0.2635 mare.sizgia + 0.0735 tmax$

```
m2.raia <- stepGAIC(m1.raia, trace = F)
summary(m2.raia)
```

```
******************************************************************
Family:  c("GA", "Gamma")

Call:  gamlss(formula = cpue ~ area + mare + tmax, family = GA,
    trace = FALSE)

Fitting method: RS()

------------------------------------------------------------------
Mu link function:  log
Mu Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.13189    0.71748   0.184  0.85436
areaárea2    0.69353    0.14077   4.927  1.9e-06 ***
areaárea3    0.34588    0.19287   1.793  0.07461 .
areaárea4    0.68316    0.21301   3.207  0.00159 **
maresizígia  0.26348    0.11961   2.203  0.02889 *
tmax         0.07346    0.02545   2.887  0.00437 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

------------------------------------------------------------------
Sigma link function:  log
```

```
Sigma Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -0.23633    0.04743  -4.982 1.47e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

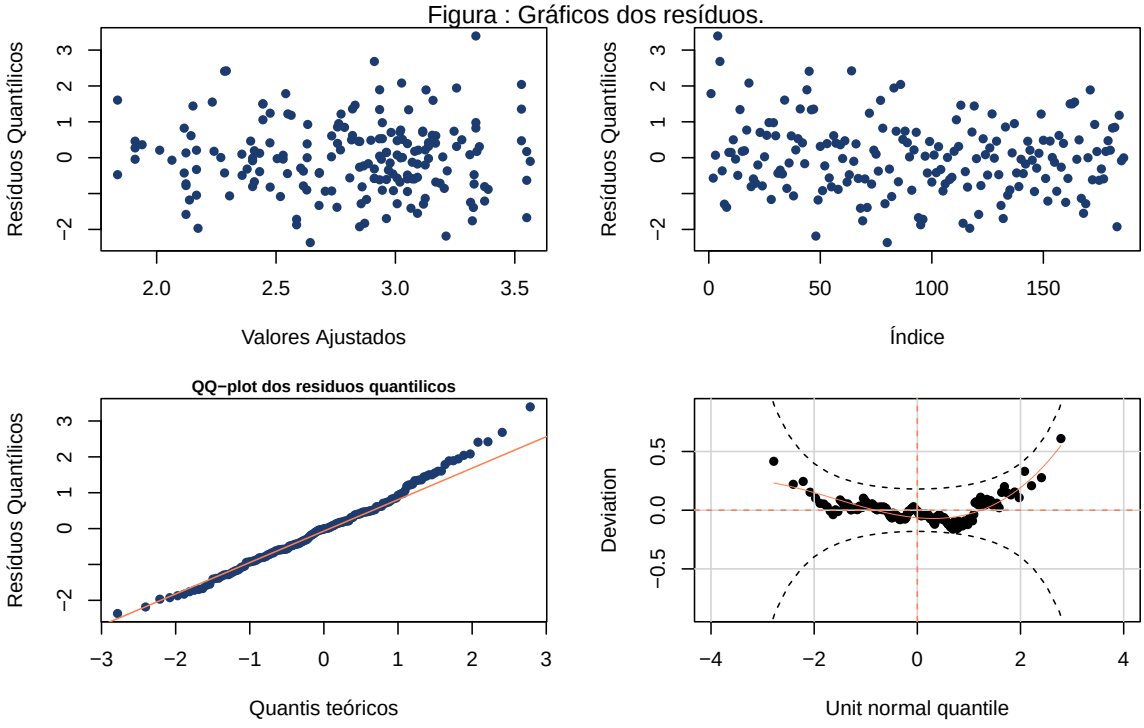
----------------------------------------------------------------------
No. of observations in the fit:  186
Degrees of Freedom for the fit:  7
      Residual Deg. of Freedom:  179
                      at cycle:  2

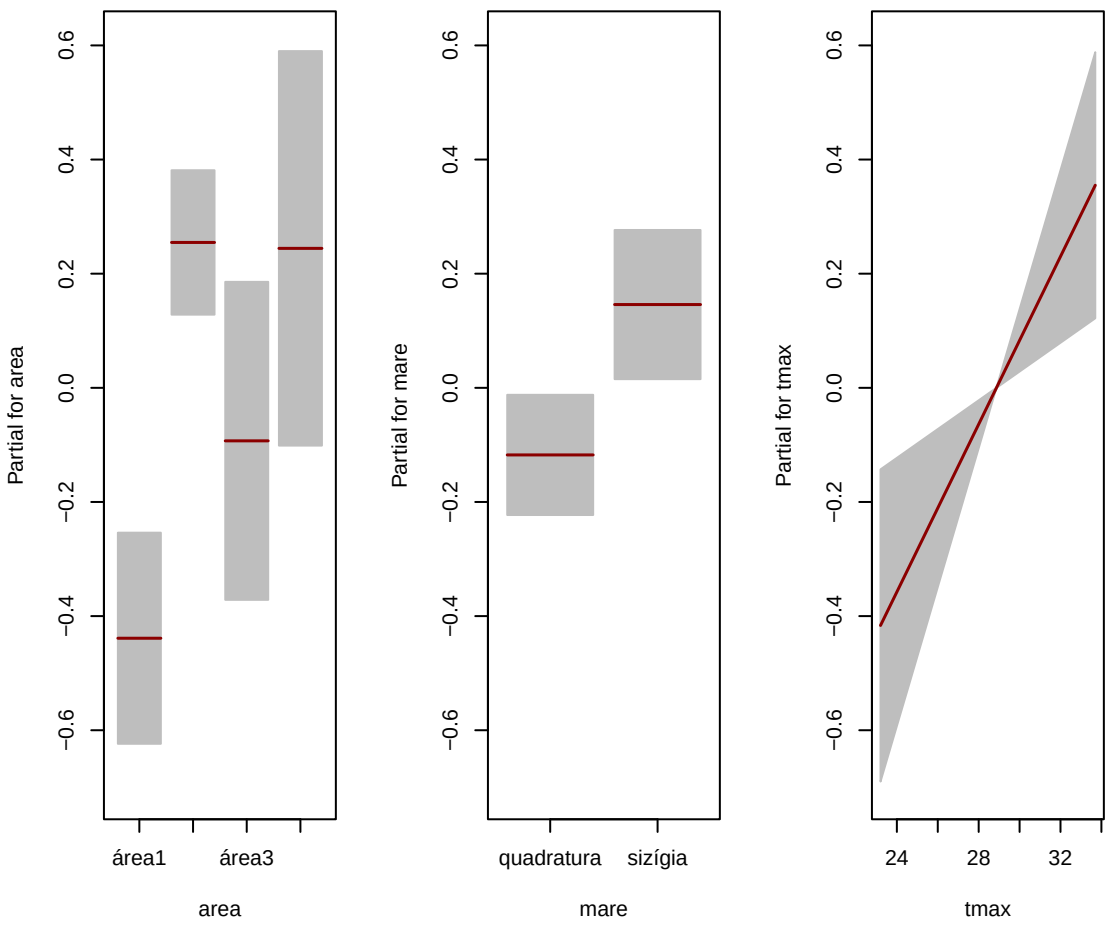
Global Deviance:     1395.071
            AIC:     1409.071
            SBC:     1431.651
**********************************************************************
```

- Interpretação: !!!!!!!!!!!!

Análise de resíduos

Figura : Gráficos dos resíduos.






```
tem.min <- seq(from = min(tmin), to = max(tmin), length.out = 200)

covariaveis <- expand.grid(
  tmin.2 = tem.min,
  area.2 = levels(area),
  mare.2 = levels(mare)
)
str(covariaveis)
```

```
'data.frame':   1600 obs. of  3 variables:
 $ tmin.2: num  18.8 18.8 18.9 18.9 18.9 ...
 $ area.2: Factor w/ 4 levels "área1","área2",..: 1 1 1 1 1 1 1 1 1 1 ...
 $ mare.2: Factor w/ 2 levels "quadratura","sizígia": 1 1 1 1 1 1 1 1 1 1 ...
 - attr(*, "out.attrs")=List of 2
  ..$ dim     : Named int [1:3] 200 4 2
```

```
.. ..- attr(*, "names")= chr [1:3] "tmin.2" "area.2" "mare.2"
..$ dimnames:List of 3
.. ..$ tmin.2: chr [1:200] "tmin.2=18.80000" "tmin.2=18.83015" "tmin.2=18.86030" "tmin.2=18
.. ..$ area.2: chr [1:4] "area.2=área1" "area.2=área2" "area.2=área3" "area.2=área4"
.. ..$ mare.2: chr [1:2] "mare.2=quadratura" "mare.2=sizígia"
```

Exercício 3

```
   diabetes        pregnant         glucose           mass
Min.   :1.000   Min.   : 0.000   Min.   : 44.00   Min.   :18.20
1st Qu.:1.000   1st Qu.: 1.000   1st Qu.: 99.75   1st Qu.:27.50
Median :1.000   Median : 3.000   Median :117.00   Median :32.30
Mean   :1.351   Mean   : 3.851   Mean   :121.94   Mean   :32.45
3rd Qu.:2.000   3rd Qu.: 6.000   3rd Qu.:141.00   3rd Qu.:36.60
Max.   :2.000   Max.   :17.000   Max.   :199.00   Max.   :67.10
   pedigree           age
Min.   :0.0780   Min.   :21.00
1st Qu.:0.2440   1st Qu.:24.00
Median :0.3770   Median :29.00
Mean   :0.4731   Mean   :33.31
3rd Qu.:0.6275   3rd Qu.:41.00
Max.   :2.4200   Max.   :81.00
```

Inicialmente fazer uma análise descritiva por meio de boxplots comparando os dois grupos de interesse com relação a diabetes, positivo e negativo, para cada variável explicativa. Como há variáveis explicativas assimétricas usar o boxplot robusto que ajusta a indicação de pontos extremos. Por exemplo, para a variável explicativa glucose use os comandos

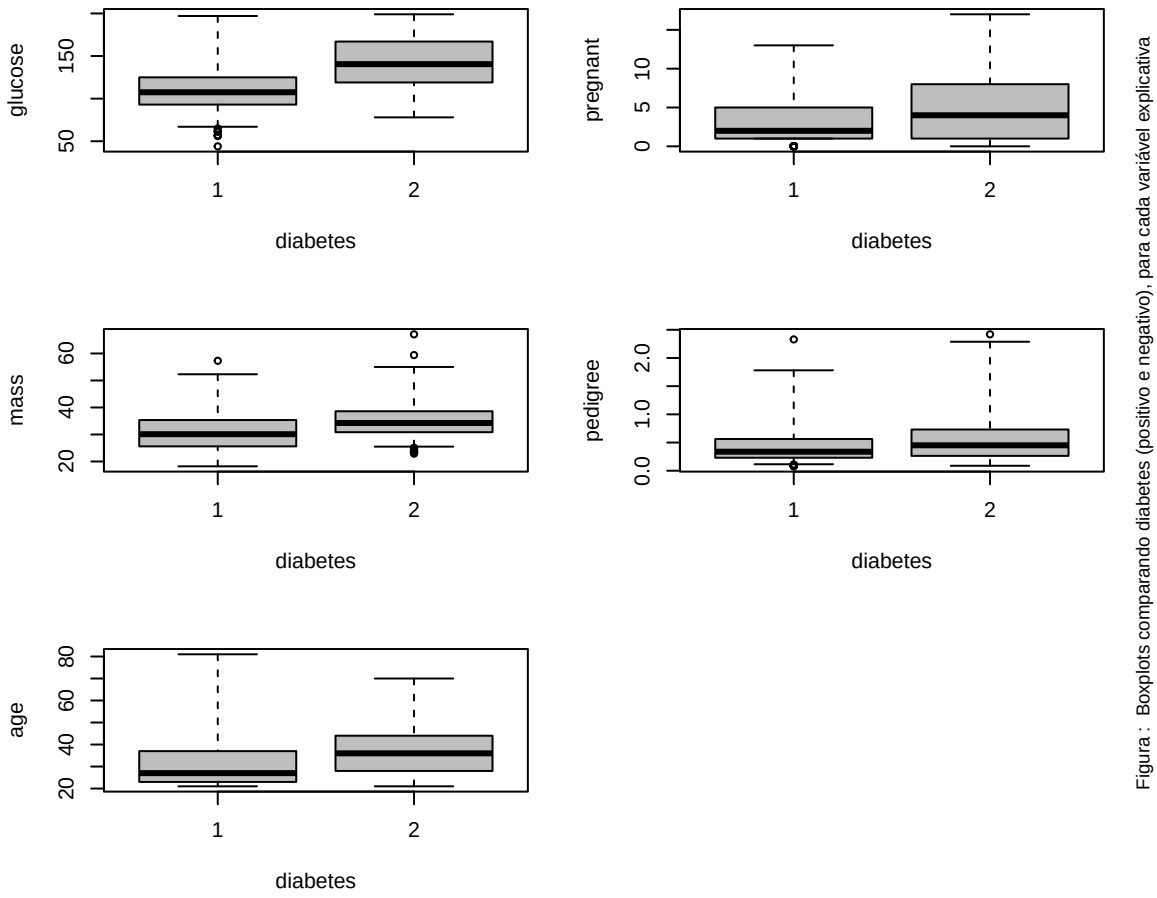


Figura : Boxplots comparando diabetes (positivo e negativo), para cada variável explicativa

Mulheres que apresentam um valor maior de mediana para as corvariáveis glucose, pregant, mass e age podem estar associadas a uma maior chance de possuir a doença.

Ajustar um modelo logístico binomial aos dados para explicar a probabilidade de diagnóstico positivo de diabetes dadas as demais variáveis explicativas. Escrever o modelo. Usar o comando stepGAIC do GAMLSS para fazer uma seleção de variáveis explicativas.

- Ajuste inicial:

(1) $Y_i \sim Binomial(n, \mu_i)$

(2) $log\left(\frac{\mu_i}{1-\mu_i}\right) = \beta_0 + \beta_1 pregnant + \beta_2 glucose + \beta_3 mass + \beta_4 pedigree + \beta_5 age$

```
m1.pima <- gamlss(diabetes ~ pregnant + glucose + mass + pedigree+age, family = BI, trace=F)
```

- Ajuste Final:

(1) $Y_i \sim Binomial(n, \mu_i)$

(2) $log\left(\frac{\mu_i}{1-\mu_i}\right) = -9.082422 + 0.135906 pregnant + 0.036807 glucose + 0.086165 mass + 0.929365 pedigree$

```
Distribution parameter:  mu
Start:  AIC= 715.24
 diabetes ~ pregnant + glucose + mass + pedigree + age

           Df    AIC
- age       1 714.72
<none>        715.24
- pedigree  1 722.90
- pregnant  1 726.30
- mass      1 752.05
- glucose   1 843.20

Step:  AIC= 714.72
 diabetes ~ pregnant + glucose + mass + pedigree

           Df    AIC
<none>        714.72
- pedigree  1 722.58
- pregnant  1 737.76
- mass      1 750.51
- glucose   1 855.93

******************************************************************
Family:  c("BI", "Binomial")

Call:  gamlss(formula = diabetes ~ pregnant + glucose + mass +
    pedigree, family = BI, trace = FALSE)

Fitting method: RS()

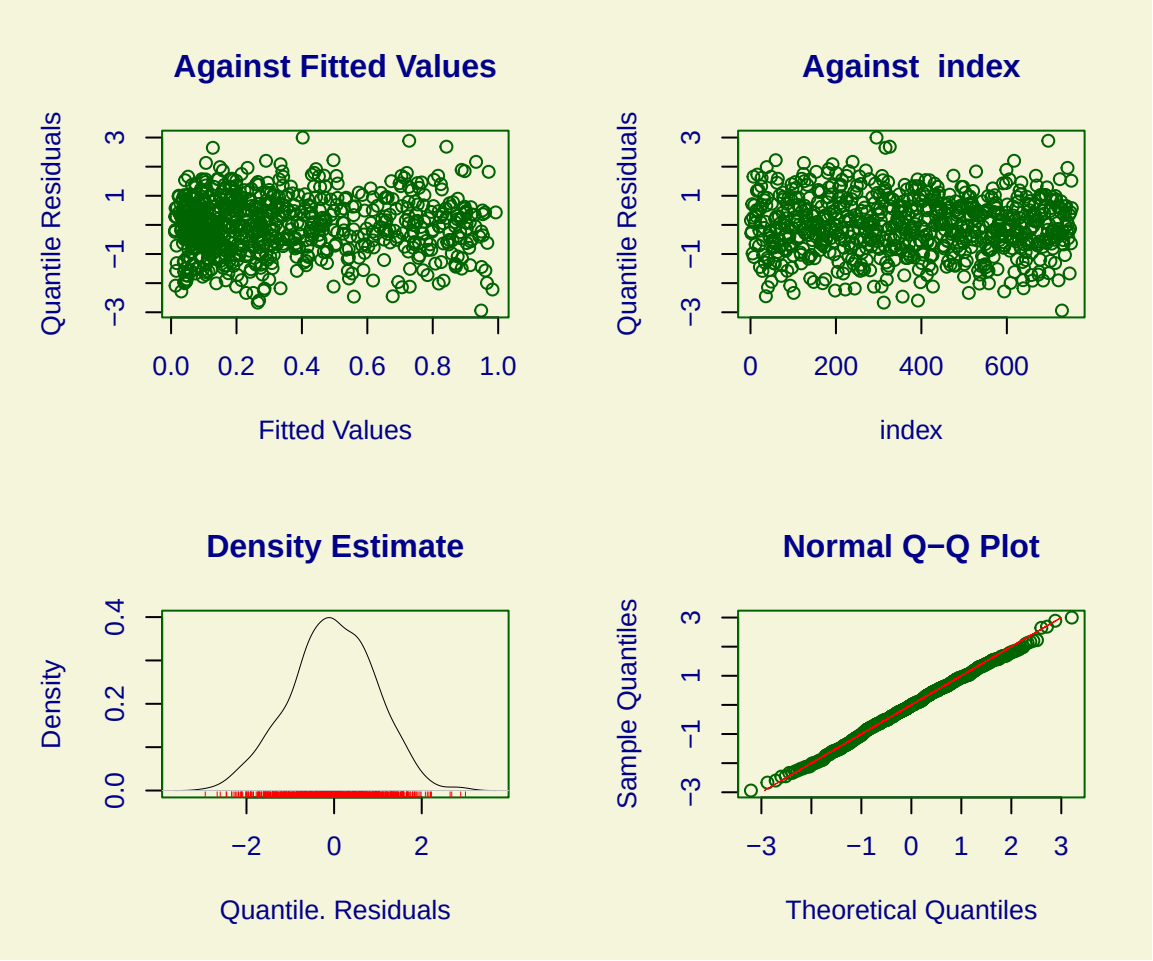
------------------------------------------------------------------
Mu link function:  logit
```

```
Mu Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept) -9.082422   0.704940 -12.884  < 2e-16 ***
pregnant     0.135906   0.027655   4.914 1.10e-06 ***
glucose      0.036807   0.003499  10.519  < 2e-16 ***
mass         0.086165   0.014688   5.866 6.69e-09 ***
pedigree     0.929365   0.300349   3.094  0.00205 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

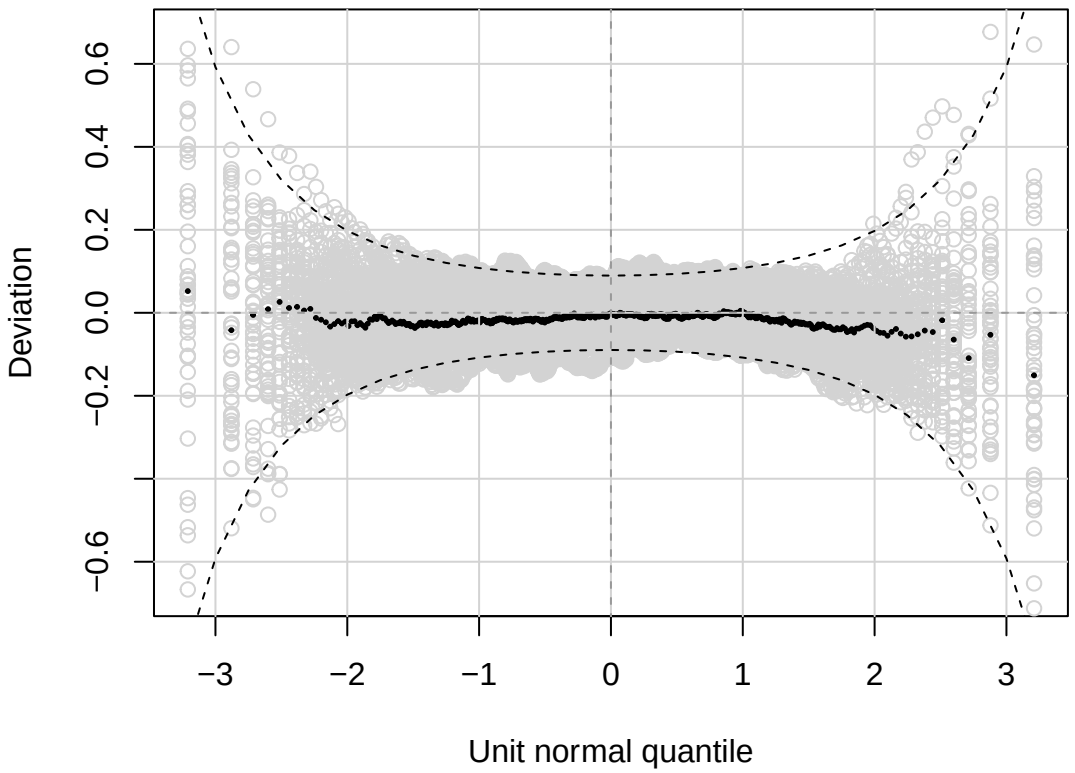
----------------------------------------------------------------
No. of observations in the fit:  752
Degrees of Freedom for the fit:  5
      Residual Deg. of Freedom:  747
                      at cycle:  2

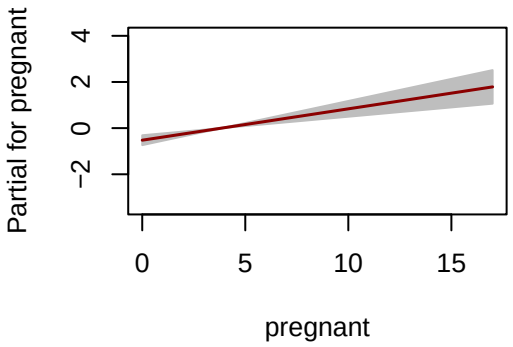
Global Deviance:     704.7176
            AIC:     714.7176
            SBC:     737.8313
****************************************************************
```

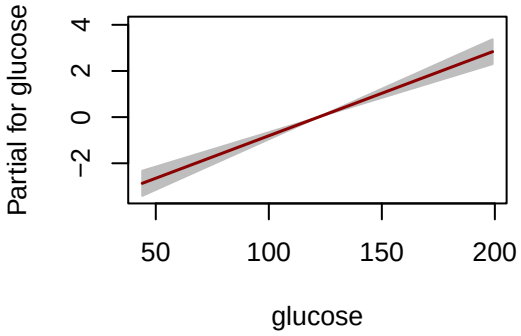
- Interpretação:

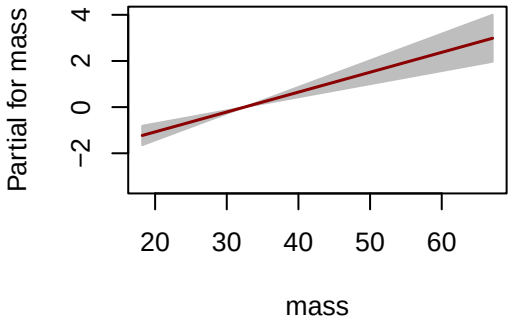


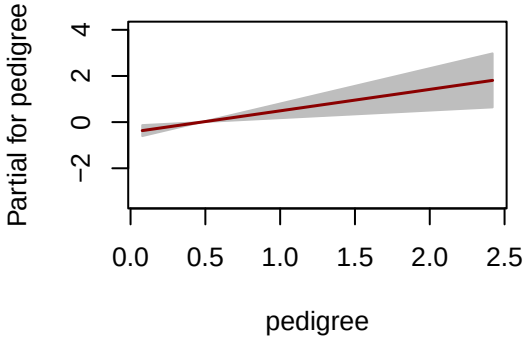

```
*****************************************************************
     Summary of the Randomised Quantile Residuals
                           mean   =  -0.03414483
                       variance   =  0.9449747
                  coef. of skewness  =  -0.08540874
                  coef. of kurtosis  =  2.880352
Filliben correlation coefficient  =  0.9990678
*****************************************************************
```


Deviation
0.6
0.4
0.2
0.0
−0.2
−0.6
−3
−2
−1
0
1
2
3
Unit normal quantile









- **Interpretação**
-

Como fica a homocedasticidade no caso da Poisson, a média é igual a variancia.

5 páginas por questão!!!