

Lista 1 - Prática (MAE5763)

Jaqueline (17646475) e Maia ()

Sumário

Exercício 1 **2**
Análise Descritiva . . . 2
Ajuste do modelo . . . 3
Validação do modelo . . . 4
Análise de resíduos . . . 4
Análise de diagnóstico . . . 5

Exercício 2 **7**
Análise Descritiva . . . 7
Ajuste do modelo . . . 8
Análise de resíduos . . . 10

Exercício 3 **12**
Análise de resíduos . . . 16

Exercício 4 **24**

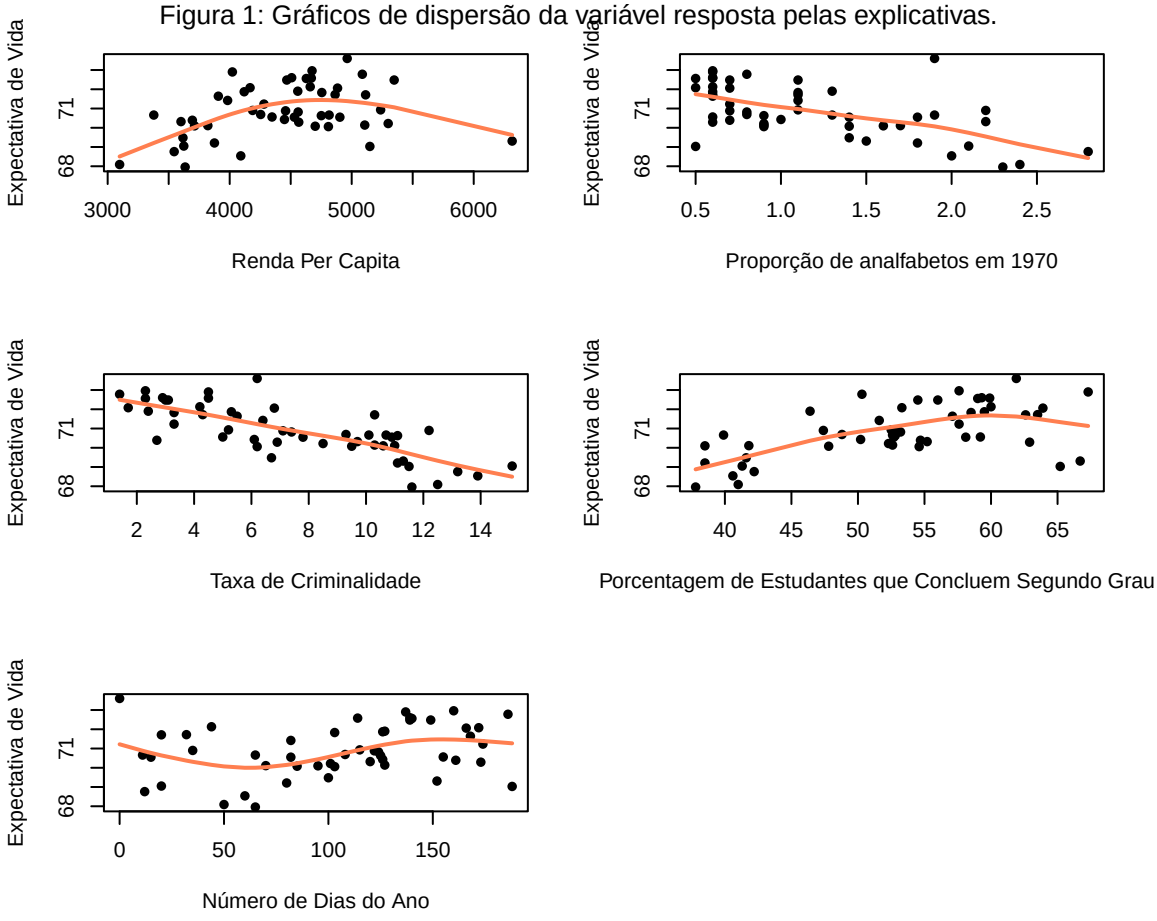
Exercício 1

O objetivo do estudo é explicar a *expec* média usando um modelo de regressão normal linear dadas as variáveis explicativas *renda*, *propa*, *taxa*, *prope* e *ndazero*.

- **UF** (nome do estado); **pop** (população estimada em julho de 1975); **renda** (renda per-capita em 1974 em USD); **propa** (proporção de analfabetos em 1970); **expec** (expectativa de vida em anos 1969-70); **taxa** (taxa de criminalidade por 100000 habitantes 1976); **prope** (porcentagem de estudantes que concluem segundo grau 1970); **ndazero** (número de dias do ano com temperatura abaixo de zero grau Celsus na cidade mais importante do estado); **area** (área do estado em milhas quadradas).

Análise Descritiva

Figura 1: Gráficos de dispersão da variável resposta pelas explicativas.



Pelos diagramas de dispersão, Figura 1, conseguimos observar que:

- As variáveis Taxa de Criminalidade e Proporção de Analfabetos em 1970 parecem se relacionar negativamente e de forma linear com a Expectativa de Vida.
- A variável Porcentagem de Estudantes que Conluem o Ensino Médio parece estar relacionada com a resposta por meio de uma curva, com uma tendência positiva.
- As variável Renda e Número de Dias do Ano com Temperaturas abaixo de zero aparenta se relacionar com a resposta por meio de uma curva.

Ajuste do modelo

- **Ajuste inicial**:

$$
\begin{aligned}
&(1)\ Y_i \sim N(\mu_i, \sigma^2) \\
&(2)\ \mu_i = \beta_0 + \beta_1 renda + \beta_2 propa + \beta_3 taxa + \beta_4 prope + \beta_5 ndazero
\end{aligned}
$$

- Após a seleção baseada no AIC por meio da função *stepGAIC*, temos o seguinte modelo ajustado:

$$
\begin{aligned}
&(1)\ Y_i \sim N(\hat{\mu}_i, \hat{\sigma^2}), \hat{\sigma^2} = 0.5074 \\
&(2)\ \hat{\mu}_i = 71.04 - 0.2831 taxa + 0.0499 prope - 0.0069 ndazero
\end{aligned}
$$

OBS.: A saída do gamlss nos apresenta o $\log(\hat{\sigma})$.

Todos os coeficientes foram significativos a um nível de signinficância de 5%. Seguem as interpretações:

- Espera-se que a expectativa de vida seja em média 71.04 anos para um estado em que a taxa de criminalidade é nula, a porcentagem de estudantes que concluem o ensino médio é igual a zero e nenhum dia do ano apresenta temperaturas negativas.
- Considerando as outras covariáveis constantes, ao aumentar uma unidade na taxa de criminalidade espera-se uma redução de 0.2831 na média da expectativa de vida.
- Considerando as outras covariáveis constantes, ao aumentar 1% na porporção de estudantes que concluem o ensino médio espera-se observar um aumento de 0.0499 na expectativa de vida média.
- Considerando as outras covariáveis constantes, espera-se uma redução de 0.0069 na média da expectativa de vida com o aumento de um dia nos número de dias do ano com temperaturas abaixo de zero na cidade mais importante do estado.

Validação do modelo

Análise de resíduos

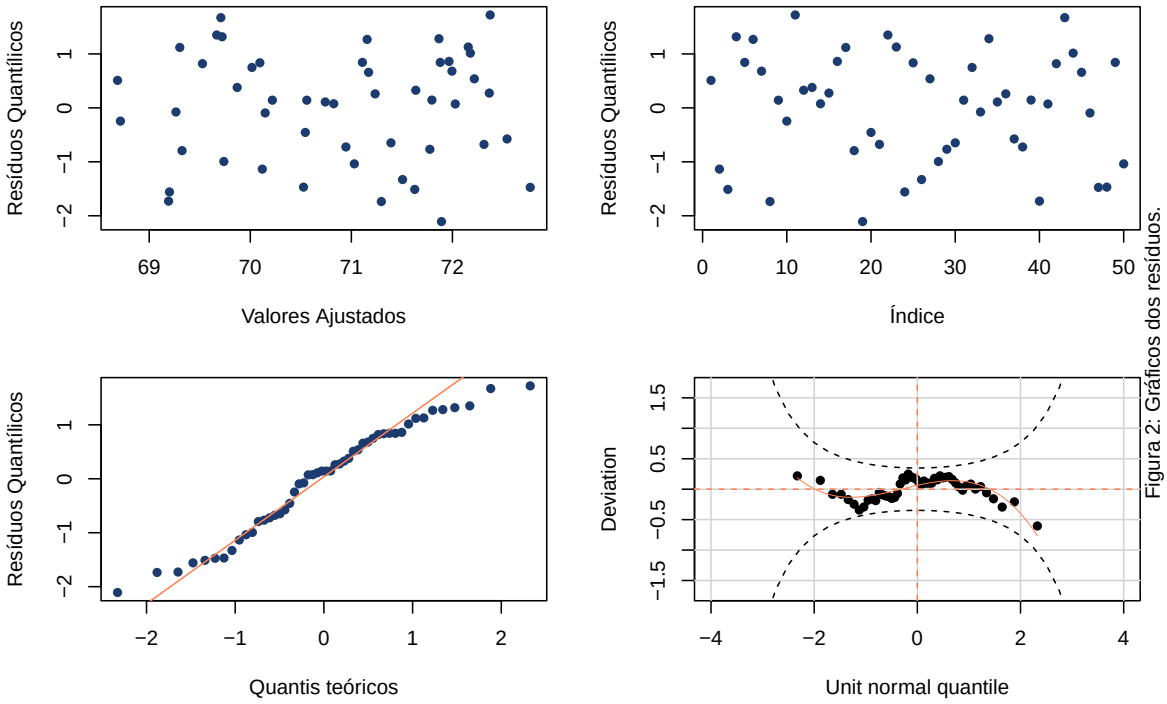


Figura 2: Gráficos dos resíduos.

Na Figura 2 observamos que:

- O gráfico dos resíduos pelo valores ajustados não apresenta nenhum padrão indicativo de heterocedasticidade, a suposição de homocedasticidade é atendida. (Painel superior à esquerda)
- O gráfico dos resíduos pelo índice das observações não apresenta padrões indicativos de dependência entre eles. (Painel superior à direita)
- Os gráficos dos resíduos quantílicos comparados com os quantis da normal (qq-plot e wormplot) não apresentam grandes desvios da normalidade. A suposição de normalidade pode ser considerada adequada. (Painéis inferiores da figura)

Análise de diagnóstico

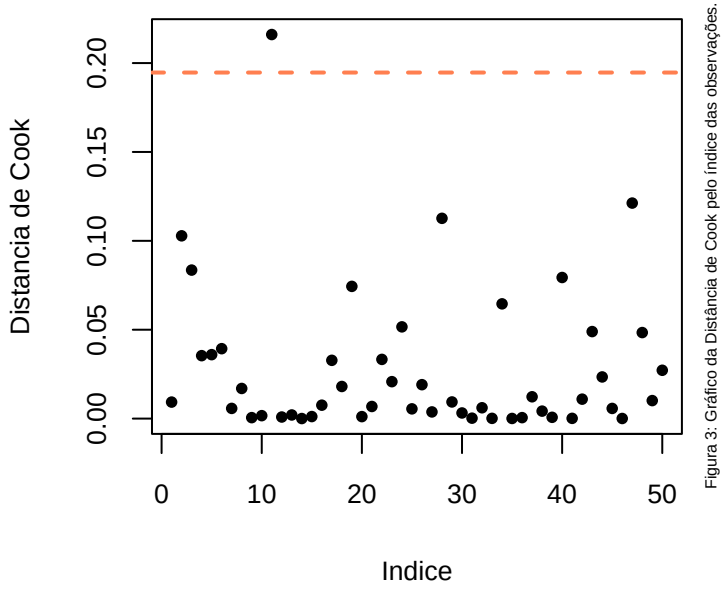


Figura 3: Gráfico da Distância de Cook pelo índice das observações.

Na Figura 3, identificamos que *Hawaii* é o estado que apresenta a maior distância de Cook. Comparamos os valores das covariáveis do estado com as medidas resumo e observamos que ele apresenta o maior valor para a expectativa de vida e o menor valor para o número de dias com temperaturas abaixo de zero.

```
******************************************************************
Family:  c("NO", "Normal")

Call:  gamlss(formula = expec ~ taxa + prope + ndazero, family = NO,
    trace = F)

Fitting method: RS()

------------------------------------------------------------------
Mu link function:  identity
Mu Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept) 71.061338   0.916690  77.519  < 2e-16 ***
```

```
taxa        -0.272106   0.034684  -7.845 6.74e-10 ***
prope        0.043437   0.014546   2.986   0.0046 **
ndazero     -0.004909   0.002495  -1.967   0.0555 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

-------------------------------------------------------------------
Sigma link function:  log
Sigma Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  -0.3677     0.1010   -3.64 0.000713 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

-------------------------------------------------------------------
No. of observations in the fit:  49
Degrees of Freedom for the fit:  5
      Residual Deg. of Freedom:  44
                      at cycle:  2

Global Deviance:     103.0208
            AIC:     113.0208
            SBC:     122.4799
*******************************************************************
```

Reajustamos o modelo sem essa observação para avaliar seu impacto nas estimativas e observamos as seguintes variações nos coeficientes estimados: 0.04% (intercepto), 3.87% (taxa), 13.04% (prope) e 28.98% (ndazero). De acordo com o professor Gilberto, variações percentuais desproporcionais (muito acima de $(1/n) \times 100\%$) são esperadas, porém deve-se dar atenção quando ocorrerem mudanças inferenciais. Nesse âmbito, observou-se uma redução na significância da variável *ndazero*, foi de um valor-p de 0.0051 para 0.0555. Portanto, o efeito da covariável *ndazero* deve ser interpretado com cuidado caso o pesquisador defenda a permanência dessa covariável no modelo.

Exercício 2

O objetivo principal do estudo é relacionar a cpue média com as demais variáveis explicativas.

- **Periodo** (período da pesca, seco ou chuvoso); **area** (local da pesca, área1, área2, área3, área4); **mare** (maré, quadratura ou sizigia); **vvento** (velocidade do vento, em m/s); **tmax** (temperatura máxima, em °C); **tmin** (temperatura mínima, em °C); **ins** (insolação, em horas); **cpue** (captura por unidade de esforço, em kg).

Análise Descritiva

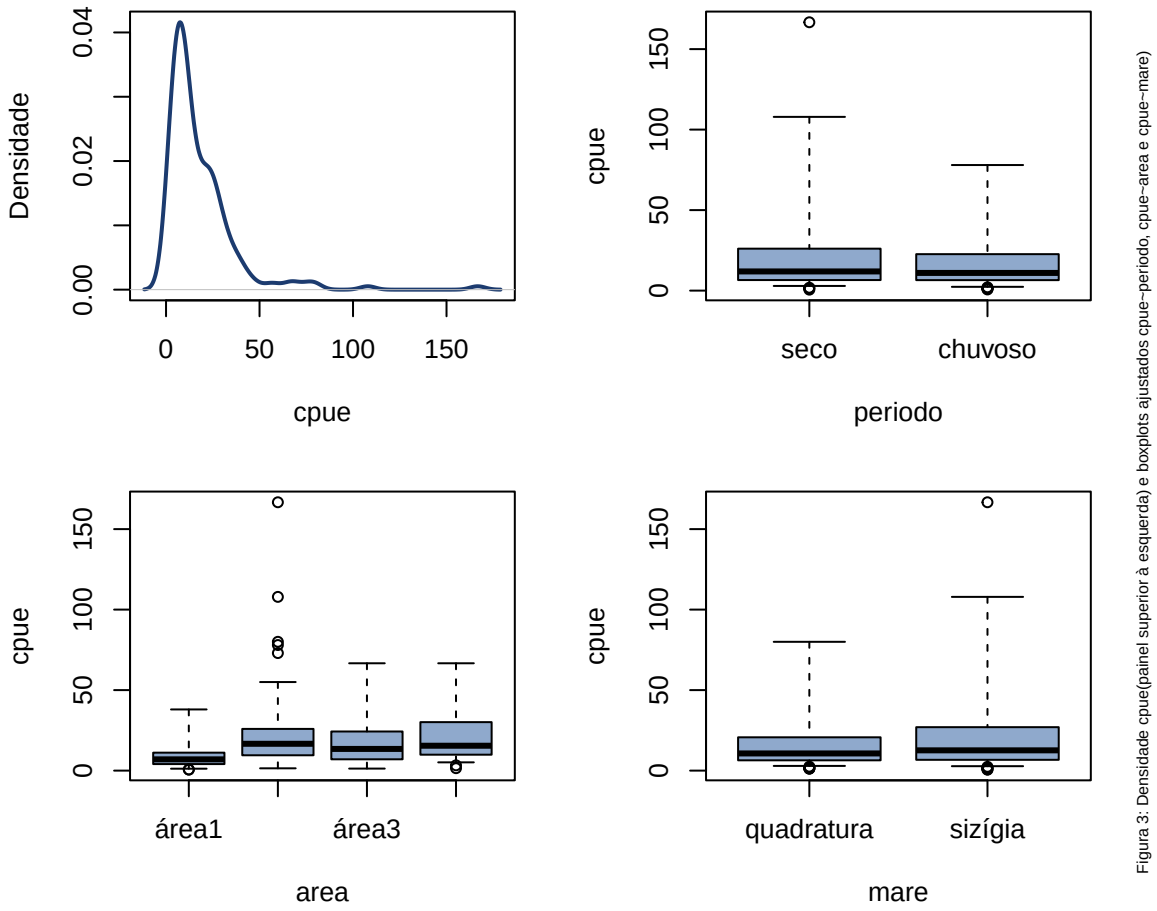


Figura 3: Densidade cpue(painel superior à esquerda) e boxplots ajustados cpue~periodo, cpue~area e cpue~mare)

Na Figura 3, observamos que a variável **cpue** apresenta uma distribuição assimétrica à direita. O período não parece impactar na captura dos peixes, observa-se uma distribuição parecida entre seco e chuvoso. As áreas 2 e 4 aparentam ter um mediana um pouco maior que as

demais. A maré de sizigia (maré viva) apresenta uma mediana levemente maior que a maré de quadratura.

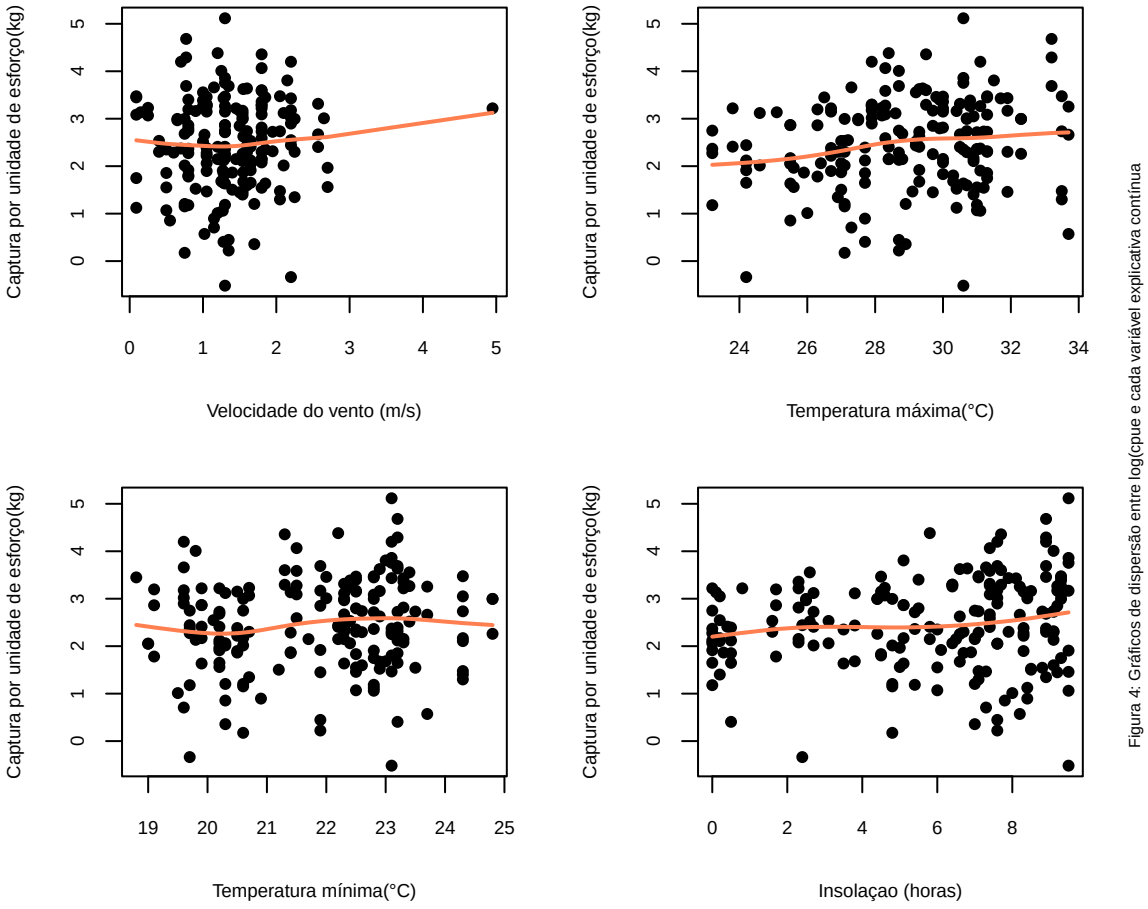


Figura 4: Gráficos de dispersão entre log(cpue e cada variável explicativa contínua

Na Figura 4 é possível verificar que nenhuma das variáveis contínuas parece impactar na captura. A velocidade do vento pode indicar um efeito positivo influenciado pelo ponto que apresentou valor fora da massa de dados.

Ajuste do modelo

- **Ajuste inicial**:

(1) $Y_i \sim Gamma(\mu_i, \sigma)$, em que σ é o coeficiente de variação de Y
(2) $\log(u_i) = \eta_i = \beta_0 + \beta_1 periodo.chuvoso + \beta_2 area_2 + \beta_3 area_3 + \beta_4 area_4 +$
$\beta_5 mare.sizgia + \beta_6 vvento + \beta_7 tmin + \beta_8 tmax + \beta_9 ins$

```
GAMLSS-RS iteration 1: Global Deviance = 1393.542
GAMLSS-RS iteration 2: Global Deviance = 1393.542
```

(1) $Y_i \sim Gamma(\mu_i, \sigma)$, em que σ é o coeficiente de variação de Y
(2) $\log(u_i) = \eta_i = 0.1319 + 0.6935 area_2 + 0.3459 area_3 + 0.6832 area_4 + 0.2635 mare.sizgia + 0.0735 tmax$

```
m2.raia <- stepGAIC(m1.raia, trace = F)
summary(m2.raia)
```

```
******************************************************************
Family:  c("GA", "Gamma")

Call:  gamlss(formula = cpue ~ area + mare + tmax, family = GA,
    trace = FALSE)

Fitting method: RS()

------------------------------------------------------------------
Mu link function:  log
Mu Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.13189    0.71748   0.184  0.85436
areaárea2    0.69353    0.14077   4.927  1.9e-06 ***
areaárea3    0.34588    0.19287   1.793  0.07461 .
areaárea4    0.68316    0.21301   3.207  0.00159 **
maresizígia  0.26348    0.11961   2.203  0.02889 *
tmax         0.07346    0.02545   2.887  0.00437 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

------------------------------------------------------------------
Sigma link function:  log
```

```
Sigma Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -0.23633    0.04743  -4.982 1.47e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

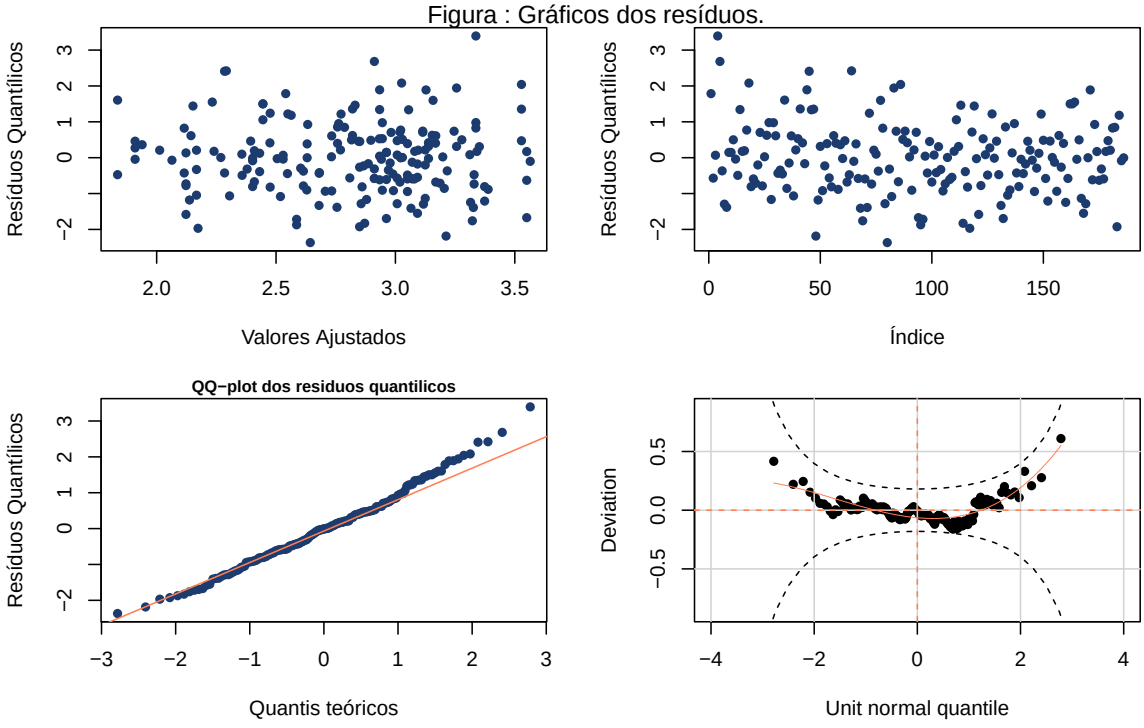
----------------------------------------------------------------------
No. of observations in the fit:  186
Degrees of Freedom for the fit:  7
      Residual Deg. of Freedom:  179
                      at cycle:  2

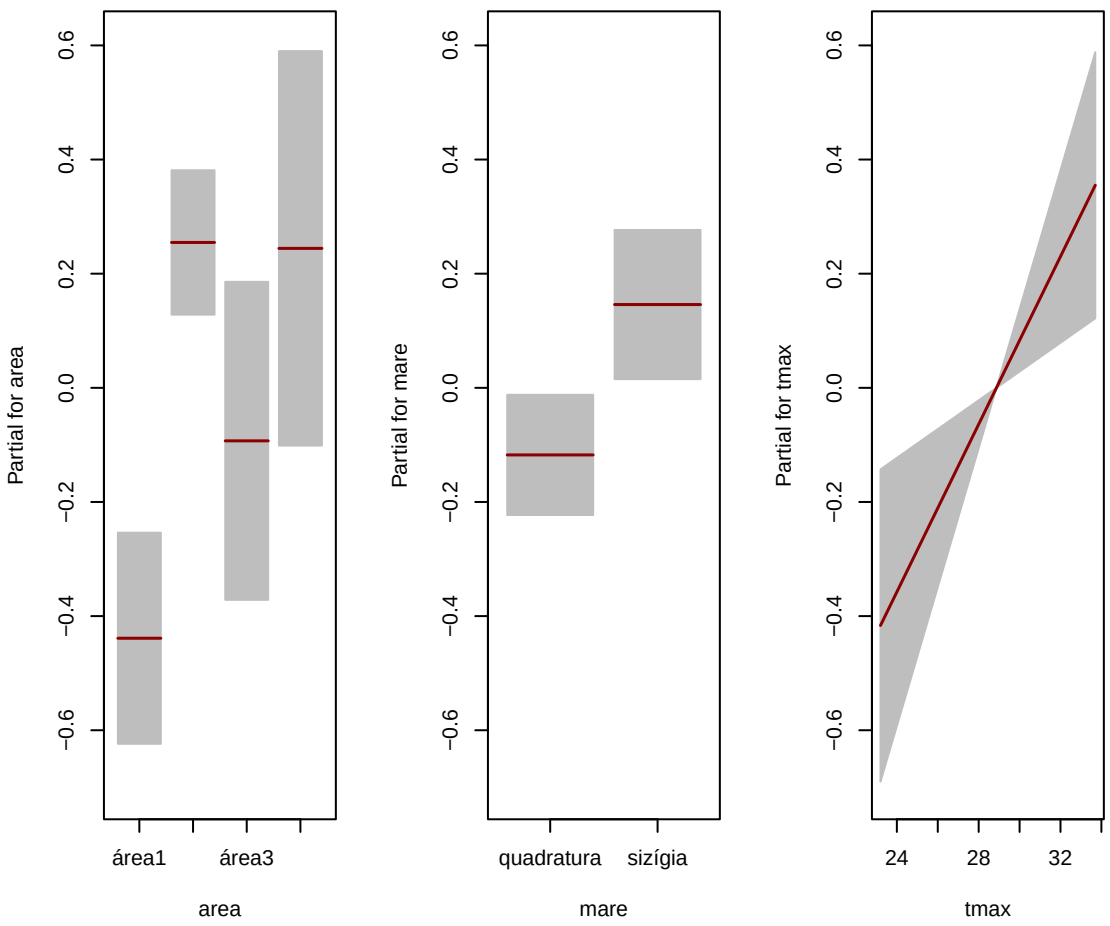
Global Deviance:     1395.071
            AIC:     1409.071
            SBC:     1431.651
**********************************************************************
```

- Interpretação: !!!!!!!!!!!!

Análise de resíduos

Figura : Gráficos dos resíduos.






```r
tem.min <- seq(from = min(tmin), to = max(tmin), length.out = 200)

covariaveis <- expand.grid(
  tmin.2 = tem.min,
  area.2 = levels(area),
  mare.2 = levels(mare)
)
str(covariaveis)
```

```
'data.frame':   1600 obs. of  3 variables:
 $ tmin.2: num  18.8 18.8 18.9 18.9 18.9 ...
 $ area.2: Factor w/ 4 levels "área1","área2",..: 1 1 1 1 1 1 1 1 1 1 ...
 $ mare.2: Factor w/ 2 levels "quadratura","sizígia": 1 1 1 1 1 1 1 1 1 1 ...
 - attr(*, "out.attrs")=List of 2
  ..$ dim     : Named int [1:3] 200 4 2
```

```
.. ..- attr(*, "names")= chr [1:3] "tmin.2" "area.2" "mare.2"
..$ dimnames:List of 3
.. ..$ tmin.2: chr [1:200] "tmin.2=18.80000" "tmin.2=18.83015" "tmin.2=18.86030" "tmin.2=18
.. ..$ area.2: chr [1:4] "area.2=área1" "area.2=área2" "area.2=área3" "area.2=área4"
.. ..$ mare.2: chr [1:2] "mare.2=quadratura" "mare.2=sizígia"
```

Exercício 3

```
   diabetes        pregnant         glucose           mass
Min.   :1.000   Min.   : 0.000   Min.   : 44.00   Min.   :18.20
1st Qu.:1.000   1st Qu.: 1.000   1st Qu.: 99.75   1st Qu.:27.50
Median :1.000   Median : 3.000   Median :117.00   Median :32.30
Mean   :1.351   Mean   : 3.851   Mean   :121.94   Mean   :32.45
3rd Qu.:2.000   3rd Qu.: 6.000   3rd Qu.:141.00   3rd Qu.:36.60
Max.   :2.000   Max.   :17.000   Max.   :199.00   Max.   :67.10
   pedigree           age
Min.   :0.0780   Min.   :21.00
1st Qu.:0.2440   1st Qu.:24.00
Median :0.3770   Median :29.00
Mean   :0.4731   Mean   :33.31
3rd Qu.:0.6275   3rd Qu.:41.00
Max.   :2.4200   Max.   :81.00
```

Inicialmente fazer uma análise descritiva por meio de boxplots comparando os dois grupos de interesse com relação a diabetes, positivo e negativo, para cada variável explicativa. Como há variáveis explicativas assimétricas usar o boxplot robusto que ajusta a indicação de pontos extremos. Por exemplo, para a variável explicativa glucose use os comandos

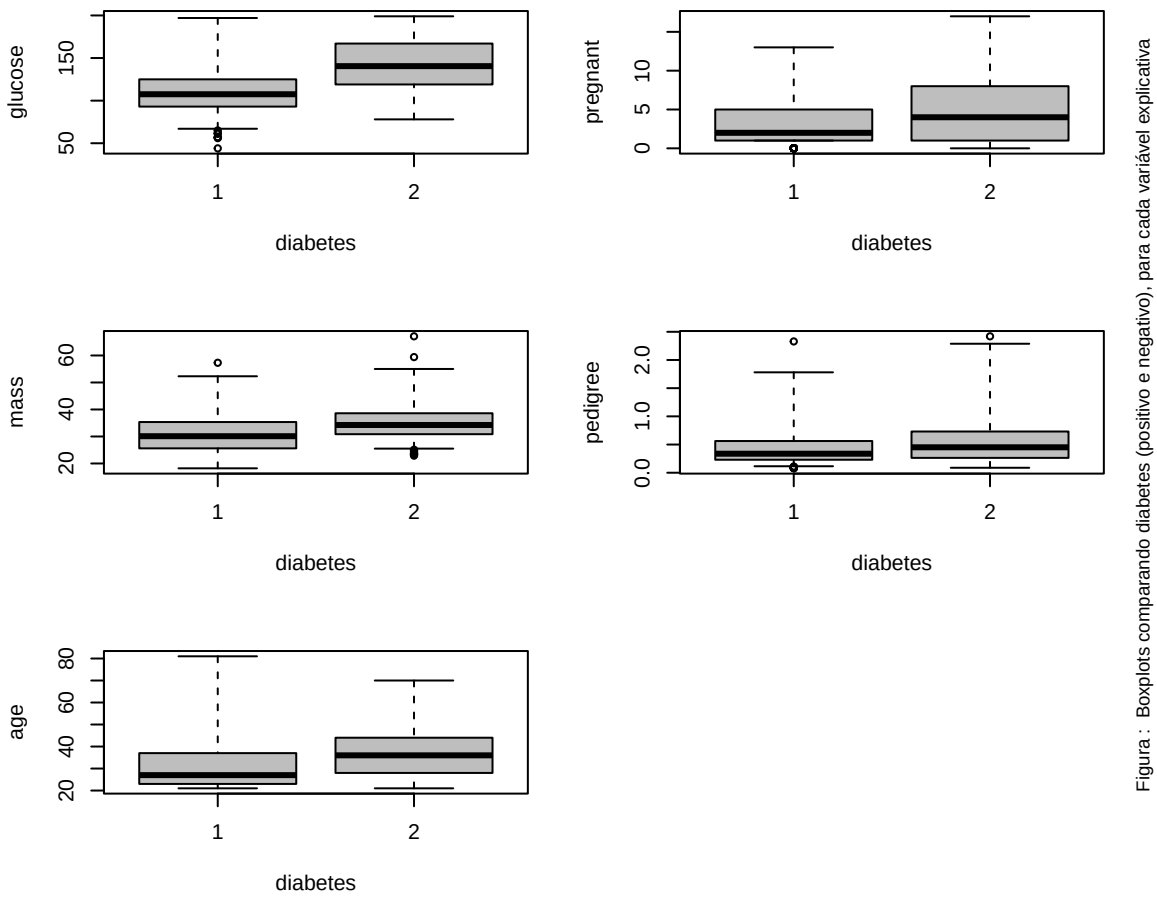


Figura : Boxplots comparando diabetes (positivo e negativo), para cada variável explicativa

Mulheres que apresentam um valor maior de mediana para as corvariáveis glucose, pregant, mass e age podem estar associadas a uma maior chance de possuir a doença.

Ajustar um modelo logístico binomial aos dados para explicar a probabilidade de diagnóstico positivo de diabetes dadas as demais variáveis explicativas. Escrever o modelo. Usar o comando stepGAIC do GAMLSS para fazer uma seleção de variáveis explicativas.

- Ajuste inicial:

(1) $Y_i \sim Bernoulli(\mu_i)$

(2) $log\left(\frac{\mu_i}{1-\mu_i}\right) = \beta_0 + \beta_1 pregnant + \beta_2 glucose + \beta_3 mass + \beta_4 pedigree + \beta_5 age$

```r
m1.pima <- gamlss(diabetes ~ pregnant + glucose + mass + pedigree+age, family = BI, trace=F)
```

- Ajuste Final:

(1) $Y_i \sim Bernoulli(n, \mu_i)$

(2) $log\left(\frac{\mu_i}{1-\mu_i}\right) = -9.082422 + 0.135906 pregnant + 0.036807 glucose + 0.086165 mass + 0.929365 pedigree$

```
Distribution parameter:  mu
Start:  AIC= 715.24
 diabetes ~ pregnant + glucose + mass + pedigree + age

           Df    AIC
- age       1 714.72
<none>        715.24
- pedigree  1 722.90
- pregnant  1 726.30
- mass      1 752.05
- glucose   1 843.20

Step:  AIC= 714.72
 diabetes ~ pregnant + glucose + mass + pedigree

           Df    AIC
<none>        714.72
- pedigree  1 722.58
- pregnant  1 737.76
- mass      1 750.51
- glucose   1 855.93

*******************************************************************
Family:  c("BI", "Binomial")

Call:  gamlss(formula = diabetes ~ pregnant + glucose + mass +
    pedigree, family = BI, trace = FALSE)

Fitting method: RS()

------------------------------------------------------------------
Mu link function:  logit
```

```
Mu Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept) -9.082422   0.704940 -12.884  < 2e-16 ***
pregnant     0.135906   0.027655   4.914 1.10e-06 ***
glucose      0.036807   0.003499  10.519  < 2e-16 ***
mass         0.086165   0.014688   5.866 6.69e-09 ***
pedigree     0.929365   0.300349   3.094  0.00205 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

-------------------------------------------------------------------
No. of observations in the fit:  752
Degrees of Freedom for the fit:  5
      Residual Deg. of Freedom:  747
                      at cycle:  2

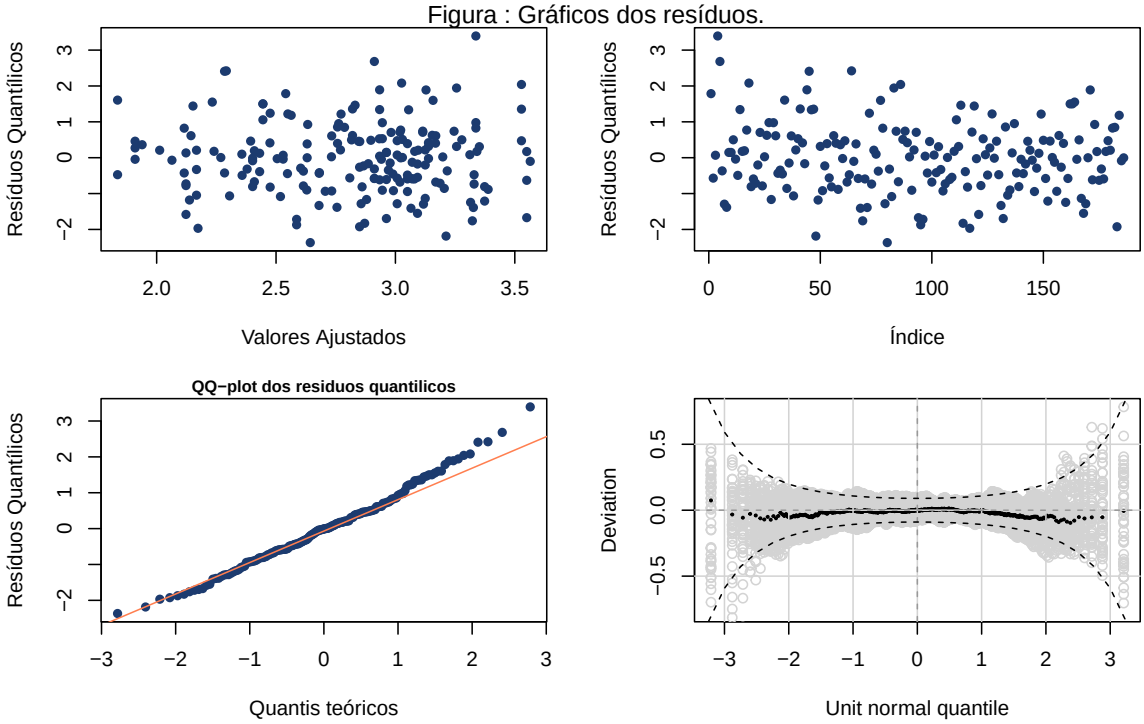
Global Deviance:     704.7176
            AIC:     714.7176
            SBC:     737.8313
*******************************************************************
```

Todas as covariáveis selecionadas pelo AIC foram significativas a um nível de 5%. * **Interpretação**

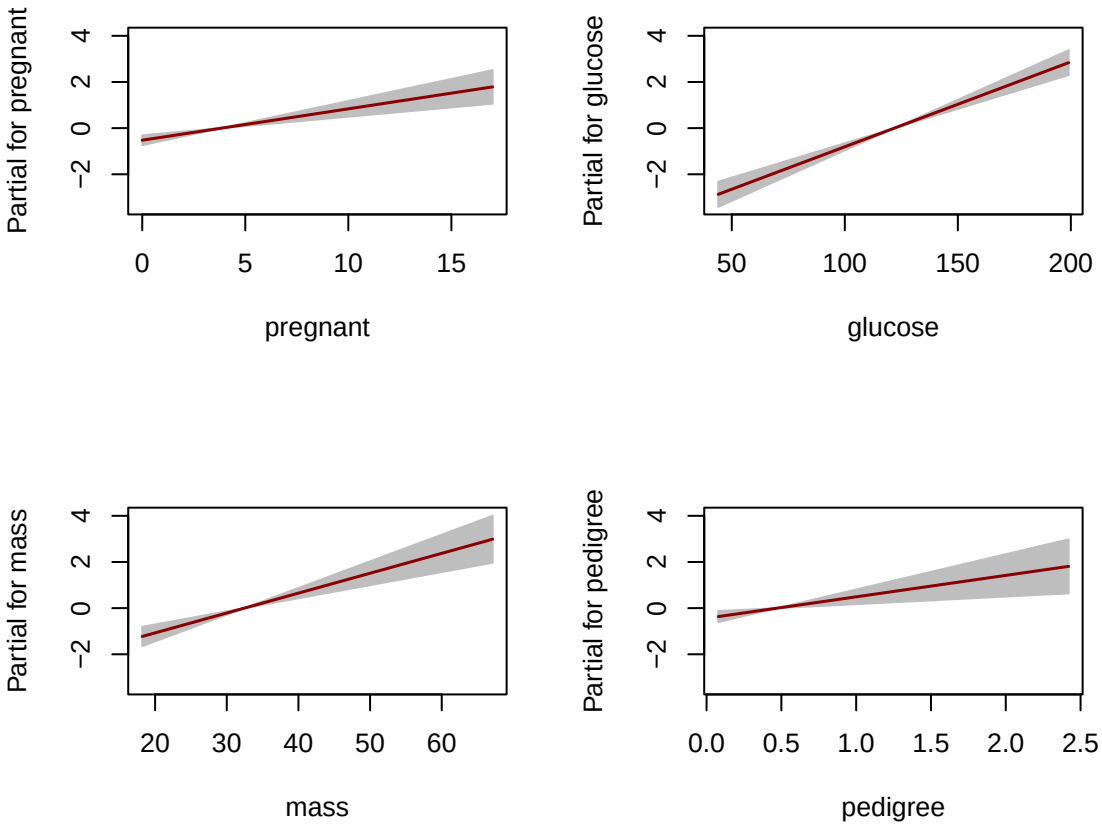
- Mantendo as demais covariáveis constantes, o aumento de uma unidade no número de vezes que engravidou aumenta em 14% a chance de ter diabetes.
- Mantendo as demais covariáveis constantes, o aumento de uma unidade na concentração de glicose no plasma aumenta em 3.7% a chance de ter diabetes.
- Mantendo as demais covariáveis constantes, o aumento de uma unidade no índice de massa corporal aumenta em 9% a chance de ter diabetes.
- Mantendo as demais covariáveis constantes, o aumento de uma unidade no pedigree aumenta em 153% a chance de ter diabetes.

Análise de resíduos

Figura : Gráficos dos resíduos.



- O gráfico dos resíduos pelo valores ajustados não apresenta nenhum padrão indicativo de heterocedasticidade, a suposição de homocedasticidade é atendida;
- O gráfico dos resíduos pelo índice das observações não apresenta padrões indicativos de dependência entre os resíduos;
- Os gráficos dos resíduos comparados com os quantis da normal(qq-plot e wormplot) não apresentam grandes desvios da normalidade. A suposição de normalidade pode ser considerada adequada.



Todos os efeitos parciais são positivos.

```
m3.pima = gamlss(diabetes ~ pregnant + pb(glucose) + pb(mass)
+ pb(pedigree) + pb(age), family = BI)
```

```
GAMLSS-RS iteration 1: Global Deviance = 655.6645
GAMLSS-RS iteration 2: Global Deviance = 655.6828
GAMLSS-RS iteration 3: Global Deviance = 655.6836
```

```
m4.pima = stepGAIC(m3.pima)
```

```
Distribution parameter:  mu
Start:  AIC= 681.61
 diabetes ~ pregnant + pb(glucose) + pb(mass) + pb(pedigree) +
```

```
    pb(age)

                    Df    AIC
- pregnant     0.99001 681.13
<none>                 681.61
- pb(pedigree) 2.44585 691.31
- pb(age)      3.13760 697.23
- pb(mass)     3.93335 721.16
- pb(glucose)  1.57510 809.57

Step:  AIC= 681.13
 diabetes ~ pb(glucose) + pb(mass) + pb(pedigree) + pb(age)

                   Df    AIC
<none>                681.13
- pb(pedigree) 2.3754 690.72
- pb(age)      3.2830 717.68
- pb(mass)     3.8221 720.02
- pb(glucose)  1.5049 808.52
```

```
summary(m4.pima)
```

```
******************************************************************
Family:  c("BI", "Binomial")

Call:  gamlss(formula = diabetes ~ pb(glucose) + pb(mass) +
    pb(pedigree) + pb(age), family = BI, trace = FALSE)

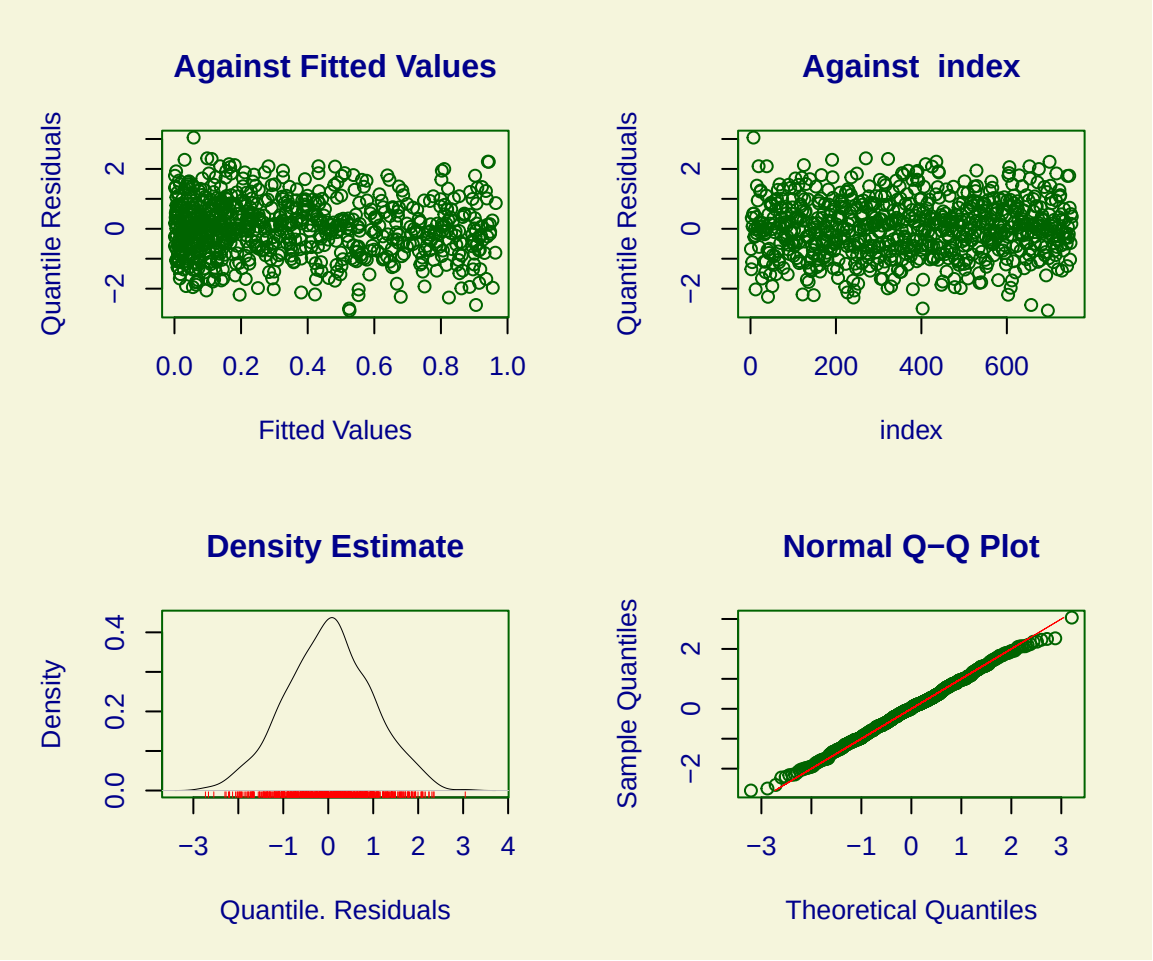
Fitting method: RS()

------------------------------------------------------------------
Mu link function:  logit
Mu Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)  -9.64402    0.77645 -12.421  < 2e-16 ***
pb(glucose)   0.03662    0.00359  10.201  < 2e-16 ***
pb(mass)      0.08566    0.01572   5.448 6.96e-08 ***
pb(pedigree)  0.78423    0.28777   2.725 0.006578 **
pb(age)       0.03340    0.00860   3.884 0.000112 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
-----------------------------------------------------------------
NOTE: Additive smoothing terms exist in the formulas:
 i) Std. Error for smoothers are for the linear effect only.
ii) Std. Error for the linear terms maybe are not accurate.
-----------------------------------------------------------------
No. of observations in the fit:  752
Degrees of Freedom for the fit:  11.97211
      Residual Deg. of Freedom:  740.0279
                       at cycle:  3

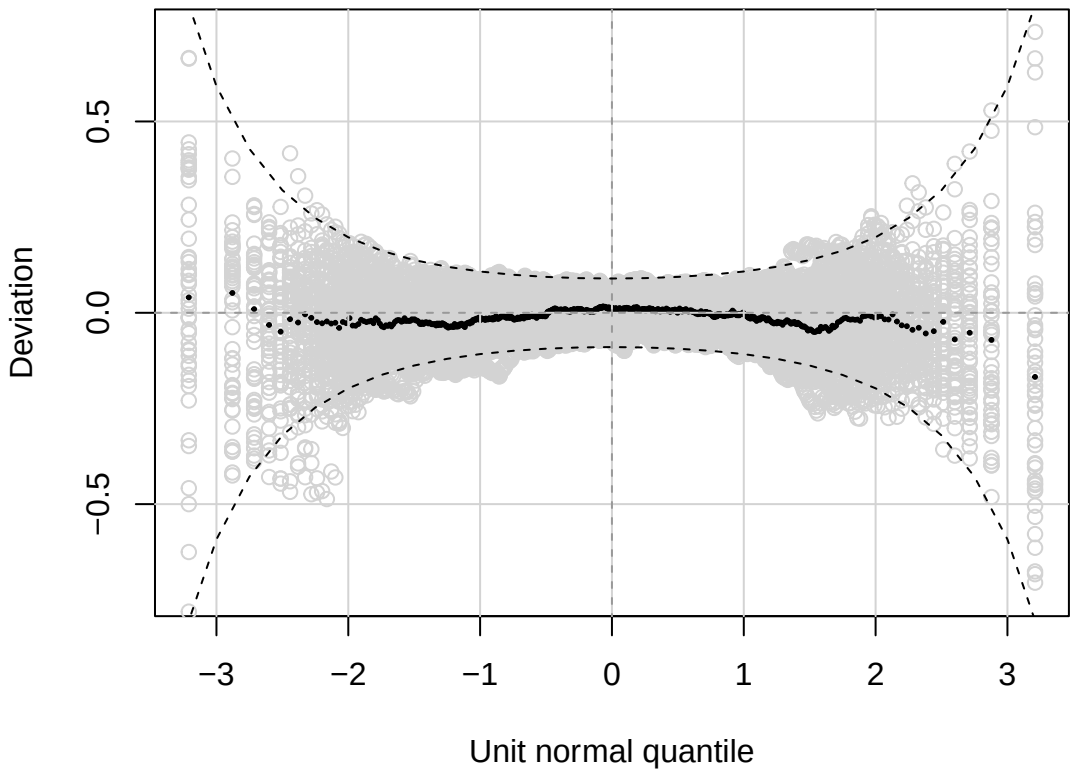
Global Deviance:     657.1858
            AIC:     681.1301
            SBC:     736.474
*****************************************************************
```

```r
plot(m4.pima)
```

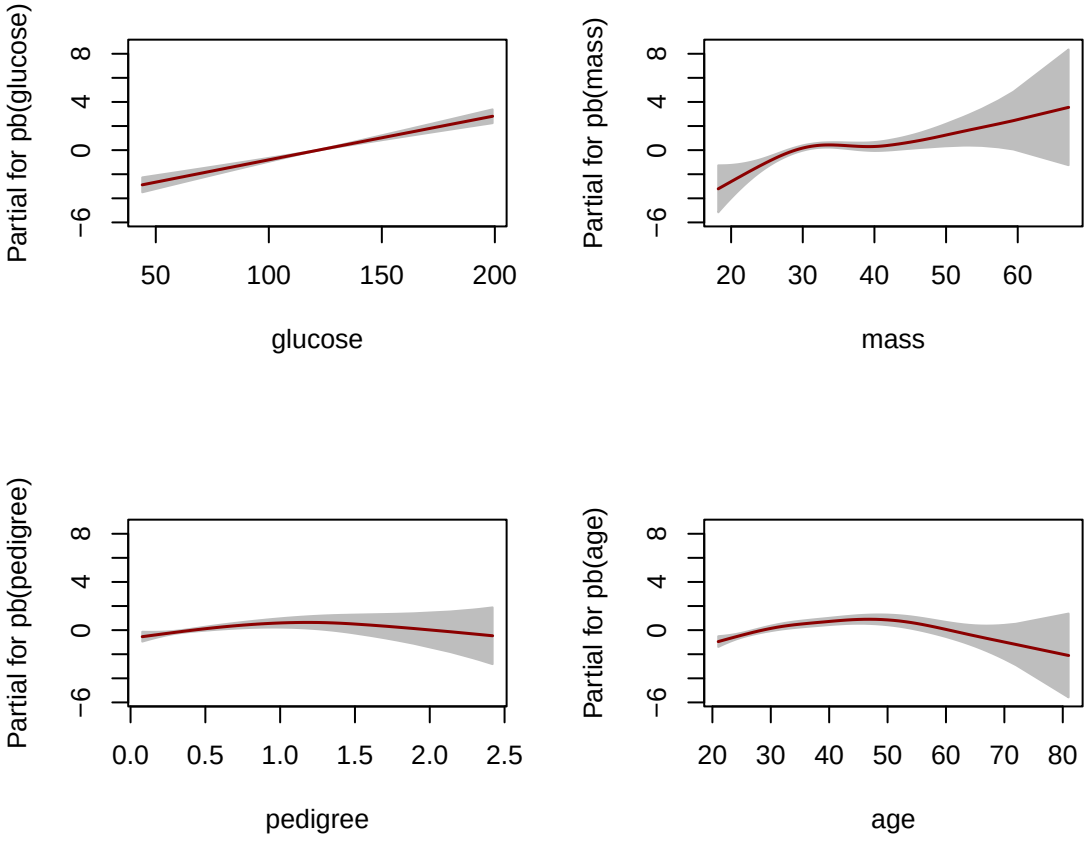



```
*****************************************************************
     Summary of the Randomised Quantile Residuals
                           mean   =  0.0187954
                       variance   =  0.8937778
                  coef. of skewness  =  -0.004447034
                  coef. of kurtosis  =  2.85582
Filliben correlation coefficient  =  0.9993326
*****************************************************************
```

```
rqres.plot(m4.pima, howmany=50, plot="all")
```




```
term.plot(m4.pima, pages=1)
```




```
require(pROC)
```

```
Carregando pacotes exigidos: pROC
```

```
Type 'citation("pROC")' for a citation.
```

```

Anexando pacote: 'pROC'
```

```
Os seguintes objetos são mascarados por 'package:stats':
```

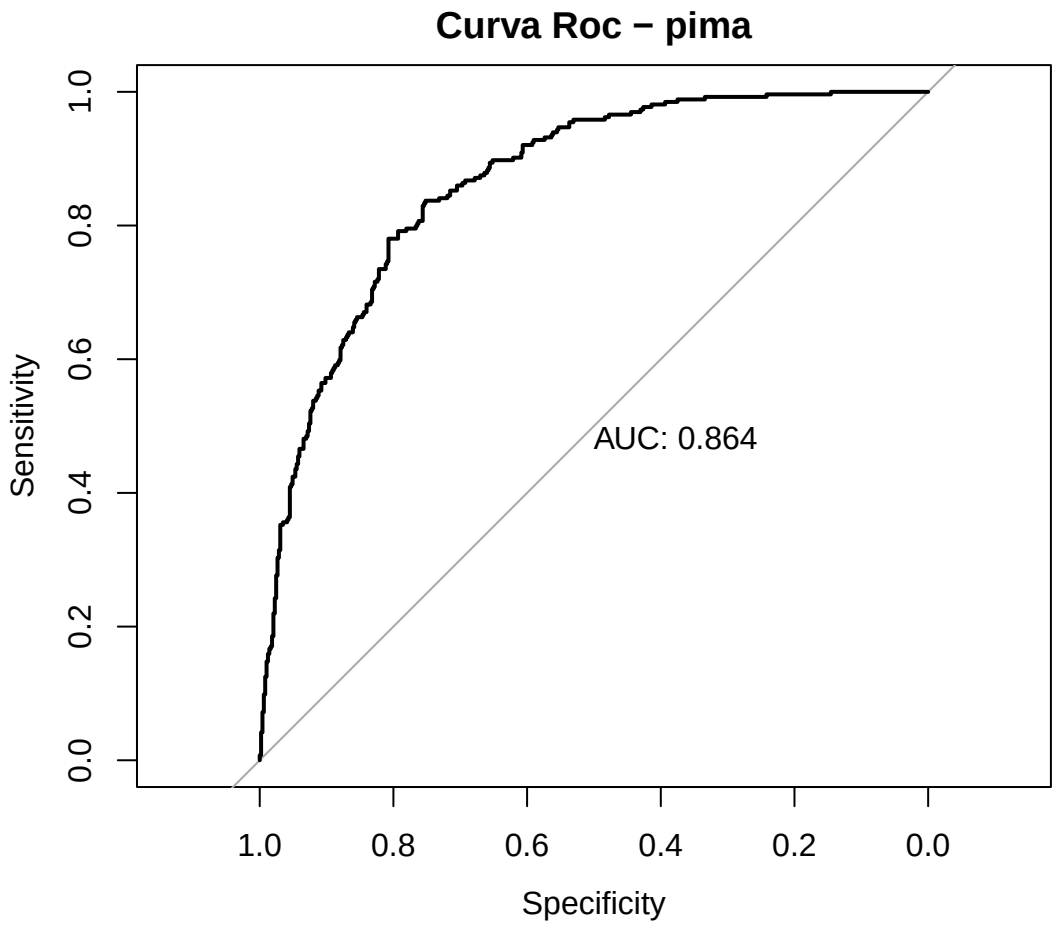
```
    cov, smooth, var
```

```r
resp = diabetes
pred.pima = predict(m4.pima, type="response")
roc.pima = roc(response = resp, predictor = pred.pima)
```

```
Setting levels: control = Negativo, case = Positivo
```

```
Setting direction: controls < cases
```

```r
plot(roc.pima, main = "Curva Roc - pima", print.auc = TRUE)
```




```r
optimal_coords = coords(roc.pima, "best", ret = c("specificity",
"sensitivity", "threshold"))
print(optimal_coords)
```

```
  specificity sensitivity threshold
1   0.7520492   0.8371212  0.322672
```

Exercício 4

```
require(pscl)
```

```
Carregando pacotes exigidos: pscl
```

```
Classes and Methods for R originally developed in the
Political Science Computational Laboratory
Department of Political Science
Stanford University (2002-2015),
by and under the direction of Simon Jackman.
hurdle and zeroinfl functions by Achim Zeileis.
```

```
summary(bioChemists)
```

```
      art            fem           mar          kid5            phd        
 Min.   : 0.000   Men  :494   Single :309   Min.   :0.0000   Min.   :0.755  
 1st Qu.: 0.000   Women:421   Married:606   1st Qu.:0.0000   1st Qu.:2.260  
 Median : 1.000                           Median :0.0000   Median :3.150  
 Mean   : 1.693                           Mean   :0.4951   Mean   :3.103  
 3rd Qu.: 2.000                           3rd Qu.:1.0000   3rd Qu.:3.920  
 Max.   :19.000                           Max.   :3.0000   Max.   :4.620  
      ment      
 Min.   : 0.000  
 1st Qu.: 3.000  
 Median : 6.000  
 Mean   : 8.767  
 3rd Qu.:12.000  
 Max.   :77.000  
```

```
attach(bioChemists)

table(art,fem)
```

```
    fem
art  Men Women
  0  136   139
  1  135   111
  2   87    91
  3   54    30
  4   38    29
  5   16    11
  6    9     8
  7   11     1
  8    1     0
  9    2     0
  10   0     1
  11   1     0
  12   2     0
  16   1     0
  19   1     0
```

```r
table(art,mar)
```

```
    mar
art  Single Married
  0      99     176
  1      84     162
  2      60     118
  3      22      62
  4      22      45
  5       6      21
  6       8       9
  7       8       4
  8       0       1
  9       0       2
  10      0       1
  11      0       1
  12      0       2
  16      0       1
  19      0       1
```

```r
tabela.total.linhas<-prop.table(table(art,fem), margin=1)*100

round(tabela.total.linhas,3)
```

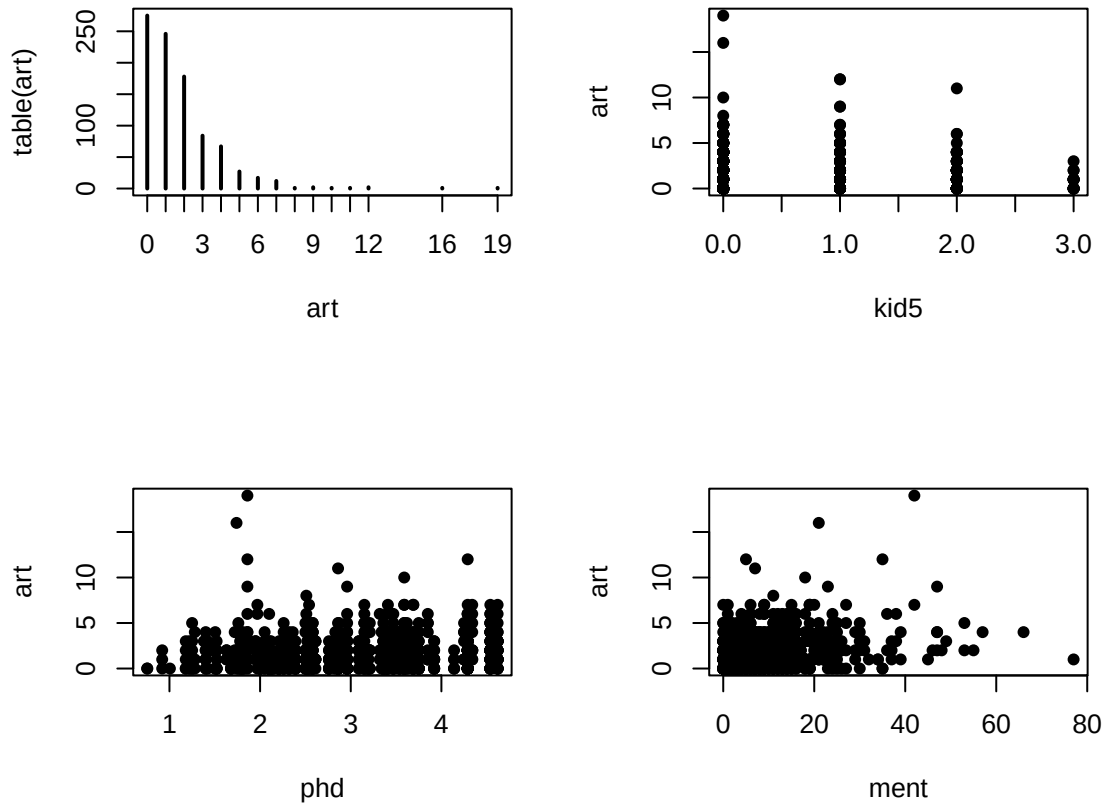
```
    fem
art      Men   Women
  0   49.455  50.545
  1   54.878  45.122
  2   48.876  51.124
  3   64.286  35.714
  4   56.716  43.284
  5   59.259  40.741
  6   52.941  47.059
  7   91.667   8.333
  8  100.000   0.000
  9  100.000   0.000
  10   0.000 100.000
  11 100.000   0.000
  12 100.000   0.000
  16 100.000   0.000
  19 100.000   0.000
```

```
tabela.total.linhas2<-prop.table(table(art,mar), margin=1)*100

t(round(tabela.total.linhas2,3))
```

```
         art
mar            0       1       2       3       4       5       6       7
  Single   36.000  34.146  33.708  26.190  32.836  22.222  47.059  66.667
  Married  64.000  65.854  66.292  73.810  67.164  77.778  52.941  33.333
         art
mar            8       9      10      11      12      16      19
  Single   0.000   0.000   0.000   0.000   0.000   0.000   0.000
  Married 100.000 100.000 100.000 100.000 100.000 100.000 100.000
```

```
par(mfrow=c(2,2))
plot(table(art),lwd=2)
plot(kid5,art, pch=16)
plot(phd,art,pch=16)
plot(ment,art,pch=16)
```




```
par(mfrow=c(1,1))
```

- Ajuste inicial:

$$(1)\ Y_i \sim Poisson(\mu_i)$$
$$(2)\ log(\mu_i) = \beta_0 + \beta_1 fem + \beta_2 mar + \beta_3 kid5 + \beta_4 phd + \beta_5 ment$$

```
m1.bio = gamlss(art ~ ., family=PO, data=bioChemists)
```

```
GAMLSS-RS iteration 1: Global Deviance = 3302.113
GAMLSS-RS iteration 2: Global Deviance = 3302.113
```

```
m2.bio = stepGAIC(m1.bio)
```

```
Distribution parameter:  mu
Start:  AIC= 3314.11
 art ~ fem + mar + kid5 + phd + ment

       Df    AIC
- phd   1 3312.3
<none>    3314.1
- mar   1 3318.5
- fem   1 3329.2
- kid5  1 3334.2
- ment  1 3444.0

Step:  AIC= 3312.35
 art ~ fem + mar + kid5 + ment

       Df    AIC
<none>    3312.3
- mar   1 3316.6
- fem   1 3327.5
- kid5  1 3332.4
- ment  1 3452.5
```

```
summary(m2.bio)
```

```
******************************************************************
Family:  c("PO", "Poisson")

Call:  gamlss(formula = art ~ fem + mar + kid5 + ment, family = PO,
    data = bioChemists, trace = FALSE)

Fitting method: RS()

------------------------------------------------------------------
Mu link function:  log
Mu Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.345174   0.060122   5.741 1.28e-08 ***
femWomen    -0.225303   0.054615  -4.125 4.04e-05 ***
marMarried   0.152175   0.061067   2.492   0.0129 *
```

```
kid5        -0.184993   0.040139  -4.609 4.63e-06 ***
ment         0.025761   0.001949  13.218  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

-------------------------------------------------------------------
No. of observations in the fit:  915
Degrees of Freedom for the fit:  5
      Residual Deg. of Freedom:  910
                      at cycle:  2

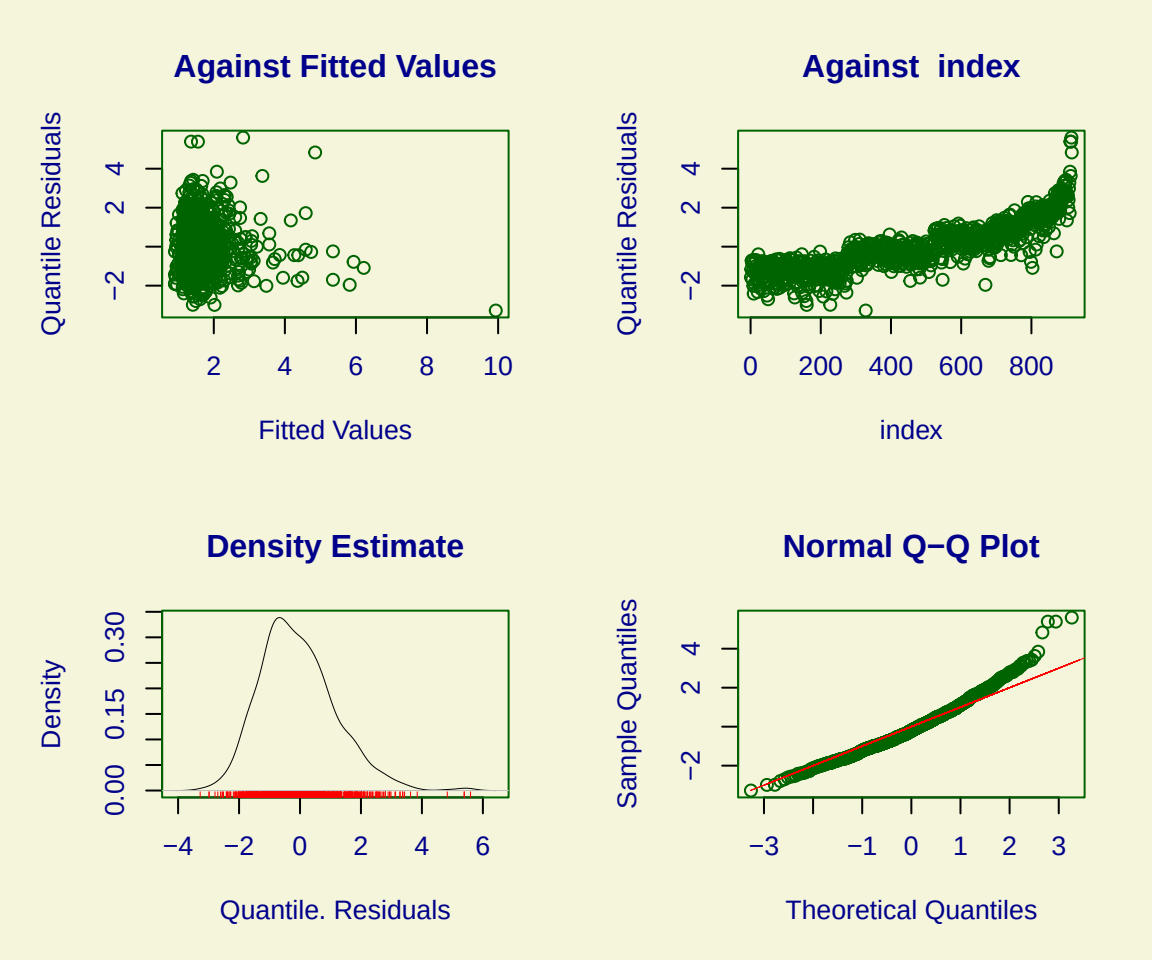
Global Deviance:     3302.349
            AIC:     3312.349
            SBC:     3336.443
*******************************************************************
```

- Ajuste Final:

(1) $Y_i \sim Poisson(\mu_i)$
(2) $log(\mu_i) = 0.345174 - 0.225303fem + 0.152175mar - 0.184993kid5 + 0.025761ment$

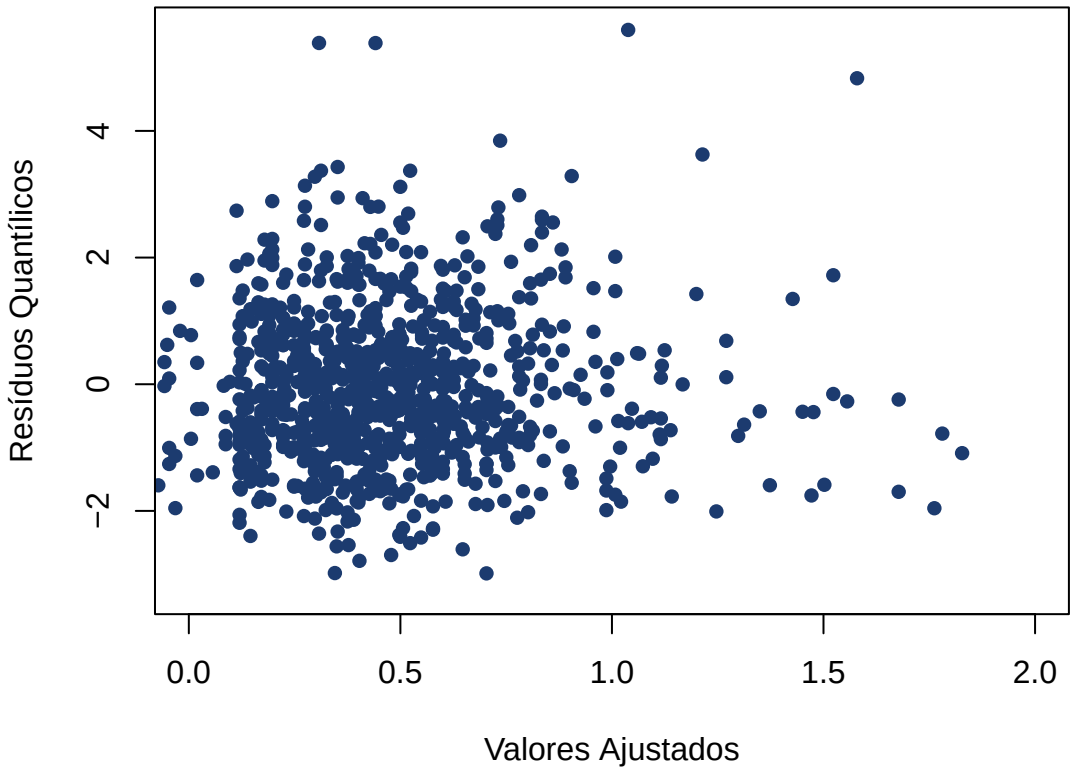
- **Interpretação**
- Um homem solteiro, sem filhos, cujo orientador não pubiblicou nenhum artigo, publica em média 1.41 artigos.
- Mantendo as demais covariáveis constantes, ser do sexo feminino reduz em aproximadamente 20% o número de artigos publicados.
- Mantendo as demais covariáveis constantes, estar casado aumenta em aproximadamente 16% o número de artigos publicados.
- Mantendo as demais covariáveis constantes, o aumento de uma unidade no número de filhos reduz em 17% o número de artigos publicados.
- Mantendo as demais covariáveis constantes, o aumento de uma unidade no número de artigos publicados pelo orientador aumenta em aproximadamente 3% o número de artigos publicados pelo doutor.

```
plot(m2.bio)
```

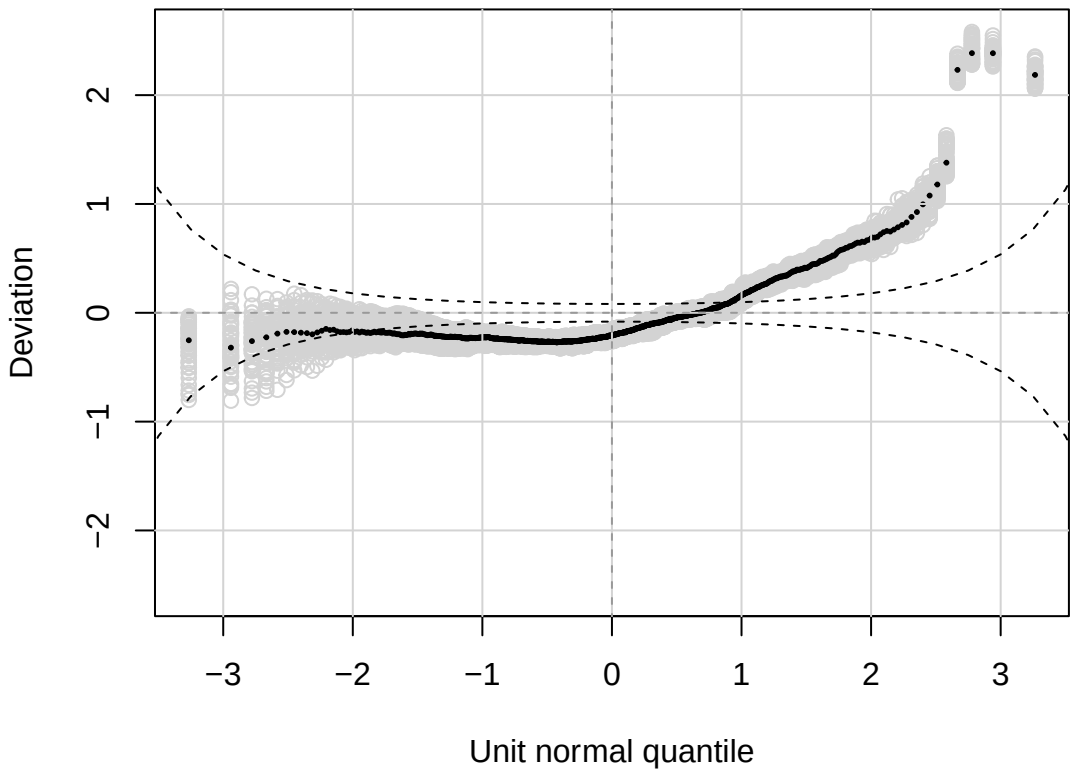



```
*****************************************************************
     Summary of the Randomised Quantile Residuals
                           mean   =  -0.0718396
                       variance   =  1.548825
                  coef. of skewness  =  0.6921813
                  coef. of kurtosis  =  4.076503
Filliben correlation coefficient  =  0.9873055
*****************************************************************
```

```r
plot(resid(m2.bio) ~ predict(m2.bio),
     xlab = "Valores Ajustados",
     ylab = "Resíduos Quantílicos",
     pch = 16,
     col = cores[1], xlim=c(0,2))
```




```
rqres.plot(m2.bio, howmany=50, plot="all")
```



- Como estamos no modelo Poisson, não temos a suposição de variância constante;
- O gráfico dos resíduos pelo índice das observações apresenta um padrão bastante evidente de dependência entre os resíduos;
- Os gráficos dos resíduos comparados com os quantis da normal(qq-plot e wormplot) apresentam grandes desvios da normalidade. O modelo postulado apresenta problemas.

```
m3.bio = gamlss(art ~., family=NBI, data=bioChemists)
```

```
GAMLSS-RS iteration 1: Global Deviance = 3121.959
GAMLSS-RS iteration 2: Global Deviance = 3121.917
GAMLSS-RS iteration 3: Global Deviance = 3121.917
```

```
m4.bio = stepGAIC(m3.bio)
```

```
Distribution parameter:  mu
Start:  AIC= 3135.92
 art ~ fem + mar + kid5 + phd + ment

       Df    AIC
- phd   1 3134.1
<none>    3135.9
- mar   1 3137.3
- fem   1 3142.7
- kid5  1 3145.0
- ment  1 3205.1

Step:  AIC= 3134.1
 art ~ fem + mar + kid5 + ment

       Df    AIC
<none>    3134.1
- mar   1 3135.3
- fem   1 3140.9
- kid5  1 3143.2
- ment  1 3208.9
```

```
summary(m4.bio)
```

```
******************************************************************
Family:  c("NBI", "Negative Binomial type I")

Call:  gamlss(formula = art ~ fem + mar + kid5 + ment, family = NBI,
    data = bioChemists, trace = FALSE)

Fitting method: RS()

------------------------------------------------------------------
Mu link function:  log
Mu Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.303318   0.082337   3.684 0.000243 ***
femWomen    -0.216671   0.072672  -2.981 0.002945 **
marMarried   0.146943   0.081675   1.799 0.072331 .
```

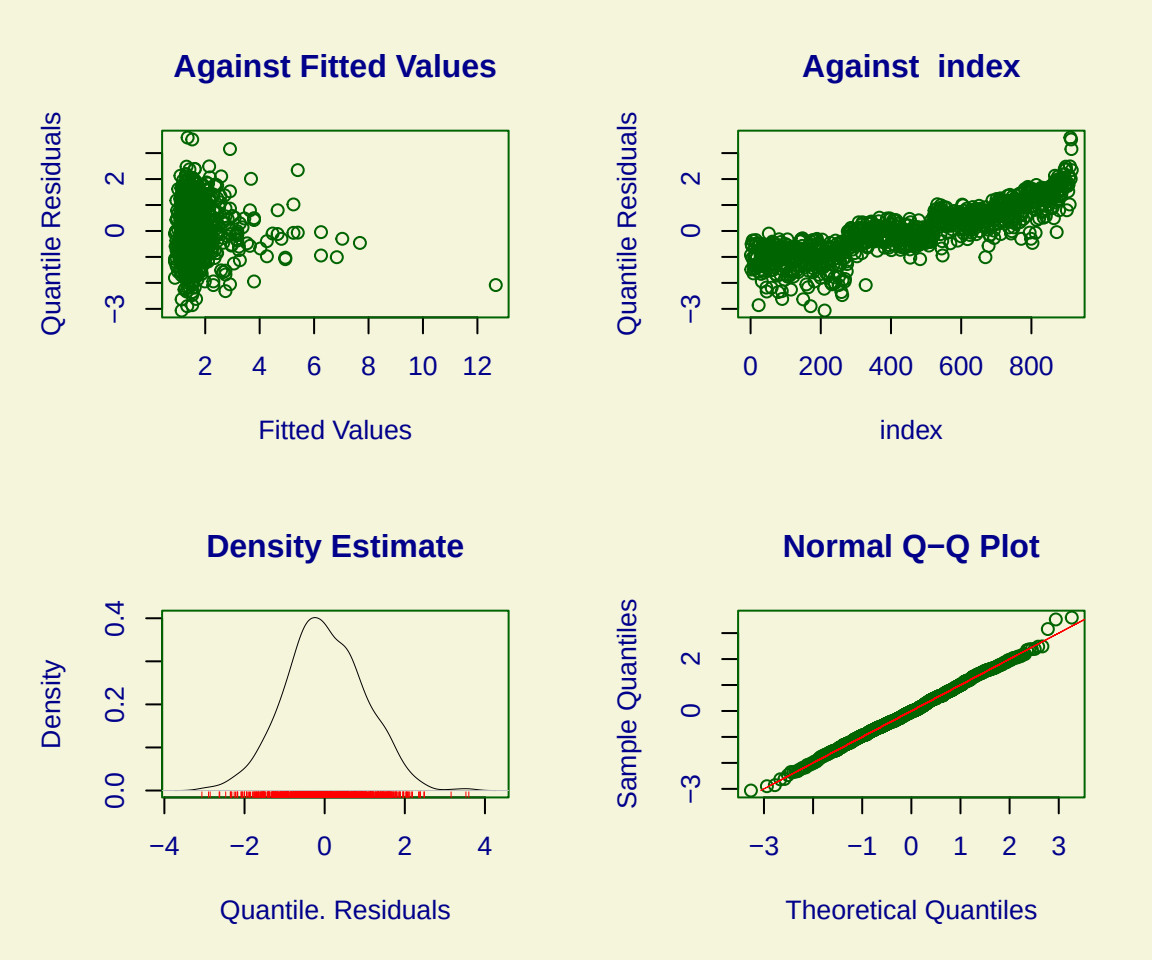
```
kid5        -0.176795   0.053054  -3.332 0.000896 ***
ment         0.029431   0.003377   8.716  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

------------------------------------------------------------------
Sigma link function:  log
Sigma Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  -0.8172     0.1199  -6.813 1.74e-11 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

------------------------------------------------------------------
No. of observations in the fit:  915
Degrees of Freedom for the fit:  6
      Residual Deg. of Freedom:  909
                      at cycle:  3

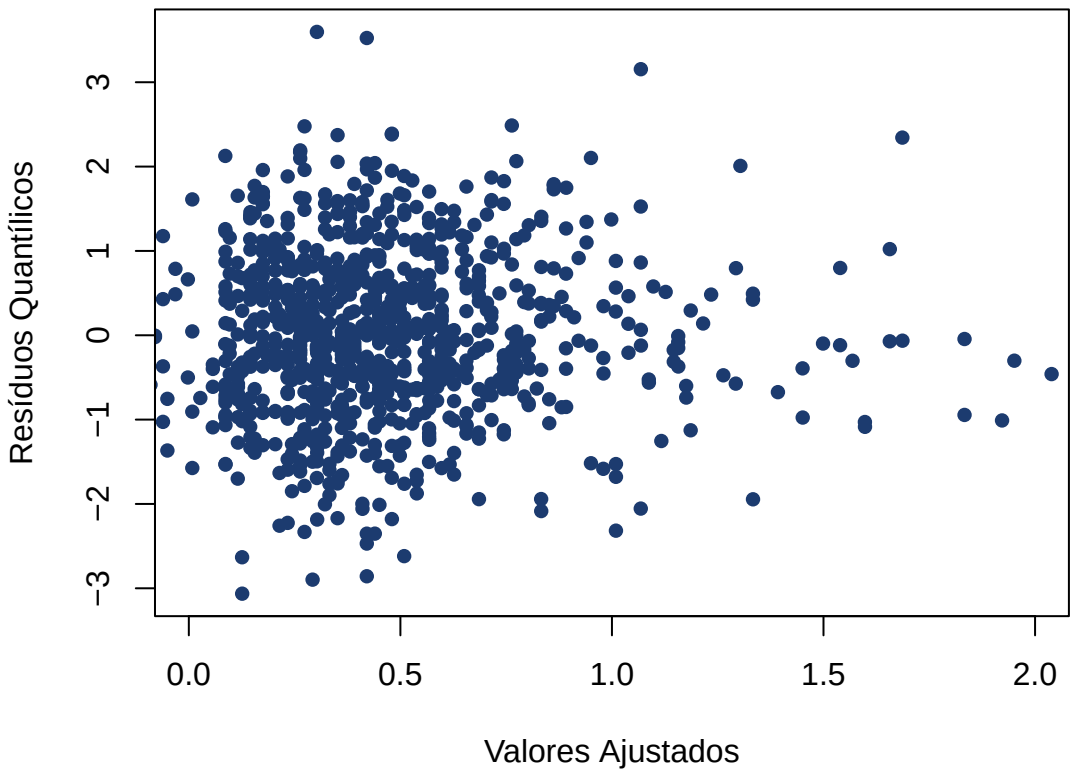
Global Deviance:     3122.096
            AIC:     3134.096
            SBC:     3163.01
******************************************************************
```

```r
plot(m4.bio)
```

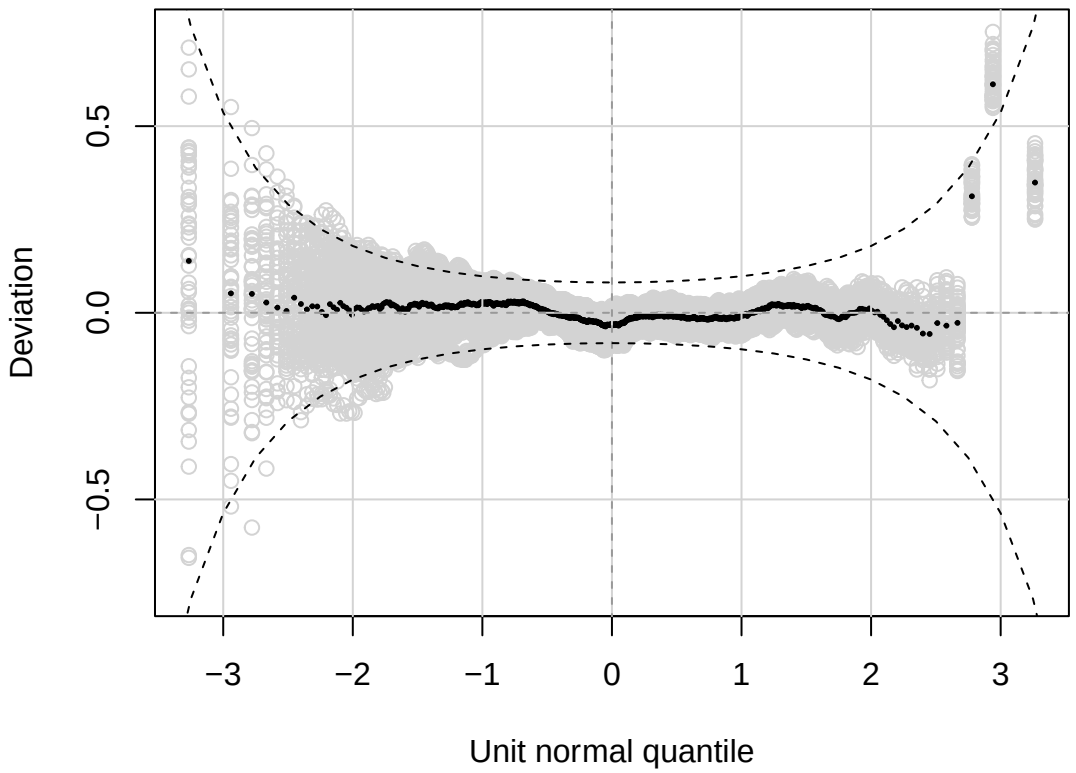



```
**********************************************************************
     Summary of the Randomised Quantile Residuals
                           mean   =  0.003444952
                       variance   =  0.9819782
                  coef. of skewness  =  0.06902594
                  coef. of kurtosis  =  3.080927
Filliben correlation coefficient  =  0.9991374
**********************************************************************
```

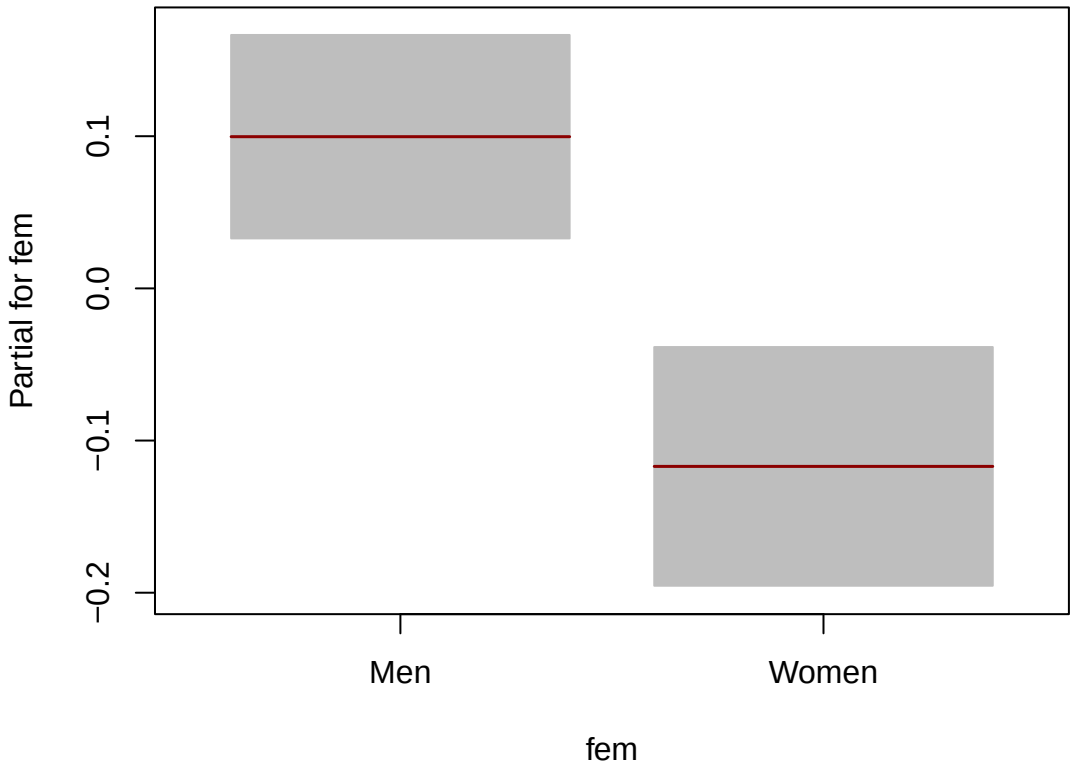
```r
plot(resid(m4.bio) ~ predict(m4.bio),
     xlab = "Valores Ajustados",
     ylab = "Resíduos Quantílicos",
     pch = 16,
     col = cores[1], xlim=c(0,2))
```



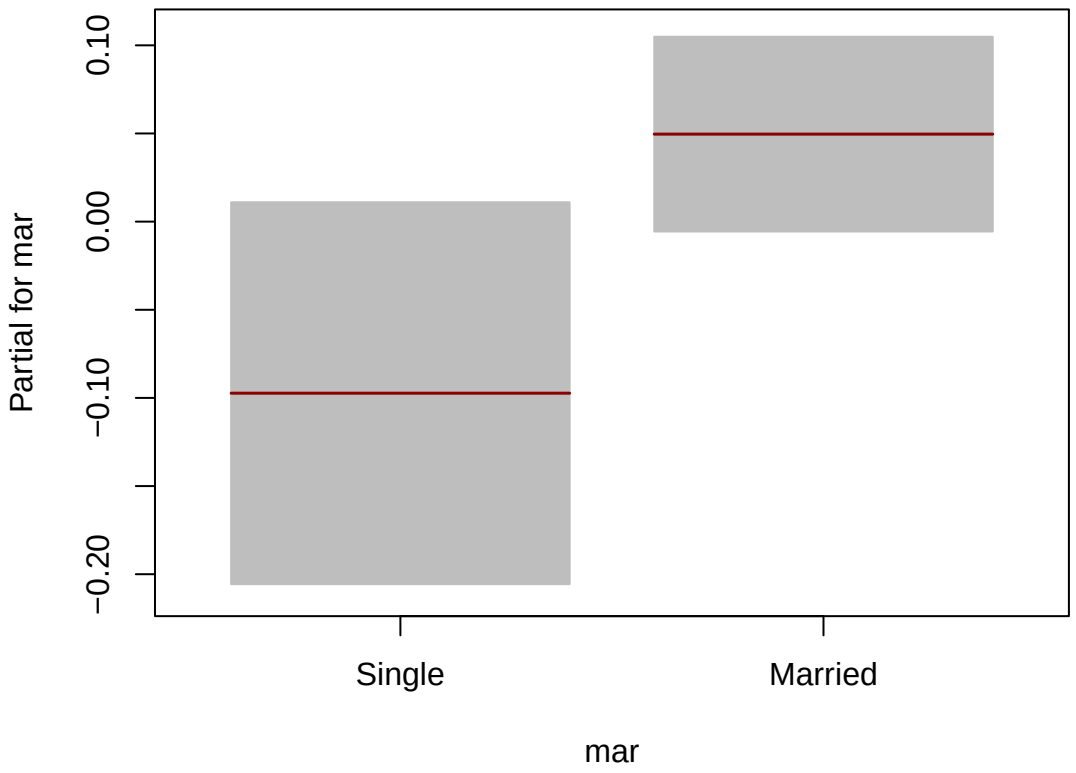

```
rqres.plot(m4.bio, howmany=50, plot="all")
```



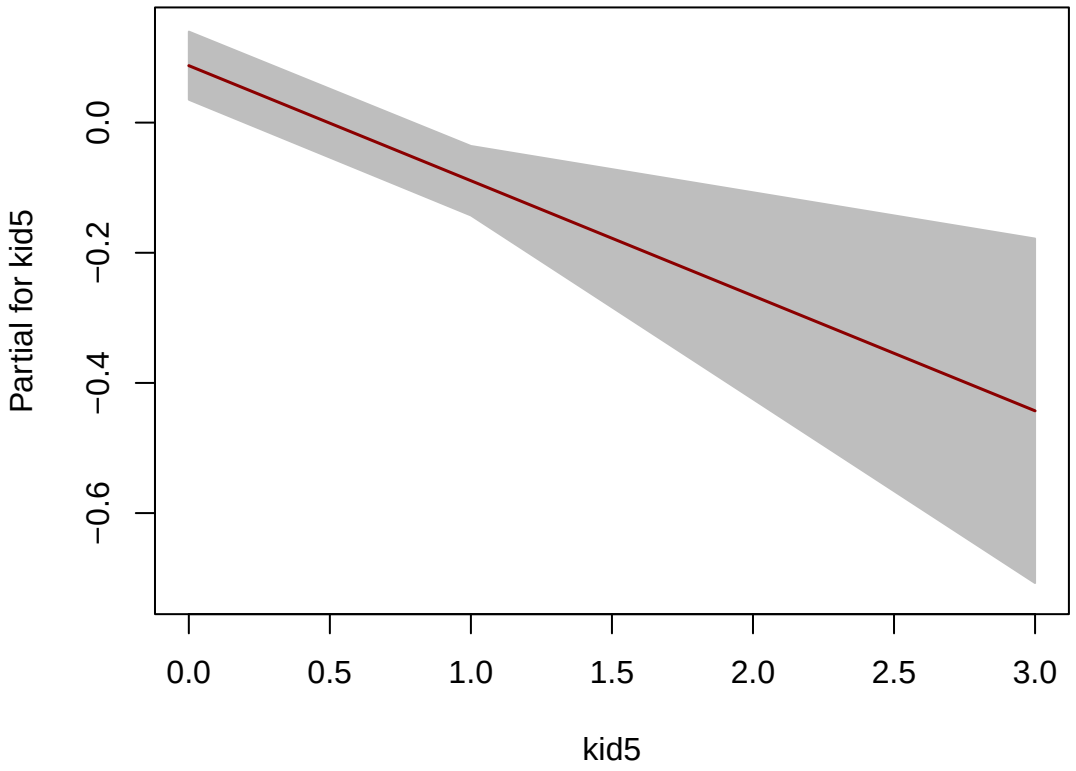

```
term.plot(m4.bio, terms=1)
```



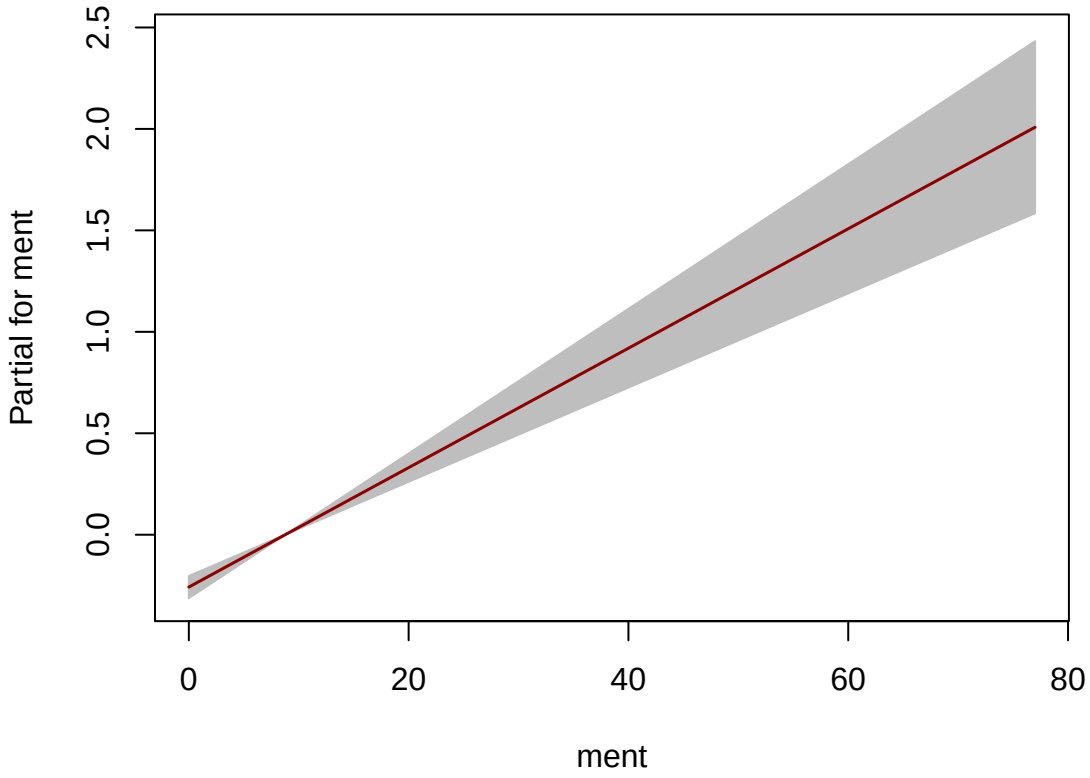

```
term.plot(m4.bio, terms=2)
```




```
term.plot(m4.bio, terms=3)
```




```
term.plot(m4.bio, terms=4)
```




```
resumo<-summary(m4.bio)
```

```
******************************************************************
Family:  c("NBI", "Negative Binomial type I")

Call:  gamlss(formula = art ~ fem + mar + kid5 + ment, family = NBI,
    data = bioChemists, trace = FALSE)

Fitting method: RS()

------------------------------------------------------------------
Mu link function:  log
Mu Coefficients:
             Estimate Std. Error t value Pr(>|t|)
```

```
(Intercept)  0.303318   0.082337   3.684 0.000243 ***
femWomen    -0.216671   0.072672  -2.981 0.002945 **
marMarried   0.146943   0.081675   1.799 0.072331 .
kid5        -0.176795   0.053054  -3.332 0.000896 ***
ment         0.029431   0.003377   8.716  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

-------------------------------------------------------------------
Sigma link function:  log
Sigma Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  -0.8172     0.1199  -6.813 1.74e-11 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

-------------------------------------------------------------------
No. of observations in the fit:  915
Degrees of Freedom for the fit:  6
      Residual Deg. of Freedom:  909
                      at cycle:  3

Global Deviance:     3122.096
            AIC:     3134.096
            SBC:     3163.01
*******************************************************************
```

```r
LI<-exp(resumo[,1]-1.96*resumo[,2])
LS<-exp(resumo[,1]+1.96*resumo[,2])
```

- Interpretação:
- Um homem solteiro, sem filhos, cujo orientador não pubiblicou nenhum artigo, publica em média 1.35 artigos. (IC,95%) = [1.15250; 1.59153]
- Mantendo as demais covariáveis constantes, ser do sexo feminino reduz em aproximadamente 20% o número de artigos publicados. (IC,95%) = [;]
- Mantendo as demais covariáveis constantes, estar casado aumenta em aproximadamente 16% o número de artigos publicados.
- Mantendo as demais covariáveis constantes, o aumento de uma unidade no número de filhos reduz em 17% o número de artigos publicados.

- Mantendo as demais covariáveis constantes, o aumento de uma unidade no número de artigos publicados pelo orientador aumenta em aproximadamente 3% o número de artigos publicados pelo doutor.

5 páginas por questão!!!