

Lista 1 - Prática - MAE5763

Jaqueline Lamas (17646475) Maia Ugarte (12558568)

Sumário

1 Exercício 1 **2**
1.1 Análise descritiva . . . 2
1.2 Ajuste do modelo . . . 3
1.3 Análise de resíduos . . . 4
1.4 Análise de diagnóstico . . . 5

2 Exercício 2 **6**
2.1 Análise descritiva . . . 6
2.2 Ajuste do modelo . . . 7
2.3 Análise de resíduos . . . 9

3 Exercício 3 **11**
3.1 Análise descritiva . . . 11
3.2 Ajuste do modelo . . . 12
3.3 Análise de resíduos . . . 13
3.4 Ajuste do modelo com splines . . . 14

4 Exercício 4 **16**
4.1 Análise descritiva . . . 16
4.2 Ajuste do modelo Poisson . . . 17
4.3 Ajuste do modelo log-linear . . . 18

5 Declaração de contribuição **21**

6 Códigos **21**

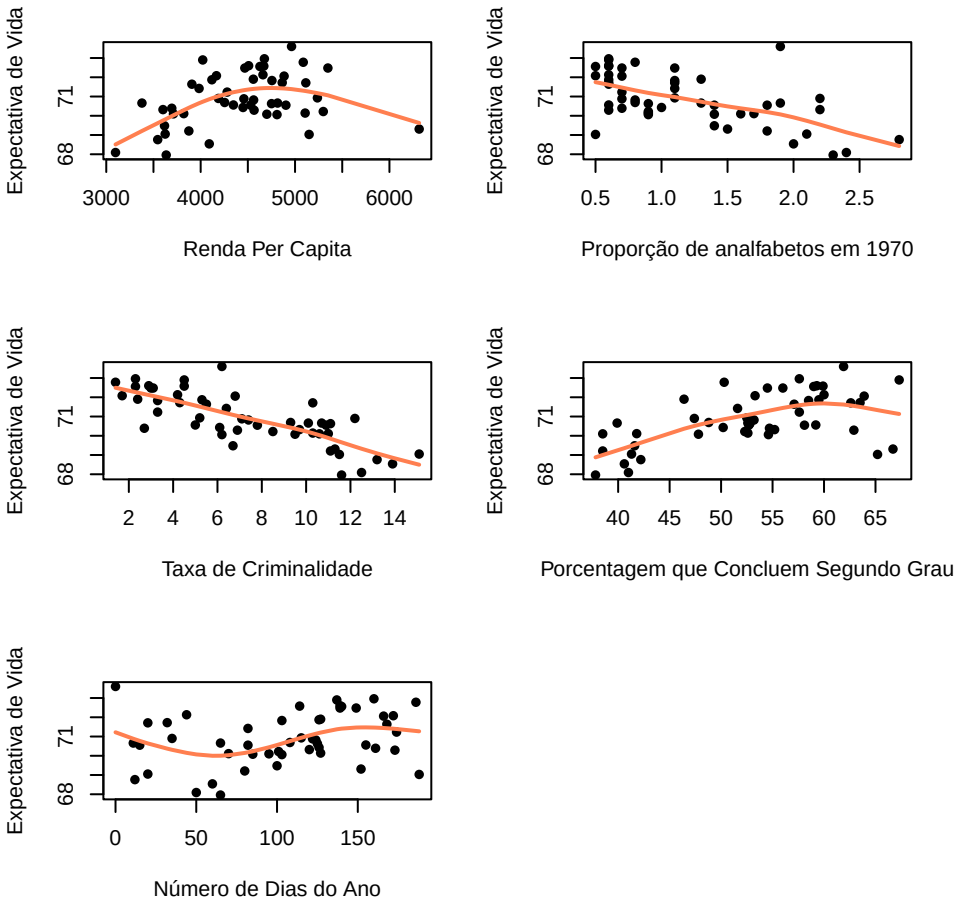
1 Exercício 1

O objetivo do estudo é explicar a *expec* média usando um modelo de regressão normal linear dadas as variáveis explicativas *renda*, *propa*, *taxa*, *prope* e *ndazero*.

- **UF** (nome do estado); **pop** (população estimada em julho de 1975); **renda** (renda per-capita em 1974 em USD); **propa** (proporção de analfabetos em 1970); **expec** (expectativa de vida em anos 1969-70); **taxa** (taxa de criminalidade por 100000 habitantes 1976); **prope** (porcentagem de estudantes que concluem segundo grau 1970); **ndazero** (número de dias do ano com temperatura abaixo de zero grau Celsus na cidade mais importante do estado); **area** (área do estado em milhas quadradas).

1.1 Análise descritiva

Figura 1: Gráficos de dispersão da variável resposta pelas explicativas.



Pelos diagramas de dispersão, Figura 1, conseguimos observar que:

- As variáveis *Taxa de Criminalidade* e *Proporção de Analfabetos em 1970* parecem se relacionar negativamente e de forma linear com a *Expectativa de Vida*.
- A variável *Porcentagem de Estudantes que Conluem o Ensino Médio* parece estar relacionada com a resposta por meio de uma curva, com uma tendência positiva.
- As variável *Renda* e *Número de Dias do Ano com Temperaturas* abaixo de zero aparenta se relacionar com a resposta por meio de uma curva.

1.2 Ajuste do modelo

- **Ajuste inicial**:

$$
\begin{aligned}
&(1)\ Y_i \sim N(\mu_i, \sigma^2) \\
&(2)\ \mu_i = \beta_0 + \beta_1 renda + \beta_2 propa + \beta_3 taxa + \beta_4 prope + \beta_5 ndazero
\end{aligned}
$$

- Após a seleção baseada no AIC por meio da função *stepGAIC*, temos o seguinte modelo ajustado:

$$
\begin{aligned}
&(1)\ Y_i \sim N(\hat{\mu_i}, \hat{\sigma^2}), \hat{\sigma^2} = 0.5074 \\
&(2)\ \hat{\mu_i} = 71.04 - 0.2831 taxa + 0.0499 prope - 0.0069 ndazero
\end{aligned}
$$

OBS.: A saída do gamlss nos apresenta o $\log(\hat{\sigma})$.

Todos os coeficientes foram significativos a um nível de signinficância de 5%, seguem as interpretações:

- Espera-se que a expectativa de vida seja em média 71.04 anos para um estado em que a taxa de criminalidade é nula, a porcentagem de estudantes que concluem o ensino médio é igual a zero e nenhum dia do ano apresenta temperaturas negativas. (Essa interpretação não tem relevância prática, pois esses valores para as covariáveis, apesar de possíveis, são pouco prováveis de acontecer na prática)
- Considerando as outras covariáveis constantes, ao aumentar uma unidade na taxa de criminalidade espera-se uma redução de 0.2831 na média da expectativa de vida.

- Considerando as outras covariáveis constantes, ao aumentar 1% na proporção de estudantes que concluem o ensino médio espera-se observar um aumento de 0.0499 na expectativa de vida média.
- Considerando as outras covariáveis constantes, espera-se uma redução de 0.0069 na média da expectativa de vida com o aumento de um dia nos número de dias do ano com temperaturas abaixo de zero na cidade mais importante do estado.

1.3 Análise de resíduos

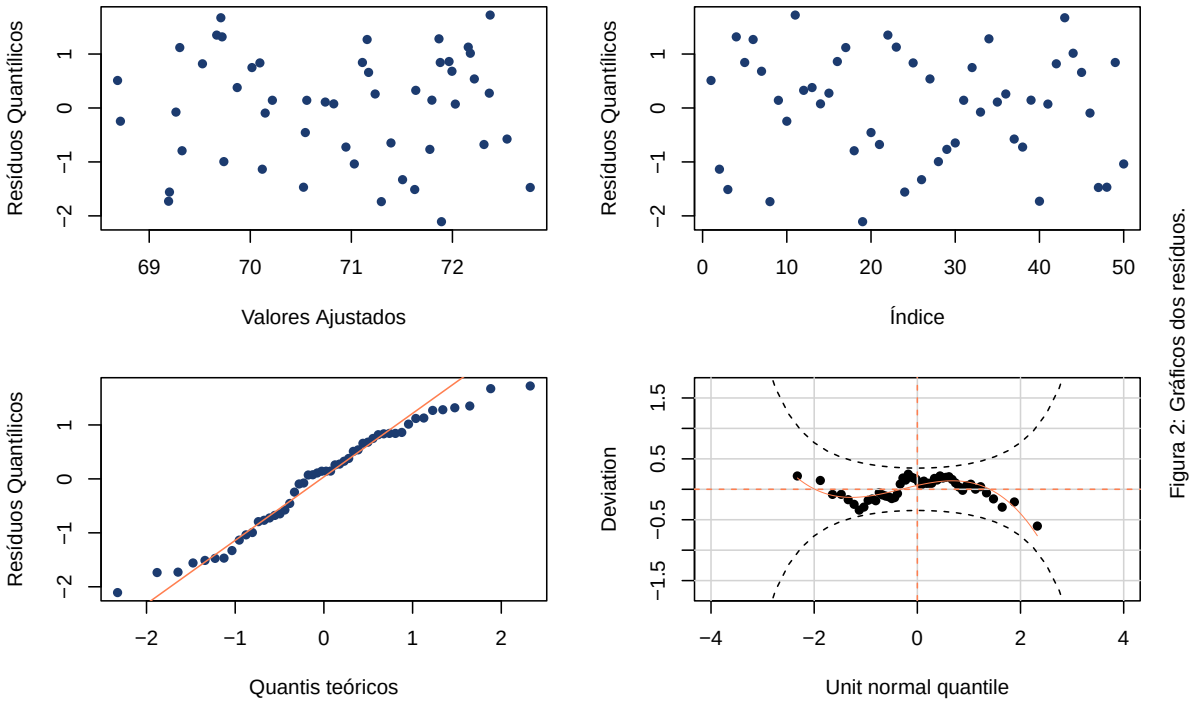


Figura 2: Gráficos dos resíduos.

Na Figura 2 observamos que:

- O gráfico dos resíduos pelo valores ajustados não apresenta nenhum padrão indicativo de heterocedasticidade, a suposição de homocedasticidade é atendida. (Painel superior à esquerda)
- O gráfico dos resíduos pelo índice das observações não apresenta padrões indicativos de dependência entre eles. (Painel superior à direita)
- Os gráficos dos resíduos quantílicos comparados com os quantis da normal (qq-plot e wormplot) não apresentam grandes desvios da normalidade. A suposição de normalidade pode ser considerada adequada. (Painéis inferiores)

1.4 Análise de diagnóstico

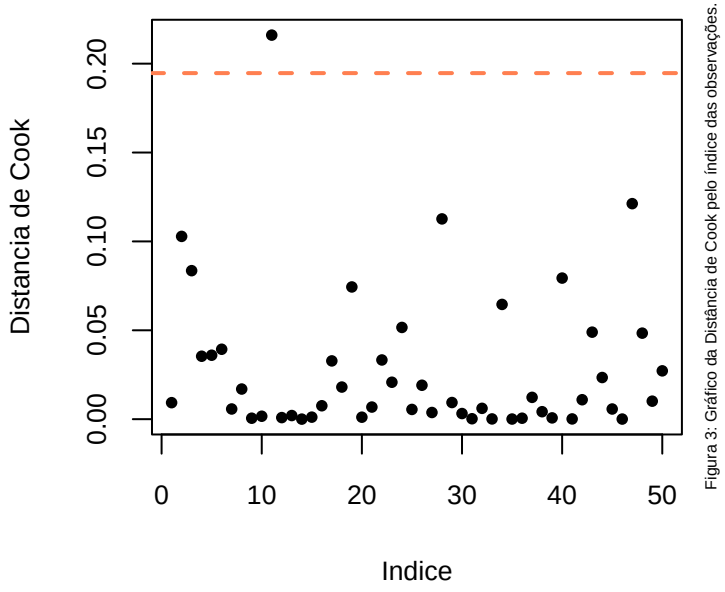


Figura 3: Gráfico da Distância de Cook pelo índice das observações.

Na Figura 3, identificamos que *Hawaii* é o estado que apresenta a maior distância de Cook. Comparamos os valores das covariáveis do estado com as medidas resumo e observamos que ele apresenta o maior valor para a expectativa de vida e o menor valor para o número de dias com temperaturas abaixo de zero.

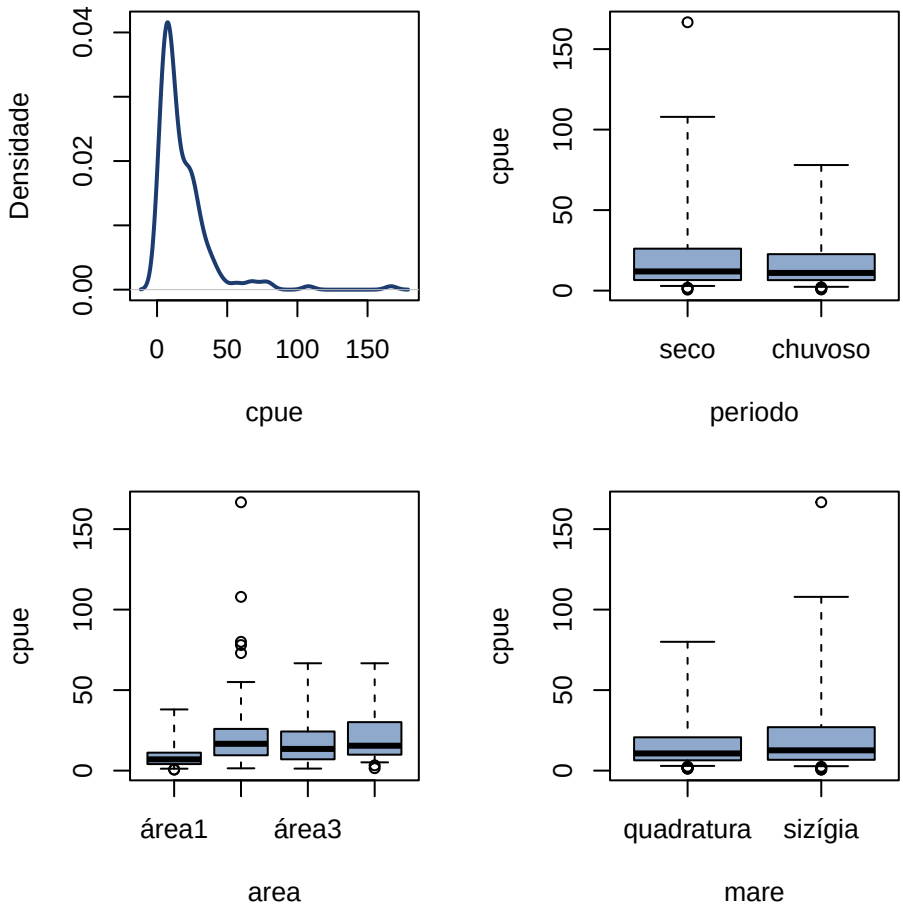
Reajustamos o modelo sem essa observação para avaliar seu impacto nas estimativas e observamos as seguintes variações nos coeficientes estimados: 0.04% (intercepto), 3.87% (taxa), 13.04% (prope) e 28.98% (ndazero). De acordo com o professor Gilberto, variações percentuais desproporcionais (muito acima de $(1/n) \times 100\%$) são esperadas, porém deve-se dar atenção quando ocorrerem mudanças inferenciais. Nesse âmbito, observou-se uma redução na significância da variável *ndazero*, foi de um valor-p de 0.0051 para 0.0555. Portanto, o efeito da covariável *ndazero* deve ser interpretado com cuidado caso o pesquisador defenda a permanência dessa covariável no modelo.

2 Exercício 2

O objetivo principal do estudo é relacionar a cpue média com as demais variáveis explicativas.

- **Periodo** (período da pesca, seco ou chuvoso); **area** (local da pesca, área1, área2, área3, área4); **mare** (maré, quadratura ou sizigia); **vvento** (velocidade do vento, em m/s); **tmax** (temperatura máxima, em °C); **tmin** (temperatura mínima, em °C); **ins** (insolação, em horas); **cpue** (captura por unidade de esforço, em kg).

2.1 Análise descritiva



Na Figura 4, observamos que a variável **cpue** apresenta uma distribuição assimétrica à direita. Apesar da mediana para o período seco ser sutilmente maior, a covariável não parece impactar na captura dos peixes, pois observa-se uma distribuição parecida entre as categorias. As áreas

2 e 4 apresentam a mediana um pouco maior que as demais áreas. A maré de sizigia (maré viva) apresenta a mediana levemente maior que a maré de quadratura.

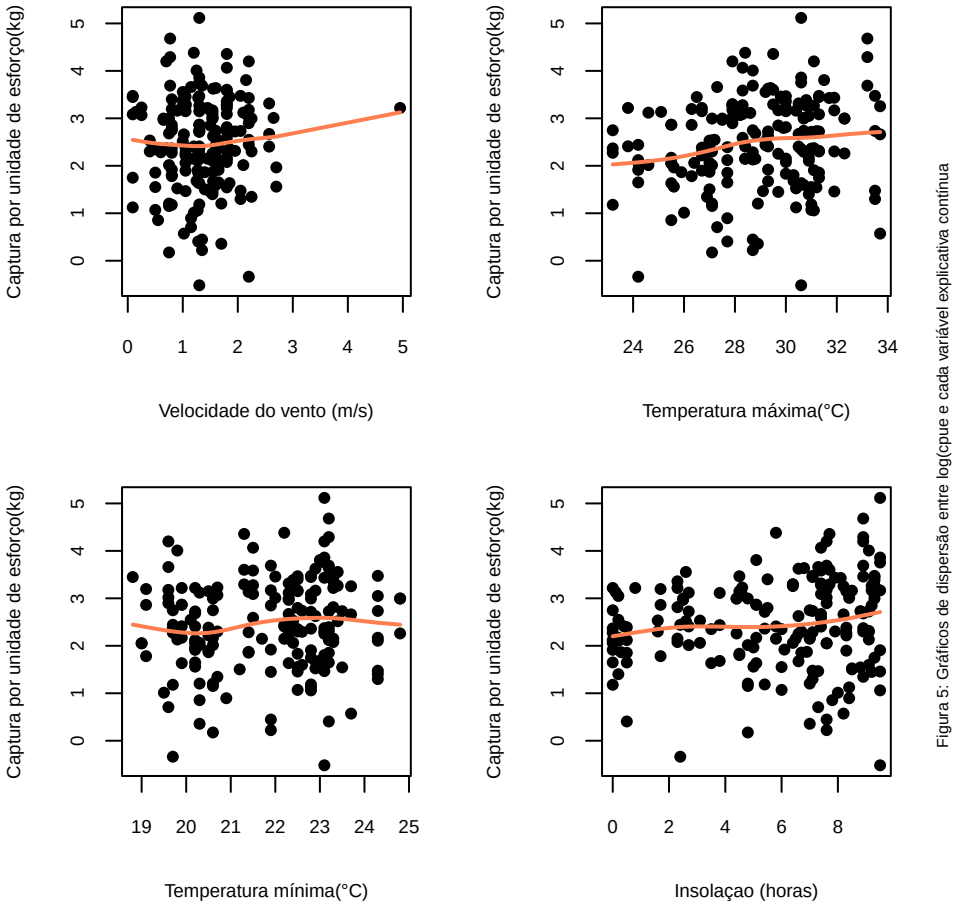


Figura 5: Gráficos de dispersão entre log(cpue e cada variável explicativa contínua

Na Figura 5 é possível verificar que nenhuma das variáveis contínuas parece ter impacto na captura. As tendência aparentam ser lineares e positivas, porém são fracas.

2.2 Ajuste do modelo

- **Ajuste inicial**:

  (1) $Y_i \sim Gama(\mu_i, \sigma)$, em que σ é o coeficiente de variação de Y
  (2) $\log(u_i) = \beta_0 + \beta_1 periodo.chuvoso + \beta_2 area_2 + \beta_3 area_3 + \beta_4 area_4 + \beta_5 mare.sizgia + \beta_6 vvento + \beta_7 tmin + \beta_8 tmax + \beta_9 ins$

- Após a seleção baseada no AIC por meio da função *stepGAIC*, temos o seguinte modelo ajustado:

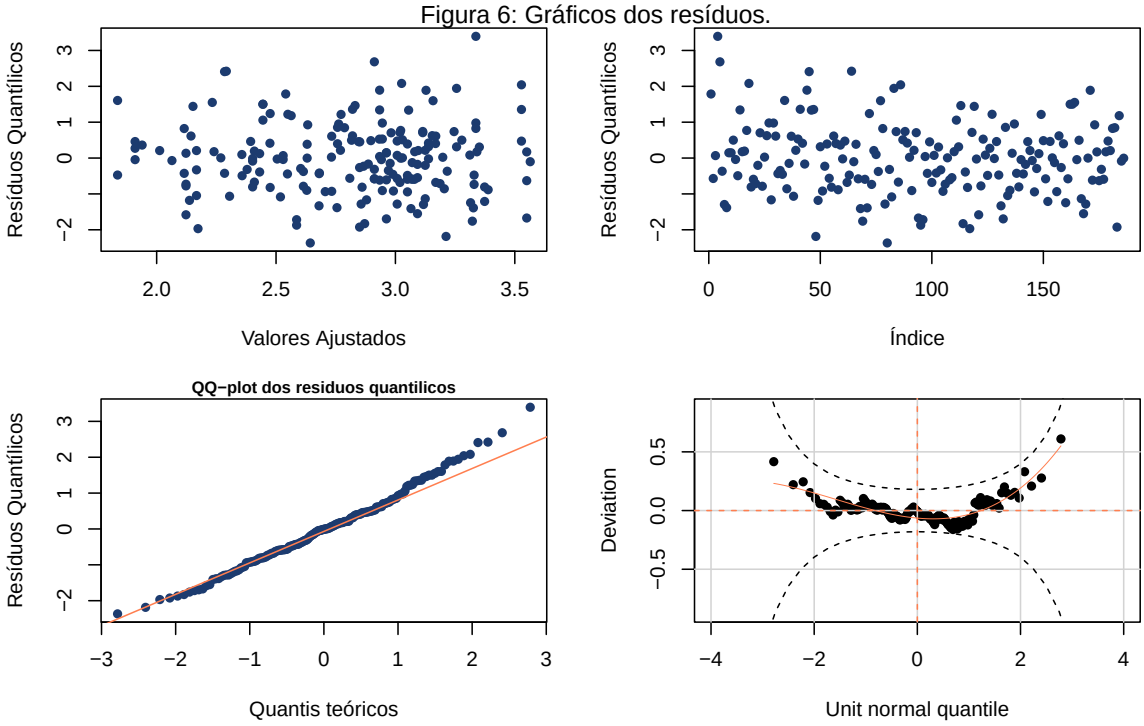
$$
\begin{aligned}
&(1)\ Y_i \sim Gama(\mu_i, \sigma),\ \text{em que } \sigma \text{ é o coeficiente de variação de Y} \\
&(2)\ \log(u_i) = 0.1319 + 0.6935 area_2 + 0.3459 area_3 + \\
&0.6832 area_4 + 0.2635 mare.sizgia + 0.0735 tmax
\end{aligned}
$$

A maioria dos coeficientes foram significativos a um nível de 5%, apenas o efeito da área 3 que apresentou um valor-p igual a 0.07461. A seguir temos as interpretações:

- Para uma frota que pesca na área 1 quando a maré é classificada como de quadratura e a temperatura máxima registrada é de 0°C, espera-se que, em média, a captura por unidade de esforço seja 1.14 kg (Essa interpretação não tem relevância prática, uma temperatura máxima de 0°C não é plausível no contexto dos dados, a menor temperatura máxima registrada é de 23.2°C).
- Considerando as demais covariáveis constantes, a area 2 proporciona o dobro de captura média comparado com a área 1.
- Considerando as demais covariáveis constantes, a area 3 proporciona um aumento de 41% na captura média comparado com a área 1.
- Considerando as demais covariáveis constantes, a area 4 proporciona um aumento de 98% na captura média comparado com a área 1.
- Considerando as demais covariáveis constantes, a maré de sizígia proporciona um aumento de 30% na captura média quando comparada com a maré de quadratura.
- Considerando as demais covariáveis constantes, o aumento de 1°C na temperatura máxima aumenta a média de captura em 7.6%.

2.3 Análise de resíduos

Figura 6: Gráficos dos resíduos.



Na Figura 6 observamos que:

- O gráfico dos resíduos pelo valores ajustados não apresenta nenhum padrão indicativo de heterocedasticidade, a suposição de homocedasticidade é atendida. (Painel superior à esquerda)
- O gráfico dos resíduos pelo índice das observações não apresenta padrões indicativos de dependência entre eles. (Painel superior à direita)
- Os gráficos dos resíduos quantílicos comparados com os quantis da normal (qq-plot e wormplot) não apresentam grandes desvios da normalidade. A suposição de normalidade pode ser considerada adequada. (Painéis inferiores)

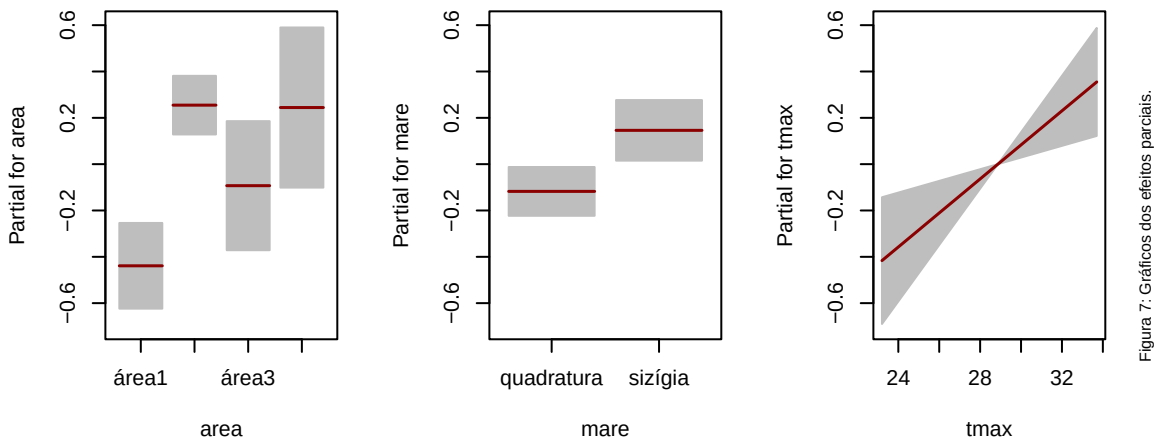
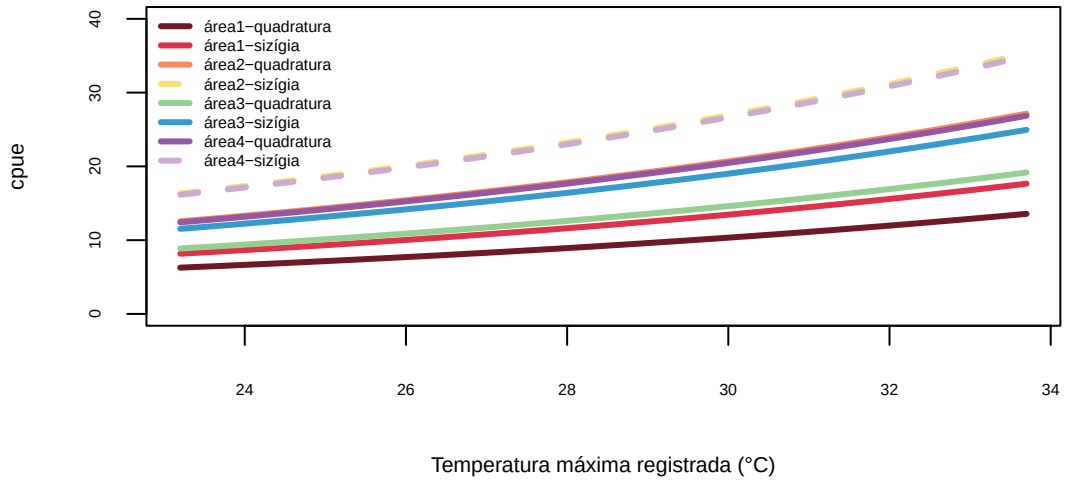


Figura 7: Gráficos dos efeitos parciais.

Conforme a Figura 7, as áreas 2 e 4, bem como a maré de sizígia (em comparação à quadratura), estão associadas a maiores valores esperados de captura. Observa-se ainda que temperaturas mais elevadas exercem um efeito positivo sobre a resposta..

Figura 8: Gráfico o comportamento da cpue ajustada segundo as variáveis explicativas selecionadas



Na Figura 8, observamos que as combinações *área2* - *sizígia* e *área4* - *sizígia* são as que proporcionam valores esperados maiores para a captura.

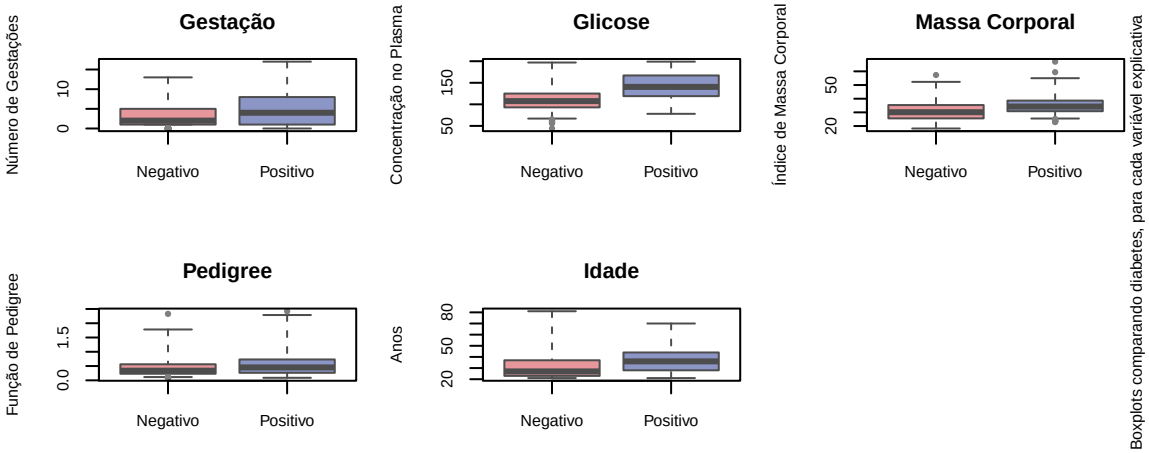
3 Exercício 3

Neste estudo a variável resposta de principal interesse é o diagnóstico de diabetes (1: negativo, 2: positivo), que será relacionada com as seguintes variáveis explicativas: *pregnant* (número de vezes que engravidou); *glucose* (concentração de glicose no plasma); *mass* (índice de massa corporal); *pedigree* (função de pedigree de diabetes, medida hereditária de diabetes); *age* (idade em anos).

3.1 Análise descritiva

Avaliando o comportamento das variáveis explicativas em relação à variável resposta do diagnóstico de diabetes, em mulheres descendentes do povo nativo Pima, podemos observar que

- A concentração de glicose no plasma apresenta a separação mais evidente entre os dois diagnósticos, a mediana da concentração é maior no grupo positivo.
- A mediana do índice de massa corporal em ambos diagnósticos é próxima, ainda que o grupo com diabetes apresente valores visivelmente maiores.
- Mulheres com o diagnóstico positivo apresentam, de modo geral, mais gestações. Além disso, há uma maior dispersão do número de gestações no grupo positivo.
- O grupo negativo é composto majoritariamente por mulheres mais jovens, com a mediana abaixo de 30.
- A função de pedigree de diabetes não possui grande separação evidente, há uma sobreposição dos valores em ambos os grupos, ainda que a mediana das mulheres com o diagnóstico positivo seja levemente maior.



3.2 Ajuste do modelo

Ajustamos um modelo logístico binomial aos dados para explicar a probabilidade π de diagnóstico positivo de diabetes.

- Ajuste inicial:

$$(1)\ Y_i \sim Bernoulli(\pi_i)$$
$$(2)\ log\left(\frac{\pi_i}{1-\pi_i}\right) = \beta_0 + \beta_1 pregnant + \beta_2 glucose + \beta_3 mass + \beta_4 pedigree + \beta_5 age$$

- Ajuste Final:

Usando o `stepGAIC`, obtemos o seguinte modelo, em que a variável explicativa da idade foi removida pois o AIC apresentou melhoria. As demais variáveis explicativas são todas estatísticamente significativas. Também podemos observar que todos os coeficientes são positivos, o aumento em qualquer covariável resulta em um aumento no logito, que traduz em um aumento na chance da paciente ser diagnosticada com diabetes.

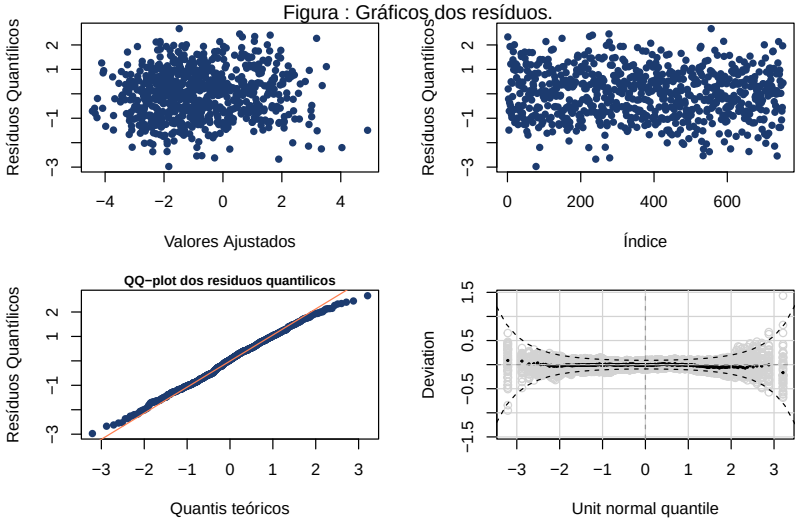
$$(1)\ Y_i \sim Bernoulli(n, \pi_i)$$
$$(2)\ log\left(\frac{\pi_i}{1-\pi_i}\right) = -9.082 + 0.136\text{pregnant} + 0.037\text{glucose} + 0.086\text{mass} + 0.929\text{pedigree}$$

Todas as covariáveis selecionadas possuem coeficientes estatísticamente significativos a um nível de 5%.

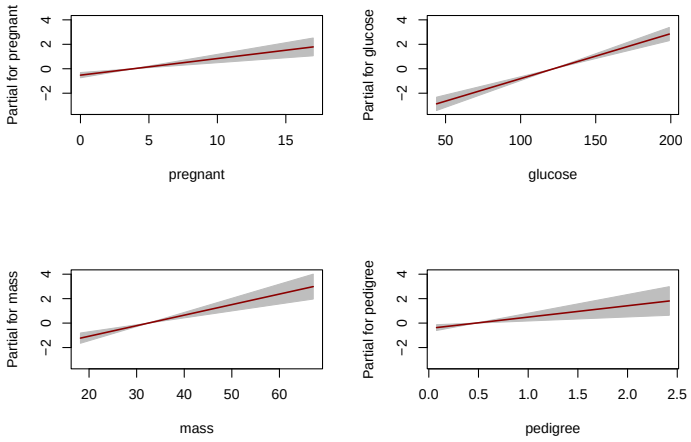
- Mantendo as demais covariáveis constantes, o aumento de uma unidade no número de gestações aumenta em 14.6% a chance de ter diabetes.
- Mantendo as demais covariáveis constantes, o aumento de uma unidade na concentração de glicose no plasma aumenta em 3.7% a chance de ter diabetes.
- Mantendo as demais covariáveis constantes, o aumento de uma unidade no índice de massa corporal aumenta em 9% a chance de ter diabetes.
- Mantendo as demais covariáveis constantes, o aumento de uma unidade no pedigree aumenta em 153.3% a chance de ter diabetes.

3.3 Análise de resíduos

Figura : Gráficos dos resíduos.



Os gráficos dos resíduos pelos valores ajustados e pelo índice não apresentam nenhum padrão indicativo de heterocedasticidade ou dependência. Além disso, o qq-plot e o wormplot não apresentam grandes desvios de normalidade. A suposição de normalidade pode ser considerada adequada.



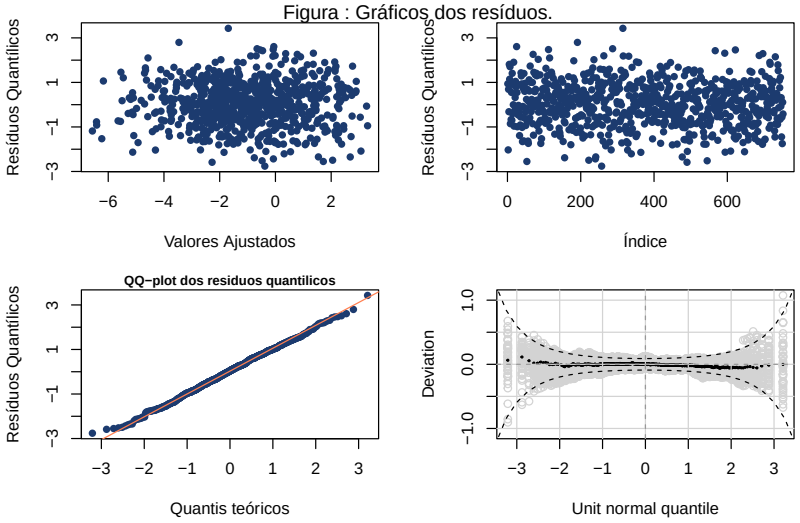
Todos os efeitos parciais são lineares e positivos.

3.4 Ajuste do modelo com splines

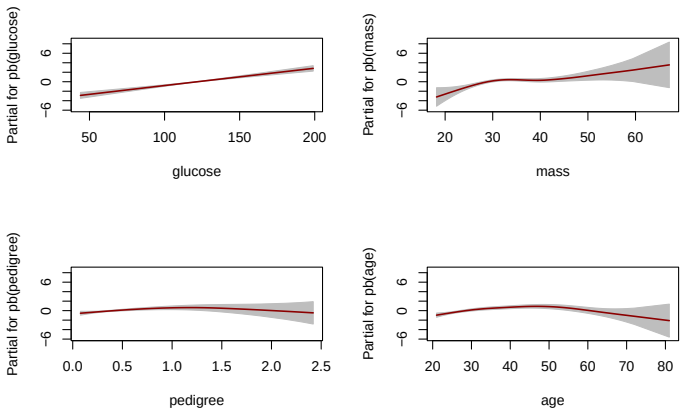
Reajustamos o modelo por meio de P-spline, ajustando as 4 variáveis explicativas contínuas com B-splines de 20 nós internos.

Usando splines, a seleção de variáveis por meio do `stepGAIC` removeu a variável pregnant uma vez que melhorou o AIC de 681.61 para 681.13. O modelo selecionado apresenta um ajuste melhor do que o modelo anterior (com as variáveis explicativas contínuas ajustadas de forma linear), cujo AIC foi de 714. Note que a variável de idade age foi mantida neste caso, indicando que o risco associado à idade é melhor compreendido quando a mesma entra no modelo de forma não linear.

Figura : Gráficos dos resíduos.

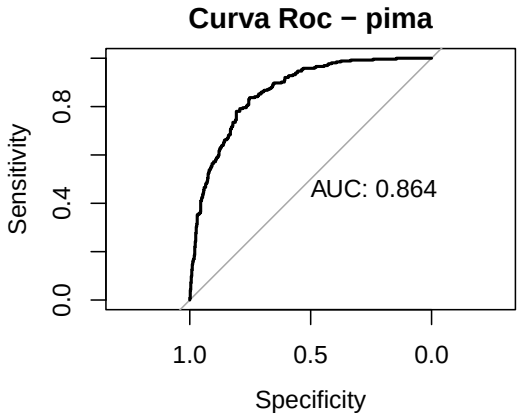


Os gráficos dos resíduos pelos valores ajustados e pelo índice não apresentam nenhum padrão indicativo de heterocedasticidade ou dependência. Além disso, o qq-plot e o wormplot não apresentam grandes desvios de normalidade. A suposição de normalidade pode ser considerada adequada.



A introdução de splines mostra que as variáveis mass, age e pedigree possuem comportamento não linear em relação ao diagnóstico de diabetes. Apenas a variável glicose permaneceu com efeito linear. As variáveis age e pedigree tem um comportamento parabólico, com efeito reduzido nas extremidades. Por fim, a variável mass tem um efeito não linear evidente, o risco aumenta rapidamente, cai levemente e depois aumenta denovo.

Abaixo podemos observar um AUC de 0.864, que caracteriza um classificador muito bom. O modelo de P-splines tem uma alta capacidade de discriminação dos pacientes com ou sem diabetes. O threshold ótimo é de 0.32, ao usar esse limiar para classificar um diagnóstico como positivo obtemos uma taxa alta de 0.837 de verdadeiros positivos, indicando que o modelo identifica corretamente 83.7% das mulheres com diagnóstico de diabetes positivo. Além disso, com o limiar ótimo a especificidade é igual a 0.752, ou seja, o modelo é capaz de classificar corretamente como negativo 75.2% dos casos verdadeiramente negativos (mulheres saudáveis), e, consequentemente, 24.8% de falsos positivos, isto é, mulheres saudáveis que recebem o diagnóstico positivo incorreto.



4 Exercício 4

O objetivo do estudo é explicar o número médio de artigos publicados nos últimos 3 anos pelo doutor dadas as variáveis explicativas: *art* (número de artigos publicados nos últimos 3 anos pelo doutor), *fem* (fator indicando gênero, masculino ou feminino), *mar* (fator indicando o estado civil, casado ou solteiro), *kid5* (número de crianças com até 5 anos), *phd* (prestígio do departamento onde o aluno fez o doutorado), *ment* (número de artigos publicados pelo orientador).

4.1 Análise descritiva

A distribuição do número de artigos publicados é assimétrica à direita, característica de dados de contagem. Além disso, a maioria dos doutores no banco de dados publicou entre 0 e 2 artigos apenas e 275 indivíduos publicaram exatamente 0, que corresponde a 30% do banco de dados. Também temos alguns outliers com mais de 15 artigos publicados. Dos 9 indivíduos que publicaram mais de 7 artigos, apenas um é mulher e todos são casados. Temos uma amostra desbalanceada em relação à variável *mar*, apenas 1/3 da amostra tem estado civil de solteiro e portanto possui menos representação nas publicações dos artigos.

Table 1: Tabela das proporções por linhas

Gênero	Número de Artigos															
	0	1	2	3	4	5	6	7	8	9	10	11	12	16	19	Total
Men	27.53	27.33	17.61	10.93	7.69	3.24	1.82	2.23	0.2	0.4	0.00	0.2	0.4	0.2	0.2	100
Women	33.02	26.37	21.62	7.13	6.89	2.61	1.90	0.24	0.0	0.0	0.24	0.0	0.0	0.0	0.0	100

Pela Tabela 1, observa-se indícios de que as mulheres estão mais propensas a não ter artigos publicados (33.02%) do que os homens (27.53%).

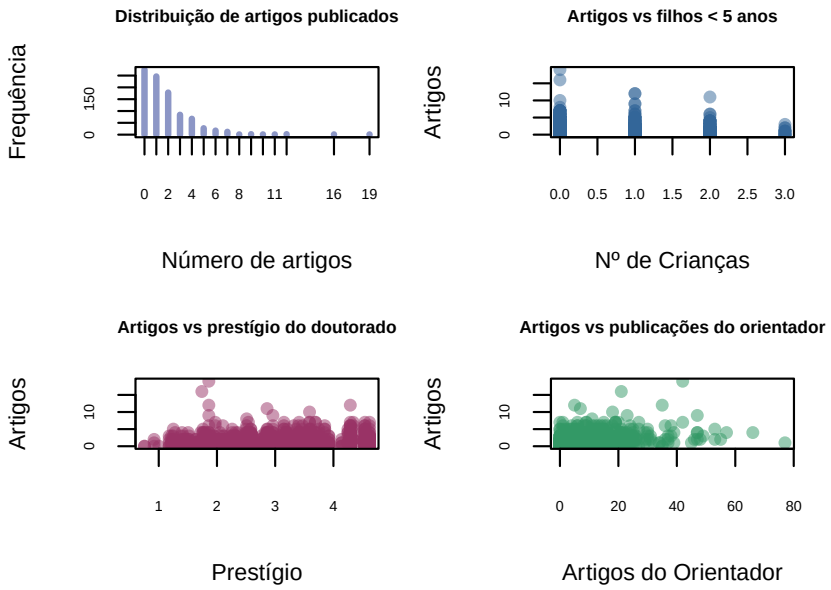
Table 2: Tabela das proporções por linhas

Estado Civil	Número de Artigos															
	0	1	2	3	4	5	6	7	8	9	10	11	12	16	19	Total
Single	32.04	27.18	19.42	7.12	7.12	1.94	2.59	2.59	0.00	0.00	0.00	0.00	0.00	0.00	0.00	100
Married	29.04	26.73	19.47	10.23	7.43	3.47	1.49	0.66	0.17	0.33	0.17	0.17	0.33	0.17	0.17	100

Pela Tabela 2, observa-se que o grupo dos solteiros parece mais propenso a não ter artigos publicados (32.04%) do que os casados (29.04%).

O gráfico de dispersão do número de artigos contra o número de filhos com menos de 5 anos sugere um impacto no volume de publicações, indivíduos com mais filhos pequenos publicam menos. Não aparenta haver uma relação muito forte entre o prestígio da instituição e o número de publicações, ambos os extremos do prestígio possuem alta e baixa produtividade. No entanto,

a produtividade do orientador aparenta ter uma relação com a produtividade do orientado, quanto mais o orientador publica há uma tendência do orientado publicar mais.



4.2 Ajuste do modelo Poisson

- Ajuste inicial:

$$(1)\ Y_i \sim Poisson(\mu_i)$$
$$(2)\ log(\mu_i) = \beta_0 + \beta_1 fem + \beta_2 mar + \beta_3 kid5 + \beta_4 phd + \beta_5 ment$$

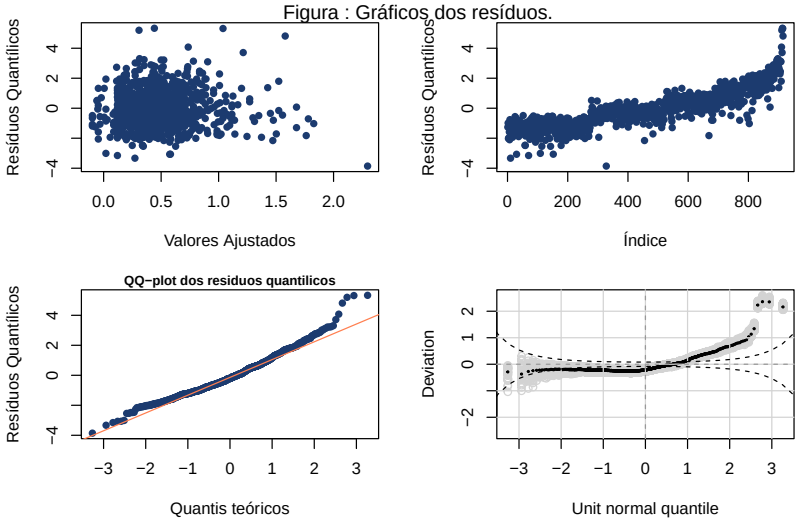
- Ajuste Final:

$$(1)\ Y_i \sim Poisson(\mu_i)$$
$$(2)\ log(\mu_i) = 0.345174 - 0.225303 fem + 0.152175 mar - 0.184993 kid5 + 0.025761 ment$$

- Um homem solteiro, sem filhos, cujo orientador não pubiblicou nenhum artigo, publica em média 1.41 artigos.
- Mantendo as demais covariáveis constantes, ser do sexo feminino reduz em aproximadamente 20% o número de artigos publicados.
- Mantendo as demais covariáveis constantes, estar casado aumenta em aproximadamente 16% o número de artigos publicados.

- Mantendo as demais covariáveis constantes, o aumento de uma unidade no número de filhos reduz em 17% o número de artigos publicados.
- Mantendo as demais covariáveis constantes, o aumento de uma unidade no número de artigos publicados pelo orientador aumenta em aproximadamente 3% o número de artigos publicados pelo doutor.

Figura : Gráficos dos resíduos.



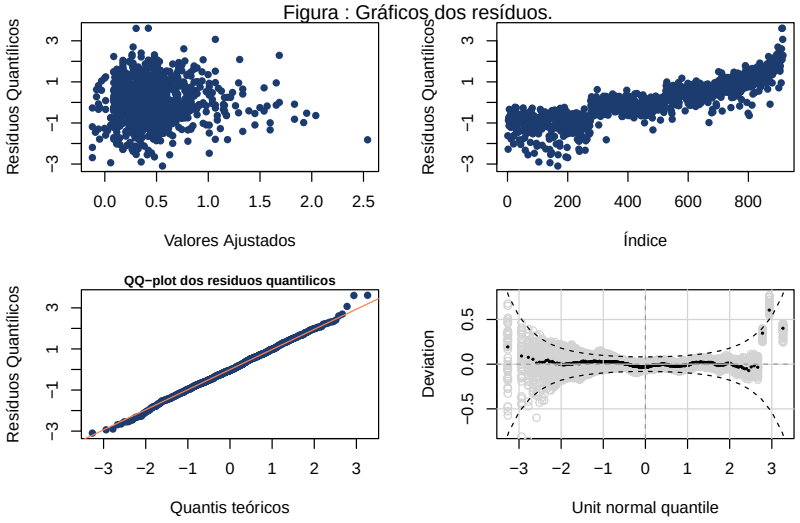
A análise dos resíduos quantílicos indica que o modelo Poisson apresenta sérios problemas de ajuste. O gráfico contra os valores ajustados revela uma dispersão desproporcional com resíduos positivos muito elevados e o gráfico dos resíduos pelo índice das observações apresenta uma curva, indicando problema de superdispersão. Além disso, os gráficos dos resíduos comparados com os quantis da normal (qq-plot e wormplot) apresentam grandes desvios da normalidade. O modelo postulado apresenta problemas.

4.3 Ajuste do modelo log-linear

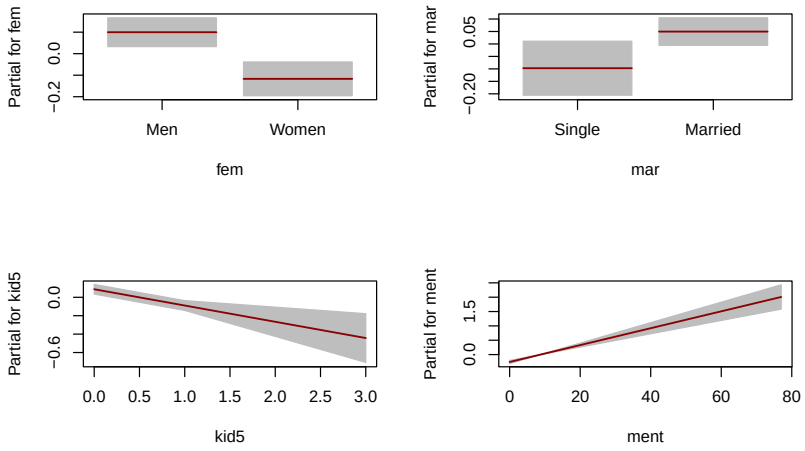
- Ajuste:

$$(1)\ Y_i \sim BN(\mu_i, \phi)$$
$$(2)\ log(\mu_i) = \beta_0 + \beta_1 fem_i + \beta_2 mar_i + \beta_3 kid5_i + \beta_4 phd_i + \beta_5 ment_i$$

Figura : Gráficos dos resíduos.



Embora a estrutura de dispersão nos valores ajustados e o padrão do índice aparentam ser semelhantes aos do modelo Poisson, a substituição pela distribuição binomial negativa trouxe uma ganho no ajuste global. Houve uma redução na escala dos resíduos quantílicos, que não atingem mais valores extremos observados no modelo anterior. A introdução de ϕ como um parâmetro de dispersão trata o problema de superdispersão do modelo de Poisson. Além disso, o qq-plot e o wormplot melhoraram significativamente e não apresentam grandes desvios. Portanto a suposição de normalidade pode ser considerada adequada. Por esses motivos, escolhemos o modelo binomial negativo como a melhor opção.



No gráfico acima, podemos observar o impacto parcial de cada covariável sobre o preditor linear. Para o gênero (fem), há um degrau evidente da categoria de homens para mulheres, o que

indica uma menor expectativa de publicações para as mulheres quando as demais covariáveis são mantidas constantes. O estado civil (mar) apresenta um salto positivo, indicando que estar casado se associa a mais publicações. O número de filhos com menos de 5 anos (kid5) apresenta uma reta decrescente, ou seja, o efeito é negativo e logo quanto mais filhos, menos publicações. Por fim, o volume de publicações do orientador tem um efeito positivo, quanto mais o orientador publica, maior é o número esperado de artigos do doutor orientado.

- Um homem solteiro, sem crianças de até 5 anos, cujo orientador não publicou nenhum artigo, publica em média 1.354 artigos. (IC 95%) = [1.153; 1.592].
- Mulheres apresentam uma média esperada de artigos aproximadamente 19.5% menor que homens, mantendo as demais variáveis constantes. Como o intervalo de confiança não contém 1, essa diferença é estatisticamente significativa ao nível de 5%. (IC 95%) = [0.698; 0.928].
- Doutores casados apresentam uma média esperada de artigos aproximadamente 15.8% maior que doutores solteiros, mantendo as demais variáveis constantes. No entanto, como o intervalo de confiança contém 1, a diferença não é estatisticamente significativa ao nível de 5%. (IC 95%) = [0.987; 1.359].
- Para cada criança adicional de até 5 anos, a média esperada de artigos diminui aproximadamente 16.2%, mantendo as demais variáveis constantes. Como o intervalo de confiança não contém 1, essa associação é estatisticamente significativa ao nível de 5%. (IC 95%) = [0,755; 0,930].
- Para cada artigo adicional publicado pelo orientador, a média esperada de artigos do doutor aumenta aproximadamente 3%, mantendo as demais variáveis constantes. Como o intervalo de confiança não contém 1, essa associação é estatisticamente significativa ao nível de 5%. (IC 95%) = [1.023; 1.037].

5 Declaração de contribuição

Declaramos que ambas as participantes da dupla contribuíram para a conclusão deste trabalho. Os exercícios 1 e 2 foram redigidos pela Jaqueline e revisados pela Maia. Já os exercícios 3 e 4 foram desenvolvidos pela Maia e revisados pela Jaqueline.

6 Códigos

Os códigos estão disponíveis no repositório do github: (https://github.com/Jaqueline-LS/2-USP-2026.2-MLG-Listas)